ĐẠI HỌC QUỐC GIA HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA MẠNG MÁY TÍNH VÀ TRUYỀN THÔNG

TRƯƠNG ĐỨC HÀO
LÊ HỒNG HIỂN

KHÓA LUẬN TỐT NGHIỆP

CƠ CHẾ PHÒNG THỦ TRƯỚC TẤN CÔNG ĐỐI KHÁNG NHẮM VÀO HỆ THỐNG PHÁT HIỆN XÂM NHẬP DỰA TRÊN CHIẾN LƯỢC PHÒNG THỦ DI CHUYỂN MỤC TIÊU VÀ HỌC TĂNG CƯỜNG

A DEFENSE MECHANISM AGAINST ADVERSARIAL ATTACKS TARGETING INTRUSION DETECTION SYSTEMS BASED ON MOVING TARGET DEFENSE STRATEGY AND REINFORCEMENT LEARNING

CỬ NHÂN NGÀNH AN TOÀN THÔNG TIN

TP.Hồ Chí Minh – Tháng 1, 2026

ĐẠI HỌC QUỐC GIA HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA MẠNG MÁY TÍNH VÀ TRUYỀN THÔNG

TRƯƠNG ĐỨC HÀO - 22520407
LÊ HỒNG HIỂN - 22520416

KHÓA LUẬN TỐT NGHIỆP

CƠ CHẾ PHÒNG THỦ TRƯỚC TẤN CÔNG ĐỐI KHÁNG NHẮM VÀO HỆ THỐNG PHÁT HIỆN XÂM NHẬP DỰA TRÊN CHIẾN LƯỢC PHÒNG THỦ DI CHUYỂN MỤC TIÊU VÀ HỌC TĂNG CƯỜNG

A DEFENSE MECHANISM AGAINST ADVERSARIAL ATTACKS TARGETING INTRUSION DETECTION SYSTEMS BASED ON MOVING TARGET DEFENSE STRATEGY AND REINFORCEMENT LEARNING

CỬ NHÂN NGÀNH AN TOÀN THÔNG TIN

GIẢNG VIÊN HƯỚNG DẪN:
TS. Phan Thế Duy

TP.Hồ Chí Minh – Tháng 1, 2026

THÔNG TIN HỘI ĐỒNG CHẤM KHÓA LUẬN TỐT NGHIỆP

Hội đồng chấm khóa luận tốt nghiệp, thành lập theo Quyết định số 60 ngày 15/01 năm 2026 của Hiệu trưởng Trường Đại học Công nghệ Thông tin.

Chủ tịch:	TS. Lê Văn Tuấn
Thư ký:	ThS. Đỗ Thị Phương Uyên
Ủy viên:	ThS. Nguyễn Thanh Sơn

LỜI CẢM ƠN

Trong quá trình thực hiện và hoàn thành khóa luận tốt nghiệp, nhóm chúng em đã nhận được nhiều sự hỗ trợ quý báu cả về chuyên môn lẫn tinh thần từ các giáo viên hướng dẫn và giáo viên bộ môn. Đây là nguồn động lực quan trọng giúp chúng em kiên trì vượt qua những khó khăn về kỹ thuật, áp lực tiến độ và từng bước hoàn thiện kết quả nghiên cứu.

Trước hết, nhóm xin bày tỏ lòng biết ơn sâu sắc đến thầy Phan Thế Duy – người đã trực tiếp đồng hành và định hướng xuyên suốt quá trình thực hiện đề tài. Những góp ý cụ thể của thầy về cách tiếp cận vấn đề, phương pháp triển khai, cũng như sự tận tình hỗ trợ khi nhóm gặp vướng mắc đã giúp chúng em điều chỉnh hướng đi kịp thời và nâng cao chất lượng khóa luận. Không chỉ dừng lại ở chuyên môn, thầy còn chia sẻ cho chúng em những bài học thực tế về tác phong làm việc, tinh thần trách nhiệm và cách nhìn nhận nghề nghiệp – những điều có ý nghĩa lâu dài với chúng em trên con đường trở thành tân cử nhân.

Nhóm cũng xin chân thành cảm ơn quý thầy cô Trường Đại học Công nghệ Thông tin – ĐHQG TP.HCM, đặc biệt là quý thầy cô Khoa Mạng máy tính và Truyền thông và Bộ môn An toàn Thông tin, đã cung cấp nền tảng kiến thức, góp ý chuyên môn và tạo điều kiện để nhóm có môi trường học thuật phù hợp nhằm hoàn thiện đề tài một cách toàn diện.

Trương Đức Hào

Lê Hồng Hiển

MỤC LỤC

THÔNG TIN HỘI ĐỒNG CHẤM KHÓA LUẬN TỐT NGHIỆP i
LỜI CẢM ƠN ii
MỤC LỤC iii
DANH MỤC CÁC KÝ HIỆU, CÁC CHỮ VIẾT TẮT vii
DANH MỤC CÁC HÌNH VẼ viii
DANH MỤC CÁC BẢNG BIỂU viii

CHƯƠNG 1. TỔNG QUAN **3**
1.1 Giới thiệu vấn đề 3
1.2 Các hướng tiếp cận phát hiện xâm nhập hiện nay 4
1.2.1 IDS truyền thống dựa trên chữ ký và bất thường 4
1.2.2 Học máy và học sâu trong phát hiện xâm nhập 5
1.2.3 Học tăng cường và Moving Target Defense cho IDS 6
1.2.4 Drift dữ liệu trong hệ thống phát hiện xâm nhập 7
1.3 Tính cấp thiết và tính ứng dụng của đề tài 8
1.4 Những thách thức 9
1.4.1 Môi trường tấn công – phòng thủ động và tương tác 9
1.4.2 Độ phức tạp của trôi dạt dữ liệu trong IDS 10
1.4.3 Tài nguyên tính toán và chi phí huấn luyện 11
1.4.4 Đánh giá tính bền vững và khả năng phục hồi dưới drift . 12
1.5 Mục tiêu, đối tượng và phạm vi nghiên cứu 12
1.5.1 Mục tiêu nghiên cứu 12
1.5.2 Đối tượng nghiên cứu 13
1.5.3 Phạm vi nghiên cứu 13
1.6 Cấu trúc khóa luận tốt nghiệp 14

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT **15**

2.1 Hệ thống phát hiện xâm nhập, tập dữ liệu CIC-IDS2017 và CIC-APT-IIOT-2024 15

2.1.1 Khái niệm IDS và phân loại 15

2.1.2 Đặc điểm tập dữ liệu 16

2.1.3 Các kiểu tấn công tiêu biểu 19

2.2 Drift dữ liệu trong an ninh mạng 22

2.2.1 Khái niệm concept drift, covariate drift, prior drift 22

2.2.2 Hiện tượng Drift tự nhiên trong lưu lượng mạng 24

2.2.3 Drift đối kháng và poisoning 25

2.3 Học tăng cường (Reinforcement Learning) và DQN 26

2.3.1 Mô hình hóa bài toán: Từ MDP đến Markov Game 26

2.3.2 Deep Q-Network, Double DQN, Dueling DQN 27

2.3.3 Replay buffer, Prioritized Experience Replay và chống nhiễm độc 28

2.4 Moving Target Defense (MTD) cho NIDS 29

2.4.1 Khái niệm MTD và ứng dụng trong an toàn mạng 29

2.4.2 Chiến lược Đa dạng hóa kiến trúc NIDS dựa trên MTD . . 30

2.5 Các kỹ thuật phát hiện Drift truyền thống 31

2.6 Tổng kết 32

CHƯƠNG 3. MÔ HÌNH IDS THÍCH NGHI DỰA TRÊN HỌC TĂNG CƯỜNG VÀ MOVING TARGET DEFENSE **33**

3.1 Tổng quan kiến trúc mô hình 33

3.2 Môi trường Đồng tiến hóa (Co-Evolutionary Environment) 35

3.2.1 Không gian trạng thái 36

3.2.2 Không gian hành động 37

3.2.3 Hàm thưởng cho Defender và Attacker 42

3.3 Thiết kế và Huấn luyện Tác nhân Phòng thủ 45
3.3.1 Kiến trúc Mạng Dueling Deep Q-Network 45
3.3.2 Cơ chế Huấn luyện Ổn định với Double DQN 47
3.3.3 Chiến lược chọn hành động bằng khám phá Boltzmann . . 48
3.4 ADI Scheduler – Adversarial Drift Injection 49
3.4.1 Các phương thức Tiêm Drift Tổng hợp 49
3.4.2 Các chế độ Lịch trình Drift 50
3.4.3 Cơ chế Điều chỉnh Độ khó Thích ứng 51
3.5 SOTADriftEmbedding 51
3.5.1 Cấu trúc chi tiết Vector SOTADriftEmbedding 52
3.5.2 Phát hiện trôi dạt khái niệm và cập nhật τ_{polyak} thích ứng 54
3.5.3 Cơ Chế Học Tăng Cường 55
3.6 Cơ chế Phòng thủ Mạnh mẽ và Chống Đầu độc 56
3.6.1 Tăng cường Thời gian Kiểm thử 56
3.6.2 Robust Prioritized Experience Replay (RobustPER) 56
3.7 Enhanced RL Select Ensemble – pha đánh giá dưới drift 57
3.7.1 Kế thừa Q-network và Model Pool từ pha huấn luyện . . . 57
3.7.2 Adapter Drift 58
3.7.3 Chiến lược Phòng thủ Phân tầng 58
3.8 Phân tích độ phức tạp của thuật toán 60
3.8.1 So sánh độ phức tạp tính toán của các mô hình thành phần 60
3.8.2 Phân tích thời gian thích ứng và độ trễ phục hồi: 60
3.8.3 Phân tích độ bền vững trong khoảng trễ thích nghi 62
3.8.4 Đánh giá chiến lược đánh đổi và Tính khả thi triển khai . 63

CHƯƠNG 4. HIỆN THỰC,THỰC NGHIỆM VÀ ĐÁNH GIÁ 65
4.1 Câu hỏi nghiên cứu 65
4.2 Hiện thực hệ thống 66
4.2.1 Ngôn ngữ lập trình và môi trường 66
4.2.2 Thông số kỹ thuật của các mô hình 67

4.3 Thực nghiệm và đánh giá 69
4.3.1 Mô tả dữ liệu 69
4.3.2 Tiền xử lý dữ liệu và chiến lược phân chia 75
4.3.3 Các kịch bản thí nghiệm 78
4.3.4 Kết quả thực nghiệm 83

CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 96

5.1 Kết luận 96
5.2 Hướng phát triển 98

TÀI LIỆU THAM KHẢO 99

DANH MỤC CÁC KÝ HIỆU, CÁC CHỮ VIẾT TẮT

MORPH-IDS	Moving Objective Reinforcement Learning Framework for Proactive and Hardened Intrusion Detection Systems
IDS	Hệ thống phát hiện xâm nhập
NIDS	Hệ thống phát hiện xâm nhập dựa trên mạng
HIDS	Hệ thống phát hiện xâm nhập được cài đặt trên các máy chủ
MTD	Phòng thủ Mục tiêu Di động
RL	Học tăng cường
DQN	Mạng nơ-ron sâu dùng để xấp xỉ hàm Q trong học tăng cường
DDQN	Biến thể của DQN
PER	Kỹ thuật lấy mẫu dữ liệu huấn luyện dựa trên mức độ quan trọng của trải nghiệm
CIC-IDS2017	Bộ dữ liệu phát hiện xâm nhập CIC-IDS 2017
TTA	Test-Time Augmentation
SOTA	Phương pháp tiên tiến nhất hiện nay
SOTADriftEmbedding	Mô-đun nhúng drift 20 chiều được đề xuất
ADI	Bộ tiêm drift đối kháng
AUC-ROC	Diện tích dưới đường cong ROC
DR	Tỉ lệ phát hiện
FN/FP/TP/TN	False Negative/False Positive/True Positive/True Negative
MDP	Quá trình ra quyết định Markov

DANH MỤC CÁC HÌNH VẼ

Hình 3.1 Mô hình tổng quan kiến trúc của MORPH-IDS 34

Hình 4.1 Phân phối nhãn trong tập dữ liệu CIC-IDS2017 70

Hình 4.2 Top 20 đặc trưng quan trọng nhất đối với CIC-IDS2017 (Random Forest) 72

Hình 4.3 Phân phối nhãn trong CIC-APT-IIoT-2024 73

Hình 4.4 Top 20 đặc trưng quan trọng nhất đối với CIC-APT-IIoT-2024 (Random Forest) 75

DANH MỤC CÁC BẢNG BIỂU

Bảng 3.1 So sánh độ phức tạp tính toán của các mô hình thành phần 60

Bảng 4.1 Thống kê phân phối tập dữ liệu CIC-IDS2017 70

Bảng 4.2 Top 20 đặc trưng quan trọng nhất đối với CIC-IDS2017 (Random Forest) 71

Bảng 4.3 Thống kê tổng quan tập dữ liệu CIC-APT-IIoT-2024 73

Bảng 4.4 20 đặc trưng quan trọng hàng đầu đối với CIC-APT-IIoT-2024 (Random Forest) 74

Bảng 4.5 Kết quả baseline ở tập dữ liệu CIC-IDS2017(Kịch bản 1) . . 84

Bảng 4.6 Chi tiết thành phần Ma trận nhầm lẫn trên CIC-IDS2017 (Tập test: 251,783 mẫu) 84

Bảng 4.7 Kết quả baseline ở tập dữ liệu CIC-APT-IIOT-2024(Kịch bản 1) 85

Bảng 4.8 Chi tiết thành phần Ma trận nhầm lẫn trên CIC-APT-IIoT-2024 (Tập test: 6,201 mẫu) 86

Bảng 4.9 Kết quả của MORPH-IDS dưới tác động của tấn công ZOO(Kịch bản 2) 88

Bảng 4.10 Kết quả của MORPH-IDS dưới tác động của tấn công HSJA AML(Kịch bản 2) 88

Bảng 4.11 Ma trận Nhầm lẫn Tổng hợp cho MORPH-IDS dưới Tấn công ZOO (4 mô hình × 1000 mẫu) 89

Bảng 4.12 Ma trận Nhầm lẫn Tổng hợp cho MORPH-IDS dưới Tấn công HSJA (4 mô hình × 200 mẫu) 89

Bảng 4.13 Kết quả so sánh khả năng thích nghi Concept Drift trên CIC-IDS2017(Kịch bản 3) 91

Bảng 4.14 Kết quả so sánh khả năng thích nghi Concept Drift trên CIC-APT-IIoT-2024(Kịch bản 4) 93

TÓM TẮT KHÓA LUẬN

Với sự phát triển bùng nổ về quy mô và độ phức tạp của hạ tầng mạng, điện toán đám mây và IoT, bề mặt tấn công mạng ngày càng mở rộng, đặt ra những thách thức lớn cho các Hệ thống Phát hiện Xâm nhập Mạng (NIDS). Mặc dù đóng vai trò then chốt trong an ninh mạng, các hệ thống NIDS truyền thống dựa trên Học máy (ML) tĩnh đang bộc lộ những điểm yếu nghiêm trọng trước các môi trường phi tĩnh. Cụ thể, sự phụ thuộc vào dữ liệu huấn luyện cố định khiến chúng dễ bị tổn thương trước hiện tượng trôi khái niệm (concept drift) và các cuộc tấn công đối kháng (adversarial attacks) tinh vi, nơi kẻ tấn công chủ động khai thác điểm mù của các mô hình hoặc đầu độc dữ liệu (poisoning).

Để giải quyết những thách thức cấp thiết này, khóa luận đề xuất một khung phòng thủ thích ứng mới, kết hợp kỹ thuật Phòng thủ Mục tiêu Di động (Moving Target Defense - MTD) và Học tăng cường đa tác nhân (Multi-agent Reinforcement Learning - RL). Hệ thống được mô hình hóa dưới dạng một trò chơi đồng tiến hóa (co-evolutionary game) giữa tác nhân "Defender" – chịu trách nhiệm tối ưu hóa chiến lược lựa chọn và cấu hình mô hình từ một tập các mô hình phòng thủ (model pools), và tác nhân "Attacker" – liên tục học cách tạo ra các nhiễu loạn để lẩn tránh. Kiến trúc này được xây dựng dựa trên kiến trúc Dueling Double Deep Q-Network (DQN) kết hợp với phương pháp thăm dò Boltzmann, giúp tạo ra một thế trận phòng thủ liên tục thay đổi và khó đoán.

Để đối phó trực tiếp với concept drift một cách cụ thể, nhóm giới thiệu kỹ thuật nhúng drift 20 chiều (Drift Embedding) tiên tiến, cung cấp cho các tác nhân khả năng nhận thức tình huống theo thời gian thực về sự dịch chuyển phân phối và các dấu hiệu tấn công poisoning. Điều này cho phép thực hiện một số cơ chế thích ứng như phát hiện điểm thay đổi, học liên tục để ngăn chặn hiện tượng lãng quên thảm khốc (catastrophic forgetting), và mô hình học theo nhịp

độ tự điều chỉnh (self-paced curriculum) giúp học hiệu quả trên dữ liệu thay đổi. Tốc độ học được tăng tốc thông qua kỹ thuật Định hình Phần thưởng Dựa trên Tiềm năng (Potential-Based Reward Shaping - PBRS), trong khi độ bền vững (robustness) được cải thiện nhờ bộ đệm Hồi Trải nghiệm Ưu tiên (PER) có khả năng nhận biết poisoning và một bộ khử nhiễu đối kháng (adversarial denoiser).

Kết quả thực nghiệm trên bộ dữ liệu chuẩn CIC-IDS2017 chứng minh tính hiệu quả vượt trội của giải pháp đề xuất so với các mô hình tĩnh. Hệ thống đạt độ chính xác phát hiện trên 90% và duy trì độ bền vững 85% ngay cả dưới điều kiện drift đối kháng. Việc tích hợp PBRS giúp tăng tốc độ hội tụ lên 2.7 lần, cho phép thích ứng nhanh chóng với các mối đe dọa mới. Đặc biệt, hệ thống còn giảm thiểu hiệu quả các cuộc tấn công poisoning với độ chính xác 88% tại tỷ lệ nhiễm độc 5%. Bằng cách liên tục thay đổi động thế trận phòng thủ, phương pháp MTD tạo ra một mục tiêu động, mang lại giải pháp chủ động và thông minh cho các hệ thống IDS thế hệ mới trong thời buổi hiện nay.

CHƯƠNG 1. TỔNG QUAN

Chương này giới thiệu về vấn đề và các nghiên cứu liên quan. Đồng thời, phạm vi và cấu trúc của Khóa luận sẽ được trình bày trong chương này.

1.1. Giới thiệu vấn đề

Hệ thống phát hiện xâm nhập mạng (Network Intrusion Detection System - NIDS) đóng vai trò là thành phần then chốt trong kiến trúc an ninh mạng hiện đại. Tuy nhiên, các hệ thống NIDS dựa trên học máy truyền thống thường được xây dựng trên giả định dữ liệu là tĩnh và độc lập. Giả định này khiến NIDS trở nên dễ bị tổn thương trước hai thách thức lớn hiện nay: Tấn công đối kháng (Adversarial Attacks) và Trôi dạt khái niệm (Concept Drift) [11]. Trong khi tấn công đối kháng là những nỗ lực có chủ đích nhằm thay đổi dữ liệu đầu vào để đánh lừa mô hình, thì trôi dạt khái niệm lại làm suy giảm hiệu suất theo thời gian do sự thay đổi tự nhiên trong phân phối thống kê của lưu lượng mạng khiến cho mô hình đã huấn luyện trở nên lỗi thời.

Mặc dù đã có nhiều nỗ lực nghiên cứu, đa phần các công trình hiện tại chỉ giải quyết riêng lẻ từng vấn đề. Chẳng hạn, các nghiên cứu nổi bật như Apollon (2024) [28] hay Adapting Under Fire (2025) [33] dù có những đóng góp quan trọng trong môi trường đối kháng hoặc thích ứng, nhưng vẫn còn tồn tại những hạn chế như xem nhẹ sự tương tác qua lại giữa tấn công đối kháng và trôi dạt khái niệm, hoặc sử dụng cơ chế thích ứng thiếu tính chủ động. Ngược lại, một số phương pháp khác tập trung vào trôi dạt khái niệm nhưng lại bỏ qua các cuộc tấn công đối kháng có chủ đích. Các hạn chế phổ biến bao gồm việc đánh giá trên một bộ dữ liệu duy nhất, thiếu cơ chế thích ứng nhanh với số lượng mẫu ít, và chưa khai thác được tính năng động trong cả tấn công và phòng thủ.

Để khắc phục những hạn chế này, đề tài này đề xuất một kiến trúc phòng thủ thích ứng mới, tích hợp chiến lược Phòng thủ Mục tiêu Di động (Moving Target Defense - MTD) với Học tăng cường đa tác nhân (Multi-Agent Reinforcement Learning - MARL) [16]. Hệ thống mô hình hóa bài toán dưới dạng một 'cuộc đua vũ trang' giữa hai thực thể: một Tác nhân Phòng thủ (Defender) học chiến lược tối ưu để thay đổi cấu hình mô hình, và một Tác nhân Tấn công (Attacker) liên tục tìm kiếm các điểm yếu để khai thác. Đặc biệt, với cơ chế nhận thức drift thông qua vector nhúng chuyên biệt, hệ thống không chỉ nâng cao độ bền vững mà còn đảm bảo khả năng thích ứng thời gian thực trong môi trường mạng thực tế, nơi các mối đe dọa liên tục tiến hóa.

1.2. Các hướng tiếp cận phát hiện xâm nhập hiện nay

1.2.1. IDS truyền thống dựa trên chữ ký và bất thường

Hai nhóm kỹ thuật phổ biến trong hệ thống IDS truyền thống là dựa trên chữ ký (signature-based) và dựa trên bất thường (anomaly-based):

- Với phương pháp dựa trên chữ ký, hệ thống so khớp lưu lượng mạng thời gian thực với một cơ sở tri thức các mẫu tấn công đã biết. Ưu điểm là độ chính xác cao đối với các tấn công đã được cập nhật vào cơ sở dữ liệu, tỉ lệ báo động sai thấp và dễ diễn giải. Tuy nhiên, hệ thống này bộc lộ hạn chế lớn trước tính chất động và đa hình của mã độc hiện đại. Kẻ tấn công chỉ cần thay đổi nhỏ trong cấu trúc gói tin là có thể vô hiệu hóa chữ ký tĩnh. Ngoài ra, phương pháp này hoàn toàn bị động và bất lực trước các tấn công mới (zero-day).

- Với phương pháp dựa trên bất thường, hệ thống xây dựng một hồ sơ hành vi (behavior profile) của lưu lượng mạng hợp lệ và đưa ra cảnh báo khi phát hiện các sai lệch thống kê đáng kể. Cách này có tiềm năng phát hiện tấn công mới, nhưng thường gặp vấn đề về tỉ lệ cảnh báo sai do khó xác định

ngưỡng tối ưu. Quan trọng hơn, các hệ thống này thường hoạt động như một mục tiêu tĩnh, cho phép kẻ tấn công kiên trì thăm dò và tìm ra ngưỡng phát hiện để thiết kế các mẫu tấn công né tránh.

Trong cả hai trường hợp, các hệ thống này hoạt động dựa trên giả định môi trường là tĩnh và độc lập. Chúng thiếu cơ chế thích ứng tự động với trôi dạt dữ liệu, chủ yếu dựa vào việc tái huấn luyện thủ công hoặc cập nhật chữ ký định kỳ.

1.2.2. Học máy và học sâu trong phát hiện xâm nhập

Những năm gần đây, sự dịch chuyển mạnh mẽ từ các phương pháp dựa trên chữ ký sang Học máy (Machine Learning - ML) và Học sâu (Deep Learning - DL) đã tạo ra bước tiến lớn trong khả năng phát hiện các mối đe dọa mới và chưa từng được biết đến.

Các thuật toán ML truyền thống như Random Forest, SVM, MLP cùng các kiến trúc học sâu tiên tiến như CNN, LSTM và TCN đã được áp dụng rộng rãi và chứng minh hiệu quả trên các bộ dữ liệu chuẩn như NSL-KDD [39] hay CIC-IDS2017 [36]. Ưu điểm vượt trội của các mô hình học sâu là khả năng học biểu diễn (representation learning), cho phép tự động trích xuất đặc trưng từ dữ liệu thô, giảm sự phụ thuộc vào kỹ thuật thiết kế đặc trưng thủ công. Cụ thể, mỗi kiến trúc mang lại những lợi thế riêng biệt trong việc xử lý lưu lượng mạng: các mạng CNN có khả năng khai thác tính cục bộ không gian của dữ liệu, trong khi các mạng TCN (Mạng tích chập thời gian) và Bi-LSTM tỏ ra hiệu quả vượt trội trong việc nắm bắt các phụ thuộc thời gian phức tạp và ngữ cảnh của chuỗi gói tin.

Tuy nhiên, mặc dù đạt độ chính xác cao, việc áp dụng ML/DL vào hệ thống phát hiện xâm nhập (NIDS) cũng nảy sinh những lỗ hổng nghiêm trọng mới:

- Giả định dữ liệu tĩnh và độc lập: Phần lớn các nghiên cứu hiện tại giả định phân phối dữ liệu huấn luyện và kiểm thử là giống nhau. Khi triển khai

trong môi trường mạng thực tế luôn biến động, sự thay đổi thống kê của lưu lượng khiến kiến thức của mô hình nhanh chóng trở nên lỗi thời và suy giảm hiệu suất.

- Dễ bị tổn thương trước nhiễu loạn đối kháng: Các mô hình học sâu, dù có độ chính xác cao, vẫn rất nhạy cảm với các biến đổi nhỏ ở đầu vào. Kẻ tấn công có thể chèn các nhiễu loạn đối kháng [13, 23], khó nhận biết bằng các phương pháp thông thường vào lưu lượng mạng để đánh lừa mô hình phân loại sai, ngay cả khi đó là những mô hình có độ chính xác rất cao.

- Mục tiêu phòng thủ tĩnh: Việc duy trì một mô hình đơn lẻ hoặc một tập hợp cố định khiến hệ thống trở thành một "mục tiêu tĩnh". Kẻ tấn công có thể thực hiện các kỹ thuật tấn công hộp đen hoặc tấn công thay thế để thăm dò biên quyết định của mô hình, từ đó xây dựng chiến lược trốn tránh hiệu quả.

Những hạn chế này cho thấy các mô hình ML/DL tĩnh, dù mạnh mẽ, vẫn chưa đủ để đảm bảo an ninh trong môi trường đối kháng và biến động. Điều này đặt ra yêu cầu cấp thiết về một cơ chế phòng thủ mang tính thích ứng và động hơn.

1.2.3. Học tăng cường và Moving Target Defense cho IDS

Học tăng cường (Reinforcement Learning - RL) cung cấp một khung toán học mạnh mẽ cho bài toán ra quyết định tuần tự (sequential decision-making), phù hợp với môi trường an ninh mạng. RL cho phép tác tử học chuỗi hành động tối ưu thông qua tương tác liên tục với môi trường bất định, nhận thưởng/phạt và học dần một chính sách tối ưu. Khi áp dụng cho IDS, RL vượt trội hơn các phương pháp tĩnh ở khả năng tự động hóa phản ứng và xây dựng chiến lược thích ứng dựa trên trạng thái thời gian thực của mạng.

Trong bối cảnh này, RL đóng vai trò là "bộ não" điều khiển chiến lược Phòng thủ Di chuyển Mục tiêu (Moving Target Defense - MTD). MTD là cơ chế phòng

thủ chủ động nhằm phá vỡ lợi thế của kẻ tấn công bằng cách liên tục thay đổi bề mặt tấn công (attack surface)[1]. Thay vì duy trì một mô hình phòng thủ tĩnh dễ bị kẻ tấn công thực hiện kỹ thuật thăm dò (probing) và tấn công thay thế (surrogate attacks), hệ thống MTD duy trì một tập các mô hình đa dạng về kiến trúc như MLP, CNN, TCN, BiLSTM,... và các cơ chế tổng hợp linh hoạt như Voting, Averaging,...

Tại mỗi bước thời gian, dựa trên trạng thái quan sát được (bao gồm cả tín hiệu drift), tác tử RL sẽ quyết định cấu hình tối ưu để kích hoạt. Cơ chế này khiến kẻ tấn công khó xây dựng một kịch bản tấn công ổn định, bởi bề mặt phòng thủ liên tục thay đổi không phải theo quy luật ngẫu nhiên mà theo chiến lược học được từ tương tác đối kháng. Việc kết hợp Học tăng cường đa tác nhân (Multi-Agent RL)[16] với MTD không chỉ giúp hệ thống đa dạng hóa chiến lược để chống lại các nỗ lực thiết kế ngược (reverse engineering), mà còn đảm bảo duy trì độ chính xác cao ngay cả khi phân phối dữ liệu mạng có sự thay đổi.

1.2.4. Drift dữ liệu trong hệ thống phát hiện xâm nhập

Trong môi trường mạng thực tế, sự trôi dạt dữ liệu (Data Drift) là thách thức nghiêm trọng khiến các đặc tính thống kê của lưu lượng mạng thay đổi theo thời gian. Hiện tượng này có thể được phân loại thành ba loại chính:

- Covariate drift: Phân phối đặc trưng đầu vào thay đổi do sự thay đổi trong hành vi người dùng hoặc dịch vụ mới.
- Prior drift: Tỉ lệ giữa lớp tấn công và lớp bình thường thay đổi theo thời gian.
- Concept drift [11]: Quan hệ giữa đặc trưng và nhãn thay đổi, thường do các phương thức tấn công mới xuất hiện.

Đặc biệt, sự hội tụ giữa kẻ tấn công thông minh và môi trường biến động tạo ra "Trôi dạt đối kháng" (Adversarial Drift). Tại đây, kẻ thù chủ động thao túng

mẫu lưu lượng để vừa trốn tránh phát hiện, vừa gây ra trôi dạt khái niệm. Nếu hệ thống NIDS không được thiết kế để thích ứng, hiệu suất sẽ suy giảm nhanh chóng do kiến thức đã học trở nên lỗi thời. Các kỹ thuật phát hiện drift truyền thống như Sliding Window, DDM hay ADWIN tuy có thể phát hiện thay đổi nhưng thường hoạt động tách biệt và thụ động—chỉ kích hoạt tái huấn luyện khi hiệu suất đã giảm sâu. Hơn nữa, chúng thường bỏ qua nguy cơ trôi dạt đối kháng và đầu độc dữ liệu, nơi kẻ tấn công tiêm nhiễu từ từ để đánh lừa cơ chế cập nhật mô hình.

Để khắc phục hạn chế này, đề tài tiếp cận bài toán theo hướng tích hợp sâu các cơ chế chủ động:

- Định lượng drift đa chiều: Sử dụng mô-đun SOTADriftEmbedding để biểu diễn trạng thái drift dưới dạng vector 20 chiều (bao gồm KS, PSI, MMD và tín hiệu poisoning) thay vì chỉ một chỉ số đơn lẻ.
- Mô phỏng chủ động: Sử dụng ADI Scheduler để tiêm các kịch bản drift tổng hợp và đối kháng trong quá trình huấn luyện, giúp tăng tính bền vững.
- Thích ứng bằng RL: Thông tin drift được đưa trực tiếp vào không gian trạng thái (State Space), cho phép tác tử RL chủ động điều chỉnh chiến lược chọn mô hình ngay khi chớm phát hiện thay đổi, thay vì chờ đợi quá trình tái huấn luyện tốn kém.

1.3. Tính cấp thiết và tính ứng dụng của đề tài

Về mặt khoa học: Hiện tượng trôi dạt dữ liệu (bao gồm cả trôi dạt tự nhiên và đối kháng) đang là thách thức nghiêm trọng, khiến các mô hình học máy trong an ninh mạng nhanh chóng bị lỗi thời. Các nghiên cứu gần đây tuy đã đề cập đến vấn đề này nhưng thường xem quá trình thích nghi là tĩnh hoặc bỏ qua nguy cơ bị đầu độc dữ liệu trong quá trình cập nhật. Đề tài này giải quyết tính cấp thiết đó bằng cách chuyển dịch hướng tiếp cận từ "phát hiện xâm nhập

tĩnh" sang "phát hiện xâm nhập thích ứng". Việc kết hợp MARL với MTD tạo ra một cơ chế đồng tiến hóa (co-evolution), nơi hệ thống không chỉ "học" mà còn liên tục "tiến hóa" cùng với chiến thuật của kẻ tấn công.

Về mặt thực tiễn: Trong bối cảnh các hệ thống IDS hiện đại tại các trung tâm dữ liệu hoặc hạ tầng Cloud đòi hỏi khả năng vận hành liên tục 24/7 với sự can thiệp tối thiểu của con người, một kiến trúc có khả năng tự thích nghi mang lại ba lợi ích cốt lõi:

1. **Tối ưu hóa chi phí vận hành:** Giảm thiểu sự phụ thuộc vào các chuyên gia bảo mật và quy trình tái huấn luyện thủ công vốn tốn kém, chậm chạp nhờ cơ chế học trực tuyến (online learning) tự động.

2. **Đảm bảo tính liên tục của dịch vụ:** Duy trì hiệu suất phát hiện ổn định ngay cả khi lưu lượng mạng thay đổi đột ngột hoặc từ từ, tránh tình trạng "mù" tạm thời trong lúc chờ cập nhật mô hình.

3. **Tăng cường độ tin cậy:** Khả năng chống đầu độc giúp hệ thống không bị kẻ tấn công thao túng trong quá trình tự học, khắc phục điểm yếu chí mạng của các hệ thống AI tự hành hiện nay.

Do đó, đề tài có tiềm năng ứng dụng cao vào các hệ thống giám sát an ninh mạng thực tế, đặc biệt là trong bối cảnh chuyển đổi số mạnh mẽ, nơi các mô hình tấn công Zero-day và APT diễn biến phức tạp.

1.4. Những thách thức

1.4.1. Môi trường tấn công – phòng thủ động và tương tác

Việc xây dựng mô hình đồng tiến hóa (co-evolution) giữa Defender và Attacker đặt ra ba thách thức lớn về tính hội tụ và thiết kế hệ thống:

- Tính chất môi trường không dừng (Non-stationarity): Khác với môi trường tĩnh, tác tử Attacker chủ động tạo mẫu đối kháng (FGSM, PGD...) thay vì

chỉ phát lại các dữ liệu cũ. Điều này biến môi trường thành một hệ thống động, nơi phân phối dữ liệu thay đổi liên tục theo chiến lược của đối phương, gây khó khăn cho việc ổn định quá trình học.

- Sự đánh đổi trong không gian hành động: Cần sự cân bằng tinh tế khi thiết kế kho mô hình (Model Pool). Tác tử phải lựa chọn tối ưu trong một Model Pool đa dạng (MLP, CNN, TCN, BiLSTM) và các chiến lược kết hợp. Nếu không gian này quá lớn, tác tử sẽ mất nhiều thời gian để khám phá; ngược lại nếu quá nhỏ, chiến lược MTD sẽ mất đi tính bất định cần thiết để đánh lừa kẻ tấn công.

- Thiết kế hàm thưởng (Reward Shaping): Trong môi trường đối kháng, việc thiết kế hàm thưởng thô sơ có thể dẫn đến hiện tượng "Hack phần thưởng" (Reward hacking[2]). Nếu các trọng số này không được tinh chỉnh kỹ lưỡng, tác tử dễ rơi vào trạng thái Reward hacking[2] hoặc tiêu tốn tài nguyên quá mức cần thiết.

1.4.2. Độ phức tạp của trôi dạt dữ liệu trong IDS

Drift trong lưu lượng mạng không đơn thuần là sự dịch chuyển tuyến tính của các giá trị trung bình hay phương sai, mà là sự thay đổi phức tạp trong không gian đặc trưng đa chiều, bao gồm:

- Sự thay đổi quan hệ phụ thuộc: Khi ngữ nghĩa của hành vi mạng bị đảo ngược (lành tính/tấn công), thường do xuất hiện các biến thể tấn công mới (Zero-day) hoặc kỹ thuật lẩn tránh tinh vi khiến luật cũ vô hiệu.

- Sự biến động cấu trúc: Do sự thay đổi phân phối đầu vào khi xuất hiện giao thức, ứng dụng mới hoặc thay đổi thói quen người dùng, làm sai lệch biên quyết định của mô hình.

- Drift đối kháng và đầu độc dữ liệu: Đây là thách thức lớn nhất, khi kẻ tấn công chủ động tạo mẫu nhiễu để thao túng quá trình thích nghi, khiến hệ

thống học sai lệch mà không hay biết.

Thách thức đặt ra là làm sao xây dựng được một biểu diễn drift giàu thông tin để phân biệt rạch ròi giữa các loại drift trên, nhưng vẫn đảm bảo hiệu năng tính toán. Để giải quyết vấn đề này, đề tài đề xuất sử dụng SOTADriftEmbedding – một vector đặc trưng 20 chiều, nó tổng hợp từ các độ đo thống kê phức tạp (như KS Test[24], PSI[42], MMD[14]) và tín hiệu bất thường – đòi hỏi sự tối ưu hóa cao độ để có thể tích hợp vào luồng xử lý thời gian thực mà không gây trễ cho toàn bộ hệ thống IDS.

1.4.3. Tài nguyên tính toán và chi phí huấn luyện

Việc huấn luyện đồng tiến hóa hai tác tử RL trên tập dữ liệu lớn (CIC-IDS2017 [36]), kết hợp phát hiện concept drift [11] và duy trì Model Pool phức tạp đặt ra thách thức lớn về chi phí tính toán và thời gian hội tụ. Đề tài giải quyết vấn đề này thông qua ba giải pháp trọng tâm:

- Tối ưu hóa không gian trạng thái: Cần thiết kế vector trạng thái cô đọng nhưng giàu thông tin, loại bỏ các đặc trưng nhiễu để giảm chiều dữ liệu mà không làm mất đi bản chất của trạng thái mạng.
- Tăng tốc độ hội tụ: Sử dụng các kỹ thuật như PER[34] để tập trung học các mẫu "khó" giúp tác tử tìm ra chính sách tối ưu nhanh hơn so với RL truyền thống.
- Chiến lược huấn luyện phân tầng: Sử dụng Transfer Learning (tận dụng các mô hình trong Model Pool đã huấn luyện trước) để giảm khối lượng học lại từ đầu, kết hợp các kỹ thuật tăng tốc phần cứng (XLA Compilation, TPU/GPU) để tăng tốc quá trình tính toán ma trận song song.

1.4.4. Đánh giá tính bền vững và khả năng phục hồi dưới drift

Các chỉ số tĩnh truyền thống (Accuracy, F1-score) không đủ để phản ánh khả năng thích ứng trong môi trường học liên tục. Đề tài áp dụng phương pháp Prequential Evaluation (đánh giá theo dòng dữ liệu) thay vì Cross-Validation, tập trung vào các thước đo động và kịch bản thử nghiệm chuyên sâu:

- Chỉ số ổn định: Đánh giá sự cân bằng giữa việc cập nhật mô hình theo drift mới và việc giữ vững kết quả phát hiện trên các kịch bản cũ, tránh hiện tượng "lãng quên thảm khốc"[20].
- Thời gian phục hồi: Số bước thời gian cần thiết để hiệu suất hệ thống quay trở lại mức chấp nhận được (ví dụ: 9/10 so với baseline) sau khi sự kiện drift xảy ra.
- Độ hiệu chuẩn: Đánh giá mức độ tin cậy của xác suất dự đoán, đảm bảo tính chắc chắn trong các quyết định an ninh tự động.

Ngoài ra, việc thiết kế các kịch bản đánh giá không chỉ dừng lại ở drift tự nhiên mà còn phải bao gồm các kịch bản Drift nhân tạo được kiểm soát bởi ADI Scheduler (như Sudden, Gradual, Recurring), giúp kiểm chứng khả năng chịu đựng của hệ thống trước các biến động cực đoan.

1.5. Mục tiêu, đối tượng và phạm vi nghiên cứu

1.5.1. Mục tiêu nghiên cứu

Đề tài giải quyết bài toán thích ứng của hệ thống IDS trong môi trường mạng biến động thông qua 4 mục tiêu chính:

- Đề xuất một kiến trúc: Xây dựng khung IDS thích ứng tích hợp Học tăng cường (RL), Moving Target Defense (MTD) cùng các cơ chế xử lý drift (SOTADriftEmbedding, ADI Scheduler).

- Phát triển mô-đun: Thiết kế SOTADriftEmbedding để biểu diễn drift dưới dạng vector và ADI Scheduler để tạo sinh kịch bản drift có kiểm soát.
- Triển khai môi trường: Xây dựng môi trường CoEvolutionGameEnv trên bộ dữ liệu CIC-IDS2017 [36], mô phỏng tương tác đối kháng giữa tấn công và phòng thủ.
- Đánh giá hiệu năng: Kiểm chứng tính bền vững và hiệu suất phát hiện của hệ thống dưới các kịch bản drift đa dạng, so sánh với các baseline phổ biến.

1.5.2. Đối tượng nghiên cứu

Đối tượng nghiên cứu:

- NIDS dựa trên ML/DL.
- Học tăng cường trong môi trường đối kháng: Ứng dụng thuật toán Dueling Double DQN để tối ưu hóa quyết định và lựa chọn mô hình trong môi trường phi dừng.
- Hiện tượng trôi dạt dữ liệu trong an ninh mạng: Các dạng biến đổi phân phối dữ liệu và tác động của kỹ thuật tấn công làm sai lệch phân phối lưu lượng.

1.5.3. Phạm vi nghiên cứu

- Dữ liệu thực nghiệm: Sử dụng bộ dữ liệu chuẩn CIC-IDS2017 [36] làm nòng cốt, còn bộ dữ liệu phụ là CIC-APT-IIOT-2024[12, 6]. Dữ liệu được chia theo kịch bản Temporal Drift (huấn luyện trên dữ liệu đầu tuần, đánh giá khả năng thích ứng trên dữ liệu cuối tuần với các tấn công mới).
- Mô phỏng Drift: Giới hạn ở việc mô phỏng các kịch bản drift nhân tạo (Sudden, Gradual, Recurring) thông qua ADI Scheduler để kiểm chứng lý thuyết, chưa thử nghiệm trên môi trường mạng vật lý quy mô lớn.

- Giới hạn triển khai: Đề tài tập trung vào tối ưu hóa thuật toán và kiến trúc mô hình học máy, chưa đi sâu vào việc tối ưu hóa phần cứng chuyên dụng hoặc triển khai hệ thống phân tán thời gian thực.

1.6. Cấu trúc khóa luận tốt nghiệp

Nhóm xin trình bày nội dung của đề tài theo cấu trúc như sau:

Khóa luận được chia thành 5 chương:

- Chương 1: Giới thiệu tổng quan đề tài
- Chương 2: Trình bày cơ sở lý thuyết và kiến thức nền tảng liên quan đến đề tài.
- Chương 3: Mô hình học tăng cường cho IDS dựa trên Moving Target Defense, Mô-Đun phát hiện Drift và đánh giá dưới Drift.
- Chương 4: Hiện thực, thực nghiệm và đánh giá.
- Chương 5: Kết luận và hướng phát triển.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT

2.1. Hệ thống phát hiện xâm nhập, tập dữ liệu CIC-IDS2017 và CIC-APT-IIOT-2024

2.1.1. Khái niệm IDS và phân loại

Hệ thống phát hiện xâm nhập (IDS) là thành phần an ninh chủ động dùng để giám sát lưu lượng mạng hoặc hoạt động hệ thống nhằm phát hiện các hành vi bất thường và vi phạm chính sách bảo mật. Về mặt kỹ thuật, IDS hoạt động như một bộ phân loại: nhận dữ liệu đầu vào (gói tin, flow, log) và đưa ra quyết định gán nhãn cho mỗi mẫu là bình thường (benign) hay tấn công (attack).

Theo vị trí triển khai, IDS được phân loại thành:

- NIDS[3] (Network-based IDS): Giám sát lưu lượng mạng tại các điểm nút mạng chiến lược (router, switch, gateway). Dữ liệu đầu vào thường là các gói tin thô (raw packets) hoặc các thống kê luồng (flow statistics).
- HIDS (Host-based IDS): Giám sát hoạt động nội tại trên từng thiết bị đầu cuối thông qua nhật ký hệ thống (system logs), lời gọi hệ thống (system calls) và kiểm tra tính toàn vẹn của tệp tin.

Theo phương pháp phát hiện, IDS được chia thành ba nhóm chính:

1. Signature-based IDS (Dựa trên chữ ký): So khớp dữ liệu hiện tại với cơ sở dữ liệu các mẫu tấn công đã biết. Phương pháp này có độ chính xác cao và tỷ lệ báo động sai thấp, nhưng không có khả năng phát hiện các tấn công mới (Zero-day) hoặc các biến thể mã độc.
2. Anomaly-based IDS (Dựa trên bất thường): Xây dựng hồ sơ hành vi "bình

thường" của mạng và cảnh báo bất kỳ sai lệch nào vượt quá ngưỡng cho phép. Phương pháp này có khả năng phát hiện tấn công Zero-day nhưng thường gặp vấn đề về tỷ lệ báo động sai (False Positive) cao do tính biến động tự nhiên của dữ liệu mạng.

3. Hybrid IDS: Kết hợp cả hai cơ chế trên để tận dụng ưu điểm của mỗi loại.

Trong phạm vi đề tài: Hệ thống được thiết kế là một NIDS[3] dựa trên bất thường (Anomaly-based) sử dụng kỹ thuật Học sâu (Deep Learning). Cụ thể, hệ thống phân tích các đặc trưng luồng (flow features) từ bộ dữ liệu CIC-IDS2017 [36] thay vì phân tích gói tin thô (raw packet) để đảm bảo hiệu năng xử lý. Đặc biệt, thay vì sử dụng một mô hình đơn lẻ, đề tài đề xuất kiến trúc đa mô hình bao gồm MLP, CNN, TCN và BiLSTM để tăng cường khả năng phát hiện các mẫu tấn công phức tạp.

2.1.2. Đặc điểm tập dữ liệu

2.1.2.1. CIC-IDS2017

CIC-IDS2017 [36], được phát triển bởi Viện An ninh Mạng Canada (CIC), là một trong những bộ dữ liệu chuẩn mực nhất hiện nay cho bài toán NIDS[3]. Khác với các bộ dữ liệu cũ (như KDD99, NSL-KDD), CIC-IDS2017 [36] cung cấp các mẫu lưu lượng (PCAPs) chứa đầy đủ payload và các giao thức phổ biến (HTTP, HTTPS, FTP, SSH) dựa trên hệ thống B-Profile mô phỏng hành vi người dùng thực tế.

Các đặc điểm kỹ thuật chính được sử dụng trong đề tài:

- Quy mô và đặc trưng: Bộ dữ liệu bao gồm khoảng 2.8 triệu mẫu. Mỗi flow được trích xuất và biểu diễn dưới dạng vector 78 chiều (Network flow features) thông qua công cụ CICFlowMeter, bao gồm các thuộc tính thống kê quan trọng như: thời lượng luồng, độ dài gói tin (min, max, mean, std), khoảng thời gian đến (IAT), và các cờ TCP.

- Phân bố theo thời gian: Dữ liệu được thu thập liên tục trong vòng 5 ngày (từ thứ Hai đến thứ Sáu), với mỗi ngày đại diện cho một phân phối dữ liệu khác nhau:
  - Thứ Hai: Chỉ chứa lưu lượng bình thường (Benign), dùng để thiết lập baseline.
  - Thứ Ba - Thứ Sáu: Xuất hiện các kịch bản tấn công đa dạng (Brute Force, DoS/DDoS, Web Attack, Infiltration, Botnet, PortScan) xen lẫn với traffic bình thường.

Vai trò trong nghiên cứu Drift: Trong khuôn khổ đề tài, CIC-IDS2017 [36] không được xáo trộn ngẫu nhiên như các phương pháp học máy truyền thống. Thay vào đó, dữ liệu được chia theo trục thời gian để mô phỏng chân thực hiện tượng trôi dạt dữ liệu tự nhiên:

- Giai đoạn Tham chiếu: Sử dụng dữ liệu Thứ Hai và Thứ Ba để huấn luyện mô hình ban đầu nhằm thiết lập tri thức nền tảng cho Model Pool và chính sách ban đầu cho tác tử RL.
- Giai đoạn Drift và Thích ứng: Sử dụng dữ liệu từ Thứ Tư đến Thứ Sáu— nơi xuất hiện các kiểu tấn công mới (như DoS/DDoS ở Thứ Tư, Web Attack ở Thứ Năm) và thay đổi cấu trúc lưu lượng (Covariate Drift) — để đánh giá khả năng phát hiện drift của mô-đun SOTADriftEmbedding và khả năng phục hồi của tác tử RL.

2.1.2.2. CIC-APT-IIOT-2024

CIC-APT-IIOT-2024[12, 6], được phát triển bởi Viện An ninh Mạng Canada (CIC) phối hợp với các chuyên gia công nghiệp IoT, là một trong những bộ dữ liệu chuẩn mực nhất hiện nay cho bài toán phát hiện xâm nhập hệ thống IoT và APT. Khác với các bộ dữ liệu truyền thống (như CIC-IDS2017 [36], UNSW-NB15), CIC-APT-IIOT-2024[12, 6] tập trung vào lưu lượng IoT đặc thù

và các chiến dịch tấn công phức tạp, đặc biệt là các Advanced Persistent Threats (APT) trong môi trường IoT/công nghiệp.

- Quy mô và đặc trưng: Bộ dữ liệu bao gồm hàng triệu mẫu lưu lượng có độ phức tạp cao. Tương tự như phiên bản tiền nhiệm, mỗi flow được trích xuất và biểu diễn dưới dạng vector đặc trưng (thường là hơn 80 chiều) thông qua công cụ CICFlowMeter, nhưng được bổ sung thêm các đặc trưng ngữ cảnh IoT/IIoT. Các thuộc tính thống kê quan trọng bao gồm: thời lượng luồng, độ dài gói tin, khoảng thời gian đến (IAT), kích thước cửa sổ TCP, và các thông số đặc trưng của giao thức điều khiển

- Phân bố theo quy trình tấn công: Thay vì chỉ phân chia theo ngày, dữ liệu được thiết kế dựa trên mô phỏng chiến dịch tấn công thực tế của nhóm APT29 (Cozy Bear), bao gồm hơn 20 kỹ thuật tấn công khác nhau được chia thành 8 chiến thuật chính theo chuỗi Cyber Kill Chain:

  - Giai đoạn Baseline: Thu thập lưu lượng và hành vi hệ thống ở trạng thái bình thường để thiết lập ngưỡng chuẩn.
  - Giai đoạn Tấn công APT: Các kịch bản tấn công được thực hiện theo trình tự thời gian và độ phức tạp, bao gồm:
    * Reconnaissance (Thăm dò): Quét cổng, dò tìm thiết bị IoT, thu thập thông tin cấu trúc mạng.
    * Weaponization & Delivery: Khai thác lỗ hổng firmware, tấn công Brute Force vào các giao thức quản trị.
    * Exploitation & Action (Tác động): Các tấn công đặc thù IIoT như False Data Injection (Tiêm dữ liệu giả), DoS/DDoS nhắm vào MQTT/CoAP, thay đổi lệnh điều khiển PLC, và Ransomware nhắm vào hạ tầng công nghiệp.

2.1.3. Các kiểu tấn công tiêu biểu

2.1.3.1. CIC-IDS2017

Bộ dữ liệu bao gồm 14 loại tấn công khác nhau, được phân bố không đồng đều theo thời gian, tạo ra các thách thức drift tự nhiên. Các nhóm tấn công chính bao gồm:

- Brute Force (Xuất hiện chủ yếu vào Thứ Ba):
  - Bao gồm FTP-Patator và SSH-Patator.
  - Đặc điểm: Tấn công vào lớp ứng dụng bằng cách thử sai nhiều thông tin đăng nhập. Đặc trưng luồng thường thể hiện qua số lượng lớn các kết nối ngắn, thất bại từ cùng một IP nguồn trong thời gian ngắn.
- DoS / DDoS (Xuất hiện vào Thứ Tư và Thứ Sáu):
  - DoS (Thứ Tư): Bao gồm các công cụ Hulk, GoldenEye, Slowloris, Slowhttptest. Đa phần là các tấn công vào Layer 7 nhắm làm cạn kiệt tài nguyên máy chủ web.
  - DDoS (Thứ Sáu): Tấn công từ chối dịch vụ phân tán sử dụng Botnet (như LOIC), tập trung làm quá tải đường truyền (Volumetric attack).
  - Ý nghĩa Drift: Sự chuyển dịch từ tấn công Brute Force (Thứ Ba) sang Ddos (Thứ Tư) tạo ra sự thay đổi đột ngột trong không gian đặc trưng. Các thuộc tính như Flow Duration (thời lượng luồng), Total Fwd Packets (tổng gói tin gửi) và Flow IAT (khoảng thời gian đến) sẽ biến động lớn, yêu cầu mô hình phải điều chỉnh trọng số nhanh chóng để thích nghi.
- Web Attacks và Infiltration (Xuất hiện vào Thứ Năm):
  - Bao gồm SQL Injection, Cross-Site Scripting (XSS), Brute Force Web và Infiltration (tấn công xâm nhập nội bộ).

  - Đặc điểm: Đây là nhóm tấn công tinh vi nhất. Lưu lượng mang các payload độc hại nhưng được bao bọc trong các giao thức hợp lệ (HTTP/HTTPS), khiến các đặc trưng thống kê trông rất giống với lưu lượng bình thường. Đây là kịch bản khó nhất để phát hiện (Conditional Drift).

- PortScan và Botnet (Xuất hiện vào Thứ Sáu):
  - PortScan: Hoạt động thăm dò nhằm phát hiện các cổng đang mở và dịch vụ đang chạy, thường là bước chuẩn bị cho các cuộc tấn công sâu hơn.
  - Botnet: Lưu lượng điều khiển (C&C traffic) từ các thiết bị bị nhiễm mã độc (ví dụ: Botnet ARES).

2.1.3.2. CIC-APT-IIOT-2024

Bộ dữ liệu bao gồm nhiều loại tấn công khác nhau (10-15 loại), được thiết kế theo các giai đoạn của một chiến dịch APT (Advanced Persistent Threat) nhằm vào hệ thống điều khiển công nghiệp. Sự phân bố các lớp tấn công này tạo ra các thách thức lớn về mất cân bằng dữ liệu và drift. Các nhóm tấn công chính bao gồm:

- Reconnaissance & Discovery (Thăm dò và Khám phá):
  - Bao gồm: OS Fingerprinting, Port Scanning, và Vulnerability Scanning (sử dụng các công cụ như Nmap, Shodan filters).
  - Đặc điểm: Tấn công nhằm vẽ lại bản đồ mạng lưới các thiết bị IIoT/OT (PLC, Cảm biến, Gateway). Đặc trưng luồng thể hiện qua hàng loạt các gói tin TCP/UDP nhỏ gửi đến nhiều đích hoặc nhiều cổng khác nhau để xác định các dịch vụ mở (như cổng 1883 cho MQTT hay 502 cho Modbus).

- DoS / DDoS IIoT (Tấn công từ chối dịch vụ công nghiệp):

  - DoS: Tấn công làm tê liệt một thiết bị cụ thể (như PLC hoặc Edge Gateway) bằng các kỹ thuật như TCP Syn Flood hoặc UDP Flood.
  - DDoS (Distributed): Tấn công phân tán sử dụng giao thức IoT, ví dụ: MQTT Flood hoặc CoAP Reflection.
  - Đặc điểm: Khác với Web DoS, tấn công này nhắm vào việc phá vỡ tính khả dụng ở thời gian thực của dây chuyền sản xuất.

- Protocol-Specific Attacks (Tấn công vào giao thức đặc thù):
  - Bao gồm: False Data Injection (FDI - Tiêm dữ liệu giả), Man-in-the-Middle (MitM) trên giao thức Modbus/DNP3, và MQTT Publish Flood.
  - Đặc điểm: Đây là nhóm tấn công tinh vi nhất trong môi trường IIoT, tương đương với Web Attacks trong môi trường IT. Kẻ tấn công không phá hỏng đường truyền mà thay đổi nội dung lệnh điều khiển (ví dụ: thay đổi giá trị nhiệt độ, lệnh đóng/mở van) nhưng vẫn giữ nguyên cấu trúc gói tin hợp lệ.

- Mirai Botnet & Weaponization:
  - Botnet: Mô phỏng sự lây nhiễm mã độc kiểu Mirai hoặc Gafgyt, biến các thiết bị IoT yếu kém thành "zombie" để tạo mạng lưới C&C (Command & Control).
  - Weaponization: Khai thác lỗ hổng firmware hoặc tấn công Brute Force vào các thông tin đăng nhập mặc định của thiết bị IoT (Admin/Admin).
  - Đặc điểm: Lưu lượng điều khiển C&C thường ẩn dưới dạng các kết nối HTTP/IRC duy trì lâu dài hoặc các gói tin heartbeat bất thường, xen lẫn với lưu lượng đo đạc thông thường.

2.2. Drift dữ liệu trong an ninh mạng

2.2.1. Khái niệm concept drift, covariate drift, prior drift

Trong lĩnh vực học máy, Drift dữ liệu (Data Drift) được định nghĩa là sự thay đổi không lường trước được của các đặc tính thống kê trong dữ liệu đầu vào theo thời gian. Giả sử $X \in \mathcal{X}$ là vector đặc trưng đầu vào và $Y \in \mathcal{Y}$ là nhãn lớp tương ứng. Gọi $P_t(X, Y)$ là phân phối xác suất liên hợp tại thời điểm t. Hiện tượng drift dữ liệu xảy ra khi có sự sai lệch giữa thời điểm huấn luyện t_0 và thời điểm hiện tại t:

$$P_{t_0}(X, Y) \neq P_t(X, Y) \tag{2.1}$$

Dựa trên định lý Bayes, ta có : $P(X, Y) = P(Y|X)P(X) = P(X|Y)P(Y)$. Từ đó phân loại drift thành ba dạng chính thường gặp trong IDS:

1. Covariate Drift (Dịch chuyển biến thiên): Phân phối của dữ liệu đầu vào thay đổi, nhưng biên quyết định $P(Y|X)$ vẫn giữ nguyên.

$$\begin{cases} P_{t_0}(X) \neq P_t(X) \\ P_{t_0}(Y|X) = P_t(Y|X) \end{cases} \tag{2.2}$$

- Ví dụ trong IDS: Sự thay đổi cấu hình mạng, nâng cấp băng thông, sự xuất hiện của các thiết bị IoT mới hoặc sự thay đổi hành vi người dùng làm thay đổi thống kê về độ dài gói tin hoặc kích thước flow, dù hành vi đó vẫn là hợp lệ.

- Tác động: Làm giảm độ tin cậy của mô hình nếu vùng dữ liệu mới nằm ngoài vùng bao phủ của tập huấn luyện.

2. Prior Drift (Dịch chuyển nhãn): Xảy ra khi xác suất tiền nghiệm của các nhãn lớp $P(Y)$ thay đổi, trong khi phân phối có điều kiện $P(X|Y)$ giữ

nguyên.

$$\begin{cases} P_{t_0}(Y) \neq P_t(Y) \\ P_{t_0}(X|Y) = P_t(X|Y) \end{cases} \tag{2.3}$$

- Ví dụ trong IDS: Trong điều kiện bình thường, lưu lượng tấn công chỉ chiếm <1%. Tuy nhiên, khi xảy ra chiến dịch DDoS hoặc Botnet, tỉ lệ lớp tấn công có thể tăng đột biến lên 50-80%.

- Tác động: Gây sai lệch cho các mô hình nhạy cảm với mất cân bằng dữ liệu, dẫn đến thiên kiến (bias) về lớp đa số mới xuất hiện

3. Concept Drift (Trôi dạt khái niệm): Xảy ra khi mối quan hệ cốt lõi giữa đặc trưng đầu vào và nhãn mục tiêu thay đổi. Đây là dạng drift nguy hiểm và thách thức lớn nhất.

$$P_{t_0}(Y|X) \neq P_t(Y|X) \tag{2.4}$$

- Ví dụ trong IDS: Sự xuất hiện của các biến thể tấn công mới (Zero-day attacks) hoặc kỹ thuật lẩn tránh (Adversarial Evasion), nơi kẻ tấn công tinh chỉnh các đặc trưng X để giả mạo thành traffic bình thường nhưng bản chất Y là độc hại.

- Tác động: Làm vô hiệu hóa đường biên quyết định (Decision Boundary) cũ, dẫn đến việc phân loại sai hàng loạt. Hệ thống bắt buộc phải cập nhật hoặc tái huấn luyện để học lại khái niệm mới.

Trong môi trường mạng thực tế, các dạng drift này hiếm khi xuất hiện đơn lẻ mà thường xảy ra đồng thời. Do đó, hệ thống phải có khả năng định lượng và phân biệt chúng để đưa ra chiến lược thích ứng phù hợp—đây chính là nhiệm vụ của module SOTADriftEmbedding - Vector drift 20 chiều (chi tiết tại Chương 3).

2.2.2. Hiện tượng Drift tự nhiên trong lưu lượng mạng

Trong môi trường vận hành thực tế, lưu lượng mạng là một chuỗi thời gian phi dừng, chịu tác động mạnh mẽ từ hành vi người dùng và sự thay đổi hạ tầng ngay cả khi không xảy ra tấn công mạng. Hiện tượng này, thường được gọi là "Drift tự nhiên" , xuất hiện dưới hai hình thái chính:

- Tính chu kỳ và mùa vụ: Phản ánh thói quen sinh hoạt của con người. Ví dụ: Lưu lượng trong giờ hành chính thường cao và tập trung vào các giao thức HTTP/HTTPS, Database, trong khi lưu lượng ban đêm giảm xuống và chủ yếu bao gồm các hoạt động bảo trì (Backup, System Update). Trong CIC-IDS2017 [36], điều này thể hiện rõ qua sự biến động của traffic giữa buổi sáng và buổi chiều trong cùng một ngày.

- Xu hướng dài hạn: Sự thay đổi cấu trúc dần dần do quá trình nâng cấp công nghệ và hạ tầng. Ví dụ: Sự chuyển dịch giao thức từ HTTP sang HTTPS/QUIC, sự gia tăng của lưu lượng video streaming, hoặc thay đổi chính sách định tuyến. Dạng drift này thường diễn ra chậm nhưng tích lũy theo thời gian, làm thay đổi vĩnh viễn phân phối nền.

Tác động đến CIC-IDS2017 [36]: Bộ dữ liệu CIC-IDS2017 [36] được thiết kế để mô phỏng chính xác hiện tượng này. Cụ thể, mặc dù dữ liệu ngày Thứ Hai và dữ liệu nền của ngày Thứ Sáu đều được gán nhãn là Benign (Bình thường), nhưng phân phối thống kê của chúng (về Packet Length, Inter-arrival Time) có sự sai lệch đáng kể.

Hệ quả là, một mô hình IDS tĩnh học trên dữ liệu Thứ Hai có thể báo động sai khi gặp traffic hợp lệ của Thứ Sáu chỉ vì sự thay đổi phân phối nền. Điều này đặt ra yêu cầu cấp thiết cho hệ thống đề xuất: phải phân biệt được đâu là drift tự nhiên (cần thích nghi để giảm tỷ lệ báo động sai) và đâu là drift do tấn công (cần phát hiện và ngăn chặn).

2.2.3. Drift đối kháng và poisoning

Khác với drift tự nhiên mang tính ngẫu nhiên, Drift đối kháng là sự thay đổi phân phối dữ liệu được thiết kế có chủ đích bởi kẻ tấn công nhằm khai thác điểm mù của mô hình học máy. Trong bối cảnh NIDS[3] thích ứng, mối đe dọa này biểu hiện qua hai hình thức chính:

- Tấn công Lẩn tránh (Evasion Attacks): Kẻ tấn công sử dụng các kỹ thuật tạo mẫu đối kháng (như FGSM, PGD, ZOO) để biến đổi đặc trưng của lưu lượng tấn công sao cho giống với lưu lượng bình thường ($P(X_{attack}) \approx P(X_{benign})$), nhằm vượt qua bộ lọc của IDS mà không cần thay đổi bản chất của cuộc tấn công.

- Đầu độc dữ liệu (Data Poisoning): Đây là mối đe dọa nghiêm trọng nhất đối với các hệ thống IDS áp dụng cơ chế học trực tuyến (Online Learning) hoặc RL. Kẻ tấn công "tiêm" dần dần các mẫu dữ liệu nhiễu hoặc sai nhãn vào luồng dữ liệu huấn luyện, khiến mô hình dần dần dịch chuyển biên quyết định (Decision Boundary) theo hướng có lợi cho kẻ tấn công (ví dụ: chấp nhận hành vi độc hại là bình thường).

Do đặc tính tự cập nhật, hệ thống NIDS[3] thích ứng vốn dĩ nhạy cảm với Poisoning. Nếu không có cơ chế kiểm soát, việc "thích nghi" sẽ trở thành "bị thao túng". Chính vì vậy, đề tài tích hợp hai thành phần thiết yếu:

- ADI Scheduler: Đóng vai trò mô phỏng các kịch bản tiêm nhiễm có kiểm soát để huấn luyện sức kháng cự cho mô hình (Adversarial Training).

- SOTADriftEmbedding: Được thiết kế không chỉ để phát hiện drift mà còn giám sát các tín hiệu đầu độc tiềm năng như Biến dị phần thưởng (Reward Anomaly) và Mâu thuẫn dự đoán (Prediction Inconsistency), đảm bảo hệ thống chỉ học các tri thức đúng đắn.

2.3. Học tăng cường (Reinforcement Learning) và DQN

2.3.1. Mô hình hóa bài toán: Từ MDP đến Markov Game

Học tăng cường (RL) mô hình hóa bài toán quyết định tuần tự dưới dạng Markov Decision Process (MDP). Tuy nhiên, trong bối cảnh tác chiến an ninh mạng giữa Tấn công và Phòng thủ, đề tài mở rộng mô hình này thành một Trò chơi Markov (Markov Game).

Mô hình được định nghĩa bởi bộ 5 tham số $\langle \mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma \rangle$, trong đó:

- **Không gian trạng thái ($\mathcal{S}$):** Biểu diễn thông tin môi trường quan sát được tại mỗi bước thời gian t.
- **Không gian hành động ($\mathcal{A}$)**: Được phân tách cho hai tác tử:
  - Tác tử Phòng thủ (Defender - $\mathcal{A}_D$): Lựa chọn cấu hình phòng thủ tối ưu từ không gian rời rạc gồm 12 hành động (kết hợp giữa 4 model và 3 aggregator).
  - Tác tử Tấn công (Attacker - $\mathcal{A}_A$): Lựa chọn chiến lược tấn công từ 12 hành động (kết hợp giữa 3 kiểu nhiễu và 4 mức cường độ ϵ).
- **Hàm chuyển trạng thái ($\mathcal{P}$):** Xác suất hệ thống chuyển từ trạng thái s sang s' khi thực hiện hành động a:

$$\mathcal{P}(s'|s, a_D, a_A) = P(S_{t+1} = s'|S_t = s, A_{t,D} = a_D, A_{t,A} = a_A) \tag{2.5}$$

- **Hàm thưởng ($\mathcal{R}$):** Phản hồi từ môi trường đánh giá chất lượng hành động. Trong cơ chế đồng tiến hóa, hàm thưởng thường có tính đối nghịch (gần với zero-sum): Defender được thưởng khi phát hiện đúng, trong khi Attacker được thưởng khi đánh lừa được Defender.

$$\mathcal{R}(s, a_D, a_A, s') = \mathbb{E}[R_{t+1}|S_t = s, A_D = a_D, A_A = a_A, S_{t+1} = s'] \tag{2.6}$$

- **Hệ số chiết khấu (γ):** $\gamma \in [0, 1)$, xác định tầm quan trọng của các phần thưởng trong tương lai so với hiện tại.

Mục tiêu của tác tử RL là tìm kiếm một chính sách tối ưu $\pi(a|s)$ nhằm tối đa hóa giá trị kỳ vọng của tổng phần thưởng tích lũy:

$$J(\pi) = \mathbb{E}_\pi \left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \right] \tag{2.7}$$

với $\gamma \in (0, 1)$ là hệ số chiết khấu, cân bằng giữa lợi ích tức thời và dài hạn.

2.3.2. Deep Q-Network, Double DQN, Dueling DQN

1. Deep Q-Network (DQN)[25]: DQN mở rộng Q-learning bằng cách sử dụng mạng nơ-ron có tham số θ để xấp xỉ hàm giá trị $Q(s, a; \theta) \approx Q^*(s, a)$, cho phép xử lý vector trạng thái đầu vào nhiều chiều. Mạng DQN được huấn luyện dựa trên phương trình Bellman, trong đó mạng nơ-ron cố gắng cập nhật dự đoán của mình sao cho khớp với tổng của phần thưởng hiện tại và giá trị ước lượng tối đa của trạng thái kế tiếp.

2. Double DQN (DDQN)[17]: DQN cổ điển gặp vấn đề đánh giá quá cao giá trị Q, do sử dụng cùng một bộ tham số mạng để vừa chọn hành động vừa ước lượng giá trị của nó. Double DQN khắc phục bằng cách tách biệt hai vai trò này cho hai mạng riêng biệt:

   - Mạng chính (Online network): Dùng để chọn hành động tốt nhất.
   - Mạng mục tiêu (Target network): Dùng để tính giá trị của hành động đó.

3. Dueling DQN[41]: Thay vì ước lượng trực tiếp một giá trị Q duy nhất, Dueling DQN tách kiến trúc mạng thành hai nhánh riêng biệt:

   - Nhánh Giá trị trạng thái $V(s)$: Đánh giá xem tình huống hiện tại tốt hay xấu.

- Nhánh Lợi thế hành động $A(s, a)$: Đánh giá xem hành động a tốt hơn mức trung bình bao nhiêu.

Áp dụng trong đề tài: Hệ thống sử dụng biến thể kết hợp Dueling Double DQN cho cả hai tác tử Defender và Attacker. Sự kết hợp này mang lại lợi thế kép: Double DQN giúp ổn định quá trình học trong môi trường phi dừng do tác động của đối thủ và drift, trong khi Dueling DQN giúp nhận diện nhanh chóng các trạng thái nguy hiểm bất kể hành động cụ thể là gì.

2.3.3. Replay buffer, Prioritized Experience Replay và chống nhiễm độc

1. Replay Buffer(Bộ nhớ đệm trải nghiệm): Replay Buffer là cơ chế bộ nhớ dùng để lưu trữ các trải nghiệm (s, a, r, s') thu thập được trong quá trình tương tác giữa tác tử và môi trường. Thay vì huấn luyện trực tiếp từ các trải nghiệm mới nhất, mô hình sẽ lấy mẫu ngẫu nhiên các mini-batch từ Replay Buffer. Cơ chế này giúp phá vỡ sự phụ thuộc theo chuỗi thời gian (decorrelation) của dữ liệu mạng, từ đó giúp quá trình tối ưu ổn định và hội tụ tốt hơn.

2. Prioritized Experience Replay (PER)[34]: là một cải tiến của Replay Buffer, trong đó mỗi trải nghiệm được gán một trọng số ưu tiên dựa trên độ lớn của sai số Temporal Difference (TD-error). Các trải nghiệm có sai số TD lớn được xem là các mẫu "khó", chứa nhiều thông tin quan trọng và có xác suất được chọn cao hơn để mô hình tập trung học.

Thách thức và giải pháp: Trong môi trường có Tấn công đầu độc (Poisoning Attack), PER truyền thống có thể bị lợi dụng để ưu tiên các mẫu dữ liệu nhiễu do kẻ tấn công tạo ra. Để khắc phục, hệ thống đề xuất tích hợp cơ chế Drift-aware: trọng số ưu tiên sẽ bị giảm xuống nếu mẫu dữ liệu đó có dấu hiệu bất thường về entropy hoặc bị đánh dấu cảnh báo bởi mô-đun SOTADriftEmbedding. Cơ

chế này đảm bảo hệ thống ưu tiên học các mẫu quan trọng nhưng phải "sạch", giúp tác tử miễn nhiễm trước các nỗ lực đầu độc dữ liệu.

2.4. Moving Target Defense (MTD) cho NIDS

2.4.1. Khái niệm MTD và ứng dụng trong an toàn mạng

Moving Target Defense (MTD)[18, 35] là một chiến lược phòng thủ chủ động nhằm đảo ngược lợi thế bất đối xứng giữa kẻ tấn công và người phòng thủ. Thay vì duy trì một cấu hình tĩnh giúp kẻ tấn công có vô hạn thời gian để thám thính và tìm điểm yếu, MTD liên tục thay đổi bề mặt tấn công (Attack Surface của hệ thống, khiến thông tin mà kẻ tấn công thu thập được nhanh chóng trở nên lỗi thời.

Trong bối cảnh các hệ thống NIDS dựa trên học máy (ML-based IDS), MTD không chỉ tập trung vào việc thay đổi địa chỉ IP hay cổng dịch vụ, mà tập trung vào MTD cấp độ quyết định (Decision-level MTD)[43]:

- Đa dạng hóa mô hình (Model Diversification): Duy trì một kho (pool) các mô hình có kiến trúc khác biệt (MLP, CNN, TCN, BiLSTM) để đảm bảo tính đa dạng về không gian đặc trưng.
- Tổng hợp động (Dynamic Aggregation): Thay đổi linh hoạt cách kết hợp kết quả dự đoán (Mean, Median, Majority Voting) để làm giảm hiệu quả của các mẫu đối kháng được tối ưu cho một hàm mục tiêu cụ thể .
- Ngẫu nhiên hóa đầu vào (Input Randomization): Sử dụng các kỹ thuật như khử nhiễu[31] hoặc thêm nhiễu chủ động để phá vỡ tính toán gradient của kẻ tấn công .

Mục tiêu cốt lõi: Việc áp dụng MTD trong đề tài nhằm giải quyết bài toán chống tấn công đối kháng. Bằng cách liên tục thay đổi cấu hình phòng thủ theo thời gian thực (dưới sự điều khiển của RL), hệ thống ép buộc kẻ tấn công phải

đối mặt với một mục tiêu di động, làm tăng chi phí tấn công và giảm xác suất thành công của các kỹ thuật trốn tránh (Evasion Attacks).

2.4.2. Chiến lược Đa dạng hóa kiến trúc NIDS dựa trên MTD

Đề tài hiện thực hóa chiến lược MTD thông qua một Model Pool được thiết kế dựa trên nguyên lý "Sự đa dạng tạo nên sức mạnh". Thay vì chọn ngẫu nhiên, hệ thống duy trì 4 kiến trúc học sâu với các thiên kiến quy nạp (inductive bias) khác biệt để bổ trợ lẫn nhau:

- MLPDropout: Đóng vai trò là mô hình cơ sở (baseline), xử lý tốt các tương tác đặc trưng đơn giản với chi phí tính toán thấp.
- DeepCNN[21]: Chuyên biệt trong việc phát hiện các mẫu cục bộ và bất biến dịch chuyển trong không gian đặc trưng.
- DeepTCN[4]: Sử dụng tích chập giãn để nắm bắt các phụ thuộc thời gian dài mà không gặp vấn đề về gradient như RNN.
- BiLSTMAttention[40]: Kết hợp LSTM hai chiều và cơ chế Attention để tập trung vào các đặc trưng quan trọng nhất trong chuỗi ngữ cảnh toàn cục.

Cơ chế hoạt động: Tại mỗi bước thời gian t, tác tử Defender sử dụng mạng Q-network để lựa chọn một hành động tối ưu a_t từ không gian hành động rời rạc gồm 12 lựa chọn (kết hợp giữa 4 kiến trúc và 3 phương pháp gộp):

1. Chọn Mô hình (m): Kích hoạt một mô hình cụ thể từ Pool.
2. Chọn Bộ kết hợp (g): Quyết định phương pháp tổng hợp kết quả (Mean Logits để tối ưu độ mượt, Median Logits để chống nhiễu/outliers, hoặc Majority Vote để đảm bảo sự đồng thuận).

Hiệu quả phòng thủ: Chiến lược này tạo ra một bề mặt phòng thủ biến thiên liên tục. Kẻ tấn công sử dụng các kỹ thuật thám thính hộp đen (như ZOO hoặc

HSJA)[9, 8] sẽ gặp khó khăn vì gradient hoặc biên quyết định mà chúng ước lượng được ở bước t sẽ trở nên lỗi thời hoặc không chính xác ở bước $t+1$, từ đó làm giảm đáng kể tỉ lệ tấn công thành công.

2.5. Các kỹ thuật phát hiện Drift truyền thống

Các kỹ thuật phát hiện drift truyền thống thường tiếp cận bài toán theo hướng giám sát hiệu suất thống kê đơn biến. Ba phương pháp tiêu biểu được sử dụng làm baseline so sánh trong đề tài bao gồm:

- DDM (Drift Detection Method)[10]:
  - Cơ chế: DDM hoạt động dựa trên giả định rằng tỷ lệ lỗi phân loại của mô hình tuân theo phân phối nhị thức. Với p_t là tỷ lệ lỗi và s_t là độ lệch chuẩn tại thời điểm t, hệ thống định nghĩa hai ngưỡng cảnh báo:
    * Ngưỡng cảnh báo (Warning Level): $p_t + s_t \geq p_{min} + 2s_{min} \rightarrow$ Hệ thống bắt đầu lưu trữ mẫu mới.
    * Ngưỡng xác nhận (Drift Level): $p_t + s_t \geq p_{min} + 3s_{min} \rightarrow$ Xác nhận có Drift, mô hình được huấn luyện lại.
  - Hạn chế: DDM rất nhạy với sự thay đổi đột ngột nhưng phản ứng chậm với drift diễn ra từ từ
- ADWIN (Adaptive Windowing)[5]:
  - Cơ chế: Duy trì một cửa sổ trượt có kích thước biến thiên động. Thuật toán liên tục cắt cửa sổ W thành hai cửa sổ con W_0 và W_1. Nếu sự khác biệt về giá trị trung bình μ giữa hai cửa sổ này vượt quá giới hạn sai số ϵ (được tính dựa trên định lý Hoeffding Bound), ADWIN kết luận phân phối đã thay đổi và loại bỏ W_0 (dữ liệu cũ).
  - Hạn chế: Thường chỉ theo dõi được một chiều dữ liệu tại một thời điểm (ví dụ: chỉ theo dõi accuracy hoặc 1 feature quan trọng), do đó dễ bỏ

sót các thay đổi cấu trúc phức tạp trong không gian đa chiều của traffic mạng.

- Sliding Window[19]:
  - Cơ chế: So sánh phân phối thống kê giữa một cửa sổ tham chiếu (Reference Window - đại diện cho dữ liệu gốc) và cửa sổ hiện tại (Current Window). Nếu giá trị thống kê $p-value$ nhỏ hơn mức ý nghĩa α (thường là 0.05), giả thuyết không (H_0: hai phân phối giống nhau) bị loại bỏ, đồng nghĩa với việc Drift đã xảy ra.

Tổng kết hạn chế: Điểm yếu chung của nhóm phương pháp này là sự thụ động. Chúng chỉ phát hiện ra vấn đề khi hệ thống đã bắt đầu mắc lỗi (dự đoán sai), thay vì cảnh báo sớm. Ngoài ra, chúng không phân biệt được đâu là thay đổi tự nhiên, đâu là tấn công, và rất dễ bị qua mặt bởi các kỹ thuật đầu độc dữ liệu tinh vi (thay đổi từ từ). Chính vì vậy, đề tài cần một giải pháp chủ động và thông minh hơn như SOTADriftEmbedding (sẽ trình bày chi tiết ở chương 3).

2.6. Tổng kết

Chương 2 đã hệ thống hóa các cơ sở lý thuyết quan trọng và công nghệ nền tảng cho đề tài, bao gồm: Hệ thống phát hiện xâm nhập (NIDS[3]), vấn đề trôi dạt dữ liệu (Data Drift), Học tăng cường (RL) và chiến lược Phòng thủ mục tiêu di động (Moving Target Defense). Bên cạnh đó, các kỹ thuật mô phỏng và phát hiện drift cũng đã được trình bày chi tiết. Việc nắm vững các khái niệm này, cùng với sự hiểu biết về bản chất của drift dữ liệu, là điều kiện tiên quyết để giải quyết bài toán thích nghi trong môi trường mạng thay đổi liên tục. Đây chính là tiền đề để phát triển một framework toàn diện, có khả năng tự chủ và linh hoạt; chi tiết về kiến trúc này sẽ được mô tả trong Chương 3.

CHƯƠNG 3. MÔ HÌNH IDS THÍCH NGHI DỰA TRÊN HỌC TĂNG CƯỜNG VÀ MOVING TARGET DEFENSE

Ở chương này, nhóm sẽ trình bày tổng quan kiến trúc hệ thống đề xuất, tập trung vào việc tích hợp các đặc trưng trôi dạt dữ liệu và chi tiết hóa quy trình hiện thực giải pháp tổng thể.

3.1. Tổng quan kiến trúc mô hình

Khóa luận đề xuất hệ thống MORPH-IDS (Moving Objective Reinforcement Learning Framework for Proactive and Hardened Intrusion Detection Systems) nhằm tự động hóa quá trình lựa chọn chiến lược phát hiện xâm nhập theo thời gian thực. Hệ thống nhận đầu vào là các mẫu lưu lượng mạng đã được trích xuất đặc trưng, và tạo ra đầu ra là nhãn phân loại (Benign hoặc Attack), với hai mục tiêu chính:

- Duy trì độ chính xác phát hiện trong điều kiện phân phối dữ liệu thay đổi theo thời gian.
- Giảm khả năng kẻ tấn công khai thác được cơ chế ra quyết định của hệ thống.

Kiến trúc tổng thể của MORPH-IDS được đề xuất là một khung giải pháp toàn diện, tích hợp chặt chẽ giữa chiến lược Phòng thủ mục tiêu di động (MTD)[1, 18] và cơ chế Học tăng cường đa tác nhân (MARL)[16], với trọng tâm là khả năng nhận thức và thích ứng với trôi dạt dữ liệu (Data Drift)[11]. Ý tưởng là mô hình hóa sự tương tác giữa NIDS và kẻ tấn công như một trò chơi đồng tiến hóa

(co-evolutionary game) có tổng bằng không: Khi bên tấn công cải thiện chiến lược gây nhiễu, bên phòng thủ phải điều chỉnh chính sách lựa chọn mô hình và cấu hình phòng thủ tương ứng. Cấu trúc chi tiết của mô hình được minh họa trong Hình 3.1. Để làm rõ luồng xử lý, MORPH-IDS được tổ chức thành hai pha vận hành chính:

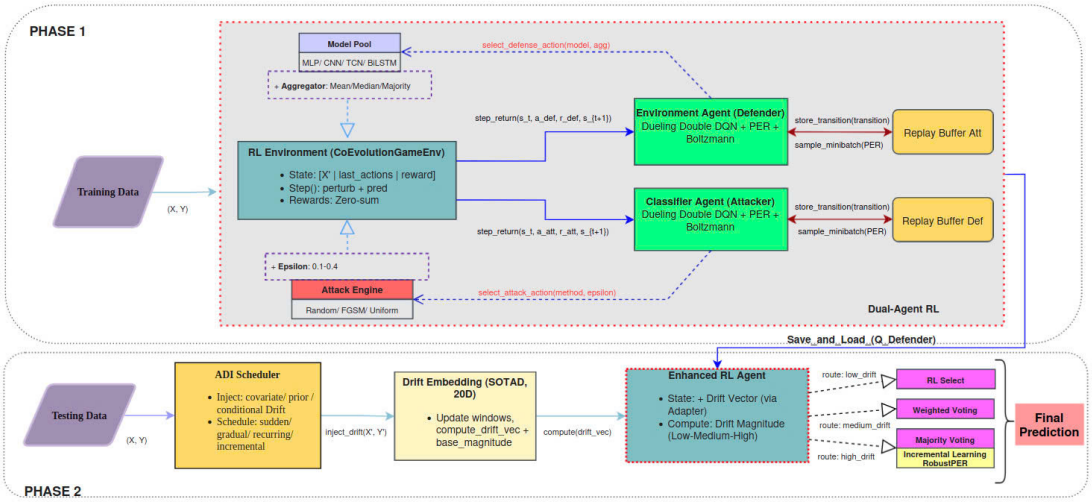

Hình 3.1: *Mô hình tổng quan kiến trúc của MORPH-IDS*

- **Pha 1 - Huấn luyện đồng tiến hóa:** Hệ thống sử dụng tập dữ liệu huấn luyện và môi trường mô phỏng để cho hai tác nhân tương tác lặp lại với nhau. Tác nhân tấn công liên tục sinh ra các mẫu gây nhiễu mới, trong khi tác nhân phòng thủ học chính sách lựa chọn mô hình và cấu hình phòng thủ tương ứng. Kết quả của pha 1 là một tập các chính sách phòng thủ đã được huấn luyện và các tham số cấu hình ban đầu cho giai đoạn triển khai thực tế.

- **Pha 2 - Triển khai và thích nghi:** Hệ thống được triển khai trên lưu lượng mạng thực tế. Các chính sách học được từ pha 1 được sử dụng để lựa chọn mô hình và chiến lược phòng thủ theo thời gian thực. Đồng thời, các mô-đun giám sát trôi dạt dữ liệu, phát hiện dấu hiệu đầu độc và cơ chế cập nhật dần được kích hoạt để điều chỉnh chính sách khi phân phối dữ

liệu thay đổi, hạn chế hiện tượng lãng quên thảm khốc và duy trì hiệu năng phát hiện.

Trong cả hai pha, kiến trúc MORPH-IDS đều xoay quanh hai tác nhân chính:

- **Tác nhân Phòng thủ (Defender Agent)**: Tác nhân phòng thủ đại diện cho hệ thống NIDS. Mục tiêu của tác nhân này là phân loại chính xác lưu lượng mạng. Không gian hành động của nó bao gồm việc lựa chọn một mô hình ML cụ thể và một chiến lược tổng hợp từ một tập hợp đa dạng. Bằng cách học một chính sách tối ưu, tác nhân phòng thủ học một chính sách ra quyết định động, thay đổi cấu hình phòng thủ theo thời gian để tối đa hóa độ chính xác phát hiện và giảm thiểu khả năng lẩn tránh của đối phương.
- **Tác nhân Tấn công (Attacker Agent)**: Tác nhân này mô hình hóa hành vi xâm nhập của kẻ tấn công. Mục tiêu của nó là tạo ra các nhiễu loạn đối kháng (adversarial perturbations) lên các mẫu lưu lượng khiến mô hình được chọn bởi bên phòng thủ phân loại sai lưu lượng độc hại. Không gian hành động của nó bao gồm nhiều loại tấn công và mức độ khác nhau.

Quy trình huấn luyện đồng tiến hóa giữa hai tác nhân trong pha 1 và cơ chế thích nghi trong pha 2 tạo thành một vòng lặp thích nghi liên tục: tác nhân tấn công điều chỉnh chiến lược sinh nhiễu dựa trên phản ứng của hệ thống, trong khi tác nhân phòng thủ cập nhật chính sách lựa chọn mô hình và cấu hình phòng thủ dựa trên các hình thái tấn công mới và sự thay đổi của dữ liệu. Các mô-đun xử lý trôi dạt khái niệm, hạn chế lãng quên thảm khốc và giảm rủi ro đầu độc dữ liệu sẽ được trình bày chi tiết ở các mục tiếp theo của chương.

3.2. Môi trường Đồng tiến hóa (Co-Evolutionary Environment)

Trong khóa luận này, MORPH-IDS được mô hình hóa như một môi trường đồng tiến hóa gồm hai tác nhân cạnh tranh (Defender và Attacker). Bài toán

được mô hình hóa dưới dạng Markov Game, trong đó tác nhân Defender lựa chọn cấu hình phát hiện xâm nhập, còn tác nhân Attacker lựa chọn chiến lược gây nhiễu đối kháng trên không gian đặc trưng.

3.2.1. Không gian trạng thái

Trong bài toán Học tăng cường, việc thiết kế không gian trạng thái đóng vai trò quyết định đến khả năng hội tụ và hiệu suất của tác tử. Khác với các phương pháp truyền thống chỉ sử dụng đặc trưng của gói tin mạng, không gian trạng thái S trong hệ thống MORH-IDS của nhóm là một vector hỗn hợp đa chiều, cung cấp ngữ cảnh toàn diện về môi trường an ninh mạng tại thời điểm t.

Vector trạng thái S_t được cấu thành từ 4 thành phần chính:

$$S_t = [X'_t \oplus D_t \oplus H_{act} \oplus H_{rew}]$$

Công thức thể hiện rằng trạng thái S_t không chỉ là dữ liệu mạng đơn thuần, mà là sự ghép nối của 4 nguồn thông tin khác nhau.
$\oplus$: Đây là ký hiệu của phép nối vector. Nó có ý nghĩa là gộp tất cả các đặc trưng thành một vector dài duy nhất để đưa vào mạng nơron (Dueling DQN) của Agent.
Trong đó chi tiết từng thành phần như sau:

- Đặc trưng Lưu lượng Mạng ($X'_t \in \mathbb{R}^N$):
  - Là vector đặc trưng của mẫu dữ liệu hiện tại sau khi đã đi qua bộ tiền xử lý. Các đặc trưng này bao gồm thông tin thống kê về luồng như: thời gian tồn tại (Flow Duration), độ dài gói tin (Packet Lengths), thời gian đến giữa các gói tin (Inter-Arrival Time - IAT), và các cờ TCP (FIN, SYN, RST, PSH, ACK...). Vector Có vai trò cung cấp thông tin nội tại về payload và hành vi giao tiếp mạng.
  - N: Số lượng đặc trưng ban đầu (các trường trong bộ dữ liệu CIC-APT-IIoT2024[12], còn ở bộ dữ liệu CIC-IDS2017 [36] được cố định N=78).

- Vector SOTADriftEmbedding ($D_t \in \mathbb{R}^{20}$): Đây là thành phần quan trọng nhất giúp Agent nhận thức được sự thay đổi của môi trường. Vector 20 chiều này được trích xuất từ mô đun SOTADriftEmbedding, bao gồm:
  - Khoảng cách phân phối (4 chiều).
  - Loại Drift (3 chiều).
  - Động lực thời gian (3 chiều).
  - Độ Không Chắc Chắn và Mức Độ Nghiêm Trọng (6 chiều).
  - Chỉ số phát hiện đầu độc (4 chiều).
- Lịch sử Hành động ($H_{act} \in \mathbb{R}^{24}$): Vector biểu diễn chuỗi các hành động $a_{t-k}, \ldots, a_{t-1}$ mà Agent đã thực hiện trong quá khứ gần. Giúp mạng LSTM bên trong Agent nắm bắt được ngữ cảnh quyết định, tránh sự chuyển đổi qua lại liên tục giữa các mô hình.
- Lịch sử Phần thưởng ($H_{rew} \in \mathbb{R}^2$): Ghi lại phản hồi hiệu suất gần nhất của MORPH-IDS. Giúp cung cấp tín hiệu ngắn hạn về hiệu quả của chiến lược hiện tại.

Tổng kích thước không gian trạng thái là $|S| = N + 20 + 24 + 2$. Thiết kế vector trạng thái S_t như trên cho phép tác tử RL không chỉ tối ưu hóa dựa trên đặc điểm của gói tin hiện tại mà còn có khả năng nhận thức ngữ cảnh môi trường và rút kinh nghiệm từ quá khứ, từ đó đưa ra các quyết định phòng thủ chính xác và bền vững hơn.

3.2.2. Không gian hành động

Trong mô hình đồng tiến hóa, cả hai tác nhân đều có không gian hành động riêng biệt để thực hiện chiến lược của mình.

3.2.2.1. Không gian Hành động của Defender (A_{def})

Trong bộ khung MORPH-IDS, tác tử Defender không trực tiếp phân loại gói tin mà đưa ra các quyết định quản trị cấu hình hệ thống. Không gian hành động của Defender A_{def} được định nghĩa là tích Descartes của hai tập hợp rời rạc:

- Tập các mô hình cơ sở (Base Learners) $\mathcal{M}$
- Tập các cơ chế kết hợp (Aggregators) $\mathcal{G}$.

$$A_{def} = \mathcal{M} \times \mathcal{G}$$

Tại mỗi bước thời gian t, hành động $a_t \in \{0, \ldots, 11\}$ được ánh xạ thành một cặp cấu hình (m, g), trong đó m là kiến trúc mạng nơ-ron được kích hoạt và g là phương pháp tổng hợp kết quả dự đoán.

a. Thiết kế Bể mô hình (Model Pool)

Tập $\mathcal{M}$ bao gồm 4 kiến trúc mạng nơ-ron sâu được lựa chọn để đảm bảo tính đa dạng - yếu tố cốt lõi của chiến lược MTD:

1. **MLP:**
   - Đóng vai trò là "Mô hình cơ sở". MLP có khả năng xử lý tốt các cuộc tấn công có đặc trưng thống kê rõ ràng.
   - MLP cung cấp độ ổn định cơ bản. Khi dữ liệu ít nhiễu, MLP thường là lựa chọn tối ưu về mặt chi phí/hiệu năng. Khi kết hợp với các mô hình phức tạp khác, MLP thường đưa ra quyết định ổn định hơn dựa trên thống kê thô.
2. **DeepCNN[21]:**
   - Đóng vai trò là "Bộ trích xuất mẫu cục bộ". Nhiệm vụ là phát hiện các signatures tấn công nằm ẩn trong các nhóm đặc trưng nhỏ thay vì nhìn vào toàn bộ vector cùng lúc.

- CNN giúp tăng khả năng phát hiện các tấn công tinh vi dựa trên sự bất thường của một nhóm chỉ số cụ thể. CNN có thể bù đắp những hạn chế về không gian của MLP. Trong cơ chế bỏ phiếu, CNN cung cấp một góc nhìn khác biệt hoàn toàn về mặt cấu trúc dữ liệu, giúp tăng độ tin cậy của quyết định cuối cùng.

3. **DeepTCN[4]:**

- Đóng vai trò là "Bộ phân tích ngữ cảnh rộng". Nó kết nối các đặc trưng ở xa nhau trong vector đầu vào để tìm ra các mẫu tấn công phức tạp trải rộng trên nhiều khía cạnh của dữ liệu.
- TCN thường được chọn khi cần tốc độ huấn luyện nhanh nhưng vẫn cần khả năng ghi nhớ dài hạn. TCN có thể phát hiện các tấn công APT. TCN hoạt động như cầu nối giữa CNN và BiLSTM. Nó cung cấp sự đa dạng về mặt kiến trúc, giúp Agent có thêm lựa chọn khi gặp các mẫu dữ liệu mà CNN thường thất bại.

4. **BiLSTMAttention (BiLSTM)[40]:**

- Đóng vai trò là "Chuyên gia phân tích sâu". Đây thường là mô hình có độ chính xác cao nhất đối với các mẫu khó, nhưng đổi lại là chi phí tính toán cao nhất.
- RNN thường bị vấn đề quên thông tin. LSTM[37] giải quyết việc này bằng các cổng. BiLSTM mạnh hơn LSTM đơn hướng vì nó nhìn thấy "ngữ cảnh" trọn vẹn của toàn bộ vector đặc trưng trước khi đưa ra quyết định. BiLSTM đóng vai trò quyết định trong các tình huống Drift cao hoặc tấn công Adversarial mạnh. Trong chiến lược bỏ phiếu của Agent, BiLSTM thường là lá phiếu chất lượng cao để phá vỡ thế bế tắc hoặc sửa sai cho các mô hình nhẹ hơn (MLP/CNN) trong các tình huống khó.

Sự kết hợp này kế thừa tư tưởng đa mô hình trong Apollon [28] và ADHS-EL [32], đồng thời được tối ưu hóa riêng cho đặc thù của bộ dữ liệu CIC-IDS2017 [36].

b. Các Chiến lược Kết hợp

Để tổng hợp dự đoán từ các mô hình thành phần trong Model Pool nhằm đưa ra quyết định cuối cùng, MORPH-IDS triển khai các chiến lược kết hợp (Aggregators). Tác nhân Defender có quyền lựa chọn sử dụng một trong các chiến lược này để tối ưu hóa sự cân bằng giữa độ chính xác (accuracy) và độ bền vững tùy thuộc vào trạng thái hiện tại. Các chiến lược kết hợp cụ thể bao gồm:

1. Chiến lược Trung bình (Mean Aggregation):
   - Cơ chế: Giả sử N là số lượng mô hình và $P_i(y|x)$ là xác suất mô hình thứ i dự đoán nhãn y. Xác suất tổng hợp được tính như sau:

$$P_{mean}(y|x) = \frac{1}{N}\sum_{i=1}^{N} P_i(y|x)$$

   - Mục tiêu: Phương pháp này tận dụng được độ tin cậy của toàn bộ các mô hình, giúp làm mịn biên quyết định và giảm phương sai của dự đoán. Nó hoạt động hiệu quả nhất trong điều kiện môi trường ổn định, ít nhiễu.

2. Chiến lược Trung vị (Median Aggregation):
   - Cơ chế: Với mỗi lớp dự đoán, MORPH-IDS sẽ sắp xếp các xác suất từ thấp đến cao và chọn giá trị ở giữa:

$$P_{median}(y|x) = \text{median}\{P_1(y|x), P_2(y|x), \ldots, P_N(y|x)\}$$

   - Mục tiêu: Tăng tính bền vững. Nếu một mô hình bị tấn công đưa ra giá trị xác suất cực đoan, chiến lược Trung bình sẽ bị kéo lệch theo, nhưng chiến lược Trung vị sẽ loại bỏ giá trị cực đoan này. Do đó, đây là lựa chọn ưu tiên khi Agent phát hiện dấu hiệu tấn công mạnh.

3. Chiến lược Bầu chọn Đa số (Majority Voting):

   - Cơ chế: Mỗi mô hình bỏ phiếu cho nhãn dự đoán $\hat{y}_i$. Nhãn cuối cùng được chọn là nhãn nhận được số phiếu bầu cao nhất từ các mô hình thành phần:

$$\hat{y}_{final} = \text{mode}\{\hat{y}_1, \hat{y}_2, \ldots, \hat{y}_N\}$$

   - Mục tiêu: Chiến lược này giúp loại bỏ hoàn toàn nhiễu từ các dự đoán có độ tin cậy thấp. Chỉ khi đa số các mô hình cùng xác nhận một mẫu là tấn công thì hệ thống mới phát cảnh báo, giúp giảm thiểu báo động sai trong môi trường thực tế.

Ý nghĩa chiến lược: Sự khác biệt của hệ thống MORH-IDS của nhóm so với các phương pháp truyền thống nằm ở khả năng lựa chọn Động (Dynamic Selection). Thay vì cố định một cách kết hợp duy nhất (ví dụ: luôn luôn lấy trung bình), Tác nhân Defender sẽ học cách chuyển đổi linh hoạt:

1. Khi trạng thái bình thường: Sử dụng Trung bình (Mean) để đạt độ chính xác cao nhất.

2. Khi phát hiện bất thường hoặc trôi dạt dữ liệu: Tự động chuyển sang Trung vị hoặc Đa số để tăng cường lớp giáp phòng thủ, đảm bảo MORPH-IDS không bị sụp đổ bởi một điểm yếu đơn lẻ.

3.2.2.2. Không gian hành động của Attacker:

Trong mô hình đồng tiến hóa, tác tử Tấn công (Attacker) không thực hiện các hành vi xâm nhập mạng ở tầng giao thức (như quét cổng hay khai thác lỗ hổng phần mềm) mà hoạt động ở tầng đặc trưng dữ liệu. Mục tiêu của Attacker là tìm ra các phương thức biến đổi đặc trưng tối ưu để đánh lừa hệ thống phòng thủ. Không gian hành động của Attacker A_{att} được định nghĩa là tích Descartes của hai tập hợp:

- Phương thức Tấn công (Perturbation Types): $\mathcal{T}$
- Cường độ Nhiễu (Epsilon Levels): $\mathcal{E}$.

$$A_{att} = \mathcal{T} \times \mathcal{E}$$

- Phương thức Tấn công ($\mathcal{T}$): Bao gồm Random Noise (mô phỏng nhiễu đường truyền), Uniform Noise (làm mờ biên quyết định), và Sign Attack (Giả lập FGSM [13]) (tấn công có chủ đích dựa trên gradient để đánh lừa mô hình).
- Cường độ ($\mathcal{E}$): Tập hợp rời rạc các mức $\epsilon \in \{0.0, 0.1, 0.2, 0.3, 0.4\}$. Việc chia nhỏ các mức độ giúp tạo ra một lộ trình học tập từ dễ đến khó cho Tác nhân Phòng thủ.

Thiết kế này mô phỏng sát sườn các kịch bản Adversarial Drift trong thực tế, phù hợp với hướng tiếp cận của GPMT [38] và TEAM [22], buộc Defender phải học cách đề kháng trước các dữ liệu bị thao túng thay vì chỉ học trên dữ liệu sạch.

3.2.3. Hàm thưởng cho Defender và Attacker

Môi trường đồng tiến hóa được thiết kế như một trò chơi cạnh tranh (Competitive Game) gần với tính chất tổng bằng không (Zero-sum). Mục tiêu là tạo ra áp lực liên tục buộc cả hai tác tử phải tối ưu hóa chiến lược: Defender học cách tối đa hóa độ chính xác và sự ổn định, trong khi Attacker học cách khai thác các điểm yếu mới xuất hiện.

a. Hàm thưởng cho Defender: Defender nhận phần thưởng dương khi phân loại đúng và chịu phạt khi mắc lỗi hoặc MORPH-IDS hoạt động thiếu ổn định.

Mục tiêu: Tối ưu hóa F1-score, phạt nặng cả việc bỏ sót tấn công (False Negative) và dương tính giả (False Positive).

$$R_{Def} = R_{base} + R_{confidence} + R_{adjustment}$$

Trong đó:

- R_{base}: Phần thưởng/phạt cơ bản dựa trên tính Đúng/Sai.
- $R_{confidence}$: Điều chỉnh dựa trên mức độ tự tin của mô hình.
- $R_{adjustment}$: Các khoản thưởng/phạt bổ sung tùy thuộc vào loại nhãn (Benign/Attack).

Chi tiết các trường hợp:

- Trường hợp 1: Dự đoán Đúng:
  - Dự đoán Benign đúng:

$$R_{def} = +5.0 + (1.0 \times p_{norm})$$

  - Dự đoán Attack đúng: Có thêm bonus +2.0 cho việc phát hiện đúng tấn công.

$$R_{def} = +5.0 + (1.0 \times p_{norm}) + 2.0 = +7.0 + p_{norm}$$

- Trường hợp 2: Dự đoán Sai: Sử dụng hình phạt cơ bản rất nặng (-20.0) cộng thêm hình phạt bổ sung (-4.0) cho cả hai loại lỗi.
  - Bỏ sót tấn công:

$$R_{def} = -20.0 - (1.0 \times p_{norm}) - 4.0 = -24.0 - p_{norm}$$

  - Báo động giả:

$$R_{def} = -20.0 - (1.0 \times p_{norm}) - 4.0 = -24.0 - p_{norm}$$

Ý nghĩa:

- Việc đặt mức phạt lớn gấp 4 lần mức thưởng buộc Defender phải thay đổi chiến thuật ngay lập tức nếu mắc lỗi, thay vì học từ từ như các phương pháp truyền thống.

- Việc cộng thêm +2.0 cho việc Dự đoán tấn công đúng giúp Defender "hào hứng" hơn trong việc tìm kiếm các mẫu tấn công hiếm gặp, giúp giải quyết vấn đề mất cân bằng dữ liệu.

b. Hàm thưởng cho Attacker: Ngược lại với Defender, Attacker nhận thưởng dựa trên khả năng đánh lừa mô hình.

Mục tiêu: Khuyến khích lừa được mô hình phòng thủ và làm cho mô hình phòng thủ đưa ra dự đoán sai với độ tự tin cao.

$$R_{Att} = R_{outcome} + R_{bonus}$$

Trong đó:

- $R_{outcome}$: Phần thưởng dựa trên kết quả phân loại. Xác định dựa trên sự thành công của tấn công:

$$R_{outcome} = \begin{cases} +5.0 & \text{nếu Defender dự đoán sai (Thành công)} \\ -10.0 & \text{nếu Defender dự đoán đúng (Thất bại)} \end{cases}$$

- R_{bonus}: Phần thưởng bổ sung dựa trên độ tự tin của Defender vào kết quả sai. Nếu Defender tin tưởng tuyệt đối vào dự đoán sai, Attacker nhận thêm thưởng.

$$R_{bonus} = \begin{cases} +1.0 \times p_{norm} & \text{nếu Tấn công Thành công} \\ 0 & \text{nếu Tấn công Thất bại} \end{cases}$$

  Với $p_{norm} \in [0, 1]$ là độ tự tin đã chuẩn hóa của Defender.

Công thức hoàn chỉnh:

$$R_{Att} = \begin{cases} +5.0 + p_{norm} & \text{nếu Thành công (Thưởng tối đa +6.0)} \\ -10.0 & \text{nếu Thất bại} \end{cases}$$

Ý nghĩa:

- Buộc Attacker phải học các mẫu nhiễu thực sự hiệu quả thay vì chỉ thêm nhiễu ngẫu nhiên.
- Việc cộng thêm p_{norm} (tối đa +1.0) định hướng Attacker tìm ra các điểm yếu nơi mô hình phòng thủ không chỉ sai mà còn sai với độ tự tin cao. Đây là kịch bản nguy hiểm nhất trong thực tế (Defender không nghi ngờ gì về quyết định sai lầm của nó).

3.3. Thiết kế và Huấn luyện Tác nhân Phòng thủ

Phần này trình bày chi tiết kiến trúc mạng nơ-ron và thuật toán huấn luyện của Tác nhân Phòng thủ. Đây là thành phần ra quyết định trung tâm, chịu trách nhiệm ánh xạ vector trạng thái ngữ cảnh s_t thành cấu hình phòng thủ tối ưu.

3.3.1. Kiến trúc Mạng Dueling Deep Q-Network

Để xấp xỉ hàm giá trị $Q(s, a)$ trong một không gian trạng thái phức tạp và đa chiều, MORH-IDS đề xuất sử dụng kiến trúc Dueling DQN[41]. Luồng xử lý dữ liệu được thiết kế khép kín từ bước tiền xử lý đầu vào đến bước tổng hợp giá trị đầu ra.

a. Tiền xử lý và Trích xuất Đặc trưng:

Đầu vào là vector trạng thái $s_t \in \mathbb{R}^{D_{\text{in}}}$. Kích thước D_{in} được thiết kế linh hoạt phụ thuộc vào số lượng đặc trưng của tập dữ liệu mục tiêu là CICIDS-2017 và CIC-APT-IIoT-2024. Do sự chênh lệch lớn về miền giá trị giữa các thành phần, dữ liệu cần được chuẩn hóa để đảm bảo mạng hội tụ ổn định:

- Chuẩn hóa: Các đặc trưng lưu lượng mạng (x'_t) được chuẩn hóa Z-score về phân phối chuẩn ($\mu = 0, \sigma = 1$). Các thành phần vector nhúng và lịch sử hành động được giữ nguyên.
- Dữ đầu vào sau khi chuẩn hóa đi qua các lớp kết nối đầy đủ để học biểu

diễn ẩn cấp cao:

$$h = \text{ReLU}\left(W_2 \cdot \text{ReLU}(W_1 \cdot s_t + b_1) + b_2\right) \in \mathbb{R}^H$$

Trong đó:

- $W_1 \in \mathbb{R}^{H \times D_{\text{in}}}$ là ma trận trọng số thích nghi của lớp ẩn thứ nhất. Kích thước của W_1 sẽ tự động điều chỉnh theo D_{in} của tập dữ liệu đang huấn luyện.
- $W_2 \in \mathbb{R}^{H \times H}$ là ma trận trọng số của lớp ẩn thứ hai, giúp tăng cường khả năng trích xuất đặc trưng phi tuyến bất kể đầu vào.

Biểu diễn ẩn h này đóng vai trò là đặc trưng chung, sau đó sẽ được tách ra làm hai luồng riêng biệt (Value stream và Advantage stream) để ước lượng giá trị Q.

b. Phân tách Luồng Dueling: Thay vì ước lượng trực tiếp giá trị Q, mạng tách biểu diễn h thành hai luồng riêng biệt:

- Luồng Giá trị (Value Stream V): Ước lượng giá trị nội tại của trạng thái, độc lập với hành động cụ thể: $V(s_t; \theta_V) = W_V \cdot h + b_V$.
- Luồng Lợi thế (Advantage Stream A): Ước lượng mức lợi thế tương đối của từng hành động so với mức trung bình: $A(s_t, a; \theta_A) = W_A \cdot h + b_A$, tạo ra một vector 12 chiều tương ứng với không gian hành động của chúng.

Giá trị Q cuối cùng cho 12 hành động phòng thủ được tái hợp theo công thức:

$$Q(s_t, a; \theta) = V(s_t; \theta_V) + \left(A(s_t, a; \theta_A) - \frac{1}{|\mathcal{A}|} \sum_{a'} A(s_t, a'; \theta_A) \right)$$

Việc trừ đi trung bình của A đảm bảo tính khả định của phân rã $Q = V + A$, tránh trường hợp V và A cùng dịch chuyển nhưng Q không thay đổi.

Trong mô hình MORPH-IDS, kiến trúc Dueling đặc biệt phù hợp vì:

- Thứ nhất, luồng giá trị $V(s_t)$ nắm bắt được độ khó vốn có của trạng thái mạng hiện tại, điều này độc lập với hành động phòng thủ cụ thể.
- Thứ hai, trong nhiều trạng thái mạng, một số lựa chọn mô hình có thể hoạt động tương đương nhau. Do đó, việc ước lượng chính xác phần lợi thế tương đối $A(s_t, a)$ là chìa khóa để phân biệt giữa các hành động gần tối ưu.

3.3.2. Cơ chế Huấn luyện Ổn định với Double DQN

Điều này rất quan trọng trong bối cảnh đối kháng của MORPH-IDS, nơi các tín hiệu phần thưởng nhiễu từ các xáo trộn của kẻ tấn công có thể dẫn đến các ước lượng giá trị không ổn định. Giá trị mục tiêu Y_t để cập nhật mạng trực tuyến (online network) được tính như sau:

Trong môi trường đối kháng, nhiễu do Attacker tạo ra có thể khiến các giá trị Q biến động mạnh. Để khắc phục hiện tượng sai lệch ước lượng quá mức của Q-learning truyền thống, cơ chế Double DQN[17] được sử dụng trong MORPH-IDS. Quy trình này tách biệt việc lựa chọn hành động và đánh giá hành động bằng hai mạng nơ-ron song song:

- Mạng Trực tuyến (θ_{online}): Được cập nhật liên tục, dùng để chọn hành động tốt nhất.
- Mạng Mục tiêu (θ_{target}): Được cập nhật chậm, dùng để tính giá trị phần thưởng kỳ vọng.

Hàm mục tiêu Y_t được tính toán như sau:

$$Y_t = r_t + \gamma \cdot Q\left(s_{t+1}, \text{argmax}_{a'} Q(s_{t+1}, a'; \theta_{\text{online}}); \theta_{\text{target}}\right)$$

Cập nhật trọng số mạng mục tiêu thực hiện theo cơ chế Soft Update để tránh sốc tham số:

$$\theta_{\text{target}} \leftarrow \tau\theta_{\text{online}} + (1 - \tau)\theta_{\text{target}}$$

3.3.3. Chiến lược chọn hành động bằng khám phá Boltzmann

Một thách thức lớn của hệ thống MTD là cân bằng giữa việc khám phá các cấu hình phòng thủ mới và khai thác cấu hình tốt nhất hiện tại. Thay vì sử dụng ϵ-greedy (chọn ngẫu nhiên mù quáng), MORPH-IDS áp dụng chiến lược Boltzmann Exploration[7].

a. Phân phối Boltzmann trên giá trị Q: Tại trạng thái s_t, xác suất chọn cấu hình phòng thủ a_i tuân theo phân phối Softmax:

$$\pi(a_i|s_t) = \frac{\exp\left(Q(s_t, a_i)/\tau_{\text{temp}}\right)}{\sum_{j=1}^{12} \exp\left(Q(s_t, a_j)/\tau_{\text{temp}}\right)}$$

trong đó τ_{temp} là tham số nhiệt độ kiểm soát sự đánh đổi giữa khám phá và khai thác.

b. Lịch trình Kiểm soát Nhiệt độ: Tham số nhiệt độ τ_{temp} được giảm dần theo số tập huấn luyện t:

$$\tau_{\text{temp}}(t) = \tau_{\max} - (\tau_{\max} - \tau_{\min}) \cdot \min\left(1, \frac{t}{T_{\text{anneal}}}\right)$$

Với $\tau_{\max} = 2.0$ (Khám phá), $\tau_{\min} = 0.1$ (Khai thác) và $T_{\text{anneal}} = 10{,}000$ tập (episodes). Ở giai đoạn đầu, nhiệt độ cao khuyến khích thử nghiệm đa dạng các tổ hợp mô hình tổng hợp. Khi huấn luyện tiến triển, nhiệt độ giảm dần giúp chính sách hội tụ dần về các hành động có Q-value cao, tương ứng với cấu hình phòng thủ hiệu quả hơn.

Chiến lược khám phá Boltzmann phù hợp với MORPH-IDS vì:

- **Thăm dò có định hướng:** Xác suất chọn hành động không tối ưu tỉ lệ với Q-value của chúng, thay vì đồng đều như trong ϵ-greedy. Điều này giúp tác nhân ưu tiên thăm dò các cấu hình có tiềm năng (Q tương đối cao) nhưng chưa chắc chắn, giảm nguy cơ lựa chọn thường xuyên các cấu hình yếu.

- **Tính khó đoán nội tại:** Ngay cả sau khi hội tụ, chính sách Boltzmann vẫn duy trì mức ngẫu nhiên nhất định trong lựa chọn hành động. Tính ngẫu

nhiên có kiểm soát này giúp cấu hình phòng thủ của MORPH-IDS khó bị dự đoán, hỗ trợ mục tiêu cốt lõi của MTD là khiến kẻ tấn công không thể dự đoán đầy đủ, ngay cả khi biết hàm Q đã học.

3.4. ADI Scheduler – Adversarial Drift Injection

Trong quy trình huấn luyện Học tăng cường, nếu Môi trường quá tĩnh tại, Tác nhân (Defender) sẽ nhanh chóng học thuộc lòng (overfitting) và thất bại khi gặp các biến thể tấn công mới. Để giải quyết vấn đề này, mô đun ADI Scheduler (Adversarial Drift Injection) được sử dụng để chủ động tiêm nhiễm các nhiễu đối kháng và trôi dạt khái niệm vào luồng dữ liệu theo thời gian thực.

Mục tiêu của mô đun này là tạo ra một môi trường huấn luyện khắc nghiệt, buộc tác nhân RL phải liên tục thích nghi và tối ưu hóa chiến lược phòng thủ.

3.4.1. Các phương thức Tiêm Drift Tổng hợp

Để mô phỏng đa dạng các kịch bản thực tế, ADI Scheduler hỗ trợ 3 cơ chế biến đổi dữ liệu nền tảng, tác động trực tiếp lên không gian đặc trưng $\mathcal{X}$ và không gian nhãn $\mathcal{Y}$.

a. Covariate Shift (Dịch chuyển Đặc trưng): Mô phỏng sự việc kẻ tấn công thay đổi kỹ thuật để lẩn tránh sự phát hiện mà không thay đổi bản chất cuộc tấn công.

- MORPH-IDS sử dụng phương pháp dựa trên Gradient. Hệ thống tính toán độ quan trọng của đặc trưng và cộng thêm nhiễu δ vào các đặc trưng mà Defender đang dựa vào nhiều nhất.

$$x_{adv} = x + \epsilon \cdot \text{sign}(\nabla_x J(\theta, x, y))$$

- Mục đích: Buộc Defender không được phụ thuộc vào các dấu hiệu đơn lẻ (như độ dài gói tin) mà phải học biểu diễn đặc trưng toàn diện.

b. Prior Drift (Dịch chuyển Tiền nghiệm): Cơ chế này mô phỏng các biến động về tần suất tấn công trong thực tế.

- Mô đun thực hiện lật nhãn (label flipping) với xác suất tỷ lệ thuận với mức độ nghiêm trọng.
- Mục đích: Mô phỏng các đợt tấn công dồn dập (Burst Attacks) hoặc thời điểm hệ thống mạng trở nên cực kỳ yên tĩnh (Benign dominant), buộc IDS phải điều chỉnh ngưỡng quyết định (threshold) để tránh False Positives/Negatives.

c. Concept Drift (Dịch chuyển Ngữ nghĩa): Mô phỏng tình huống nguy hiểm nhất: hành vi tấn công cũ nhưng mang đặc điểm mới, hoặc hành vi bình thường bị nhiễu trông giống tấn công.

- ADI xác định đặc trưng quan trọng nhất và tính toán độ bất định cục bộ. Xác suất lật nhãn sẽ cao hơn ở những vùng mà dữ liệu có độ bất định cao.
- Mục đích: Mô phỏng các cuộc tấn công tinh vi nhắm vào điểm mù của mô hình hoặc sự thay đổi trong hành vi tấn công.

3.4.2. Các chế độ Lịch trình Drift

Để kiểm tra khả năng thích nghi của MORPH-IDS dưới nhiều tình huống khác nhau, ADI Scheduler điều khiển cường độ nhiễu theo thời gian thông qua 4 chế độ:

- Sudden Drift (Dịch chuyển Đột ngột): Phân phối dữ liệu thay đổi tức thời tại thời điểm t_{drift}. Dùng để đánh giá tốc độ phản ứng của Defender.
- Gradual Drift (Dịch chuyển Dần dần): Thay đổi từ từ trong khoảng Δt. Dữ liệu mới dần dần thay thế dữ liệu cũ. Dùng để kiểm tra xem Defender có bị đánh lừa bởi các thay đổi nhỏ tích lũy hay không.

- Incremental Drift (Dịch chuyển Leo thang): Độ khó tăng dần không giới hạn. Dùng để kiểm tra giới hạn chịu đựng của hệ thống.
- Recurring Drift (Dịch chuyển Lặp lại/Chu kỳ): Lặp lại các mẫu tấn công cũ. Dùng để kiểm tra khả năng ghi nhớ, tránh hiện tượng lãng quên thảm khốc.

3.4.3. Cơ chế Điều chỉnh Độ khó Thích ứng

Đây là bộ não của ADI Scheduler, tạo nên tính chất Đối kháng của MORPH-IDS. Nó không tấn công mù quáng mà quan sát hiệu suất của Defender để điều chỉnh cường độ tấn công α_t. Để đảm bảo quá trình huấn luyện hiệu quả, cường độ Drift (α) được điều chỉnh động dựa trên tỷ lệ thắng (Win Rate) của Defender trong N tập gần nhất.

Công thức cập nhật độ khó:

$$\alpha_{t+1} = \begin{cases} \alpha_t + \eta, & \text{nếu } WR_{def} > T_{high} \quad \text{(Defender quá giỏi} \rightarrow \text{Tăng khó)} \\ \alpha_t - \eta, & \text{nếu } WR_{def} < T_{low} \quad \text{(Defender đang thua} \rightarrow \text{Giảm khó)} \\ \alpha_t, & \text{khác} \end{cases}$$

Trong đó η là bước nhảy độ khó.

Ý nghĩa: Giữ trạng thái dòng chảy: Bài toán không quá dễ cũng không quá khó. Cơ chế này tự động tạo ra một lộ trình huấn luyện từ cơ bản đến nâng cao mà không cần can thiệp thủ công.

3.5. SOTADriftEmbedding

Trong kiến trúc đề xuất, SOTADriftEmbedding đóng vai trò là cơ chế nhận thức ngữ cảnh. Mô đun này chịu trách nhiệm chuyển đổi các tín hiệu thống kê thô về sự thay đổi phân phối dữ liệu thành một biểu diễn vector D_t cố định. Vector này cung cấp thông tin đầu vào quan trọng giúp Tác nhân RL phân biệt

giữa sự thay đổi dữ liệu lành tính và các cuộc tấn công đối kháng.

3.5.1. Cấu trúc chi tiết Vector SOTADriftEmbedding

Để cung cấp ngữ cảnh toàn diện cho Tác nhân RL, mô đun SOTADriftEmbedding tổng hợp một vector đặc trưng cố định D_t gồm 20 chiều ($D_t \in \mathbb{R}^{20}$). Vector D_t được tính toán dựa trên cơ chế Sliding Window, so sánh sự sai lệch phân phối giữa Cửa sổ Tham chiếu (W_{ref}: 1000 mẫu lành tính gần nhất) và cửa sổ dữ liệu hiện tại (W_{curr}: 200 mẫu mới nhất). Vector bao gồm 5 nhóm chỉ số thành phần:

a. Nhóm Khoảng cách Phân phối ($d_0 - d_3$):Đo lường sự thay đổi tổng quát của dữ liệu:

1. d_0: Bình phương khoảng cách Euclidean giữa hai vector trung bình (centroids), chuẩn hóa và cắt về $[0, 10]$.

2. d_1: Khoảng cách 1-Wasserstein[14] trung bình trên 10 đặc trưng quan trọng nhất.

3. d_2: Entropy nhị phân trung bình của điểm tin cậy dự đoán trong cửa sổ hiện tại, chuẩn hóa bởi $\ln 2$ và nhân với 3, cắt về khoảng $[0, 3]$.

4. d_3: Phân kỳ Jensen-Shannon (JSD)[15] tính trên biểu đồ tần suất. trung bình tính từ biểu đồ tần suất 50-bin của 10 đặc trưng đầu tiên, cắt về khoảng $[0, 1]$.

b. Nhóm Phân loại Drift ($d_4 - d_6$): Giúp Agent hiểu nguyên nhân của sự thay đổi để chọn chiến lược đối phó phù hợp.

1. d_4 (Covariate Drift): Thống kê Kolmogorov-Smirnov[24] trung bình trên tất cả đặc trưng, nhân với hệ số nhạy 2.0.

2. d_5 (Prior Drift): Chênh lệch tuyệt đối giữa tỷ lệ tấn công trong cửa sổ tham chiếu so với cửa sổ hiện tại, nhân hệ số 3.0.

3. d_6 (Conditional Drift): Chênh lệch độ tuyệt đối trong điểm tin cậy trung bình, được điều chỉnh bởi d_5, nhân hệ số 5.0.

c. Nhóm Động lực học Thời gian ($d_7 - d_9$): Theo dõi đạo hàm của sự thay đổi qua 5 bước thời gian để dự báo xu hướng:

1. d_7 (Vận tốc): Tốc độ thay đổi trung bình của trôi dạt: $(m_t - m_{t-4})/5$, cắt về khoảng $[-1, 1]$.
2. d_8 (Gia tốc): Sự thay đổi của vận tốc $(d_7^{(t)} - d_7^{(t-1)})$, cắt về khoảng $[-1, 1]$.
3. d_9 (Xu hướng): Hệ số góc hồi quy tuyến tính của lịch sử độ lớn trôi dạt, cắt về khoảng $[-0.5, 0.5]$.

d. Nhóm Độ Không Chắc Chắn và Mức Độ Nghiêm Trọng ($d_{10} - d_{15}$): Các chỉ số đồng thuận và chỉ báo không chắc chắn:

- d_{10}: Tỷ lệ giữa khoảng cách Fréchet và Wasserstein (đo lường tính nhất quán hình học).
- d_{11}: Tỷ lệ các số liệu trôi dạt vượt quá trung vị của chúng.
- d_{12}: Entropy chuẩn hóa của độ tin cậy trung bình.
- d_{13}: Giá trị tối đa trong nhóm khoảng cách $(d_0 \dots d_3)$, chỉ báo trường hợp xấu nhất.
- d_{14}: Điểm tin cậy nghịch đảo dựa trên phương sai của các khoảng cách: $1/(1 + \mathrm{Var}(d_0, \dots, d_3))$.
- d_{15}: (Dự phòng cho chỉ số tổng hợp biến thiên).

e. Nhóm Chỉ số Phát hiện Đầu độc ($d_{16} - d_{19}$): Được thiết kế chuyên biệt để chống lại các cuộc tấn công đối kháng (Adversarial Attacks) nhắm vào chính Tác nhân RL:

1. d_{16}: Z-score của phần thưởng hiện tại so với 1000 phần thưởng gần nhất, chuẩn hóa bởi ngưỡng 3.0.

2. d_{17}: Phương sai của điểm tin cậy trên 20 dự đoán gần nhất, chuẩn hóa bởi 0.1.

3. d_{18}: Z-score của độ lớn thay đổi trạng thái (chuẩn L2 giữa các trạng thái liên tiếp).

4. d_{19}: Tích của độ tin cậy tối đa và phương sai độ tin cậy, phát hiện việc khai thác ranh giới.

Chỉ số Trôi dạt Tổng hợp (m_t): Độ lớn trôi dạt vô hướng dùng để kích hoạt các cơ chế thích ứng được tổng hợp từ nhóm khoảng cách phân phối:

$$m_t = \frac{1}{4}\left(\frac{d_0}{10} + \frac{d_1}{5} + \frac{d_2}{3} + d_3\right)$$

Nhờ cấu trúc này, SOTADriftEmbedding không chỉ phản ánh "mức độ xa" so với phân phối gốc, mà còn phân biệt được kiểu drift và cách drift thay đổi theo thời gian.

3.5.2. Phát hiện trôi dạt khái niệm và cập nhật τ_{polyak} thích ứng

Trôi dạt khái niệm được phát hiện bằng một bộ chỉ số kết hợp các kiểm định thống kê (như KS-test), các thước đo khoảng cách phân phối (Wasserstein, JSD) và sự bất đồng thuận của tập mô hình. Chỉ số mức độ nghiêm trọng được suy ra từ nhúng trôi dạt d_t^{drift}, kết hợp các thành phần d_1, d_3 và các độ đo bất định.

Khi mức trôi dạt vượt qua ngưỡng xác định, hệ số Polyak τ_{polyak} trong cập nhật mạng mục tiêu của Dueling Double DQN được điều chỉnh tăng để nâng cao tốc độ theo dõi của mạng mục tiêu. Quy tắc cập nhật như sau:

$$\theta^- \leftarrow \tau_{polyak}\theta + (1 - \tau_{polyak})\theta^-$$

, trong đó τ_{polyak} tăng từ 0.005 (giai đoạn ổn định) lên 0.05 (trôi dạt cao) để tăng

tốc độ thích ứng trong khi vẫn duy trì sự ổn định của quá trình huấn luyện.

3.5.3. Cơ Chế Học Tăng Cường

Để giảm thiểu hiện tượng quên thảm khốc trong khi thích ứng với các mẫu tấn công mới, hệ thống triển khai một cơ chế học tăng cường dựa trên bộ đệm nhỏ.

- Bộ đệm học tập: Lưu trữ tối đa 32 cặp (đặc trưng, nhãn) gần nhất, đại diện cho phân phối hiện thời.
- Điều kiện kích hoạt: Khi độ lớn trôi dạt m_t vượt ngưỡng θ_{drift} đã hiệu chỉnh và bộ đệm đã đầy.

Khi hội đủ điều kiện, tất cả bốn mô hình trong tổ hợp được cập nhật theo quy trình sau:

1. Lấy mẫu phân tầng: Nếu tỷ lệ lớp thiểu số trong bộ đệm dưới 20%, áp dụng kỹ thuật lấy mẫu quá mức để đạt tỉ lệ gần 45%–55% giữa hai lớp. Bước này đảm bảo các bản cập nhật không bị lệch về phía một lớp chi phối.
2. Cập nhật mô hình: Mỗi mô hình được tối ưu bằng SGD với momentum:

$$\theta \leftarrow \theta - \eta \cdot \nabla_\theta \mathcal{L}_{\text{CE}}(y, f_\theta(x))$$

   với tốc độ học $\eta = 0.01$, momentum $= 0.9$ và suy giảm trọng số $= 10^{-5}$. Số bước cập nhật được giới hạn ở 20 lần gradient, sử dụng hàm mất mát cross-entropy có trọng số lớp.
3. Thời gian hồi chiêu (cooldown): Ít nhất 20 mẫu mới phải được xử lý trước khi cho phép một đợt cập nhật tăng cường tiếp theo, nhằm tránh dao động do cập nhật quá dày.

Kích thước bộ đệm nhỏ giúp giữ chi phí tính toán và bộ nhớ ở mức thấp, trong khi vẫn cho phép các mô hình điều chỉnh dần theo phân phối mới.

3.6. Cơ chế Phòng thủ Mạnh mẽ và Chống Đầu độc

Để bảo vệ hệ thống khỏi các cuộc tấn công đối kháng nhắm vào chính mô hình học máy, MORPH-IDS triển khai lớp phòng thủ đa tầng.

3.6.1. Tăng cường Thời gian Kiểm thử

Khi độ lớn trôi dạt $m_t > 0.25$, cho thấy khả năng có nhiễu loạn đối kháng, quá trình suy diễn không dựa trên một mẫu đơn lẻ mà chuyển sang chế độ Test-Time Augmentation (TTA). Xác suất dự đoán cuối cùng được tính bằng trung bình các đầu ra softmax:

$$p(y|x) = \frac{1}{3}\sum_{k=1}^{3} \text{softmax}(f_\theta(x + \epsilon_k)), \quad \text{với } \epsilon_k \sim \mathcal{N}(0, 0.02^2 I)$$

Kỹ thuật này giúp vô hiệu hóa các nhiễu loạn nhỏ được thiết kế để đẩy mẫu qua ranh giới quyết định.

3.6.2. Robust Prioritized Experience Replay (RobustPER)

Bộ đệm Prioritized Experience Replay (PER)[34] tiêu chuẩn được mở rộng với các cơ chế phát hiện và giảm thiểu ảnh hưởng của chuyển tiếp bị đầu độc.

Quy trình lọc dữ liệu độc hại gồm 3 giai đoạn:

1. Phát hiện Bất thường Thống kê: Loại bỏ các mẫu có lỗi TD (Temporal Difference error) vượt quá 3σ, thường là dấu hiệu của tấn công Backdoor nhằm thao túng giá trị Q.

2. Kiểm tra Gradient: Giám sát chuẩn (Norm) của gradient. Nếu một mẫu i tạo ra gradient quá lớn bất thường so với batch hiện tại ($r_i > \tau_{grad}$), nó sẽ bị coi là mẫu đối kháng phá hoại quá trình học và bị giảm trọng số.

$$r_i = \frac{\|\nabla_\theta \mathcal{L}(s_i, a_i)\|}{\text{median}(\{\|\nabla_\theta \mathcal{L}(s_j, a_j)\|_{j \in B}\})}$$

3. Kiểm tra nhất quán Ensemble: Nếu một mẫu được gán độ ưu tiên cao nhưng lại gây ra sự bất đồng thuận lớn giữa các mô hình trong modelpool, nó bị đánh dấu là đáng ngờ.

Các mẫu bị xác định là độc hại sẽ bị gán mức ưu tiên thấp $p'_i = \min(p_i, \tau_{max})$ hoặc bị loại bỏ, ngăn chúng làm hỏng chính sách của Agent.

3.7. Enhanced RL Select Ensemble – pha đánh giá dưới drift

Sau giai đoạn huấn luyện đối kháng, hệ thống chuyển sang giai đoạn đánh giá và vận hành. Tại đây, kiến trúc Enhanced RL Select Ensemble được kích hoạt để đối phó với các luồng dữ liệu chứa Drift phức tạp. Khác với các phương pháp Ensemble tĩnh truyền thống (như Random Forest), cơ chế này hoạt động động dựa trên ngữ cảnh nhờ chiến lược ra quyết định 3 tầng.

3.7.1. Kế thừa Q-network và Model Pool từ pha huấn luyện

Bước đầu tiên của pha đánh giá là quá trình chuyển giao tri thức từ môi trường huấn luyện sang môi trường suy diễn. Quá trình chuyển giao bao gồm hai thành phần chính:

a. Model Pool (Kho mô hình cơ sở): Hệ thống MORH-IDS của nhóm tải lại trọng số tối ưu của 4 mô hình: MLP, CNN, TCN, và BiLSTM. Các mô hình này cung cấp các dự đoán đa dạng dưới các góc nhìn khác nhau (thống kê, cục bộ, ngữ cảnh rộng, chuỗi).

b. Q-Network (Bộ não điều khiển): Mạng Q-Network tải trọng số đã hội tụ sau quá trình RL Training. Chiến lược hành động chuyển từ ϵ-greedy (thăm dò) sang Greedy Policy hoàn toàn ($a_t = \text{argmax}\, Q(s_t, a)$) để tối đa hóa hiệu năng phòng thủ.

3.7.2. Adapter Drift

Để giải quyết bài toán Phát hiện Mù - nơi Agent không biết nhãn thực của dữ liệu hay loại tấn công cụ thể - mô đun Adapter đóng vai trò đồng bộ hóa tín hiệu môi trường.

- Đầu vào: Vector đặc trưng dữ liệu gốc (X_t) và Vector nhúng trôi dạt ($D_t \in \mathbb{R}^{20}$) từ mô đun SOTADriftEmbedding.
- Cơ chế Tích hợp:Adapter thực hiện nối và chuẩn hóa cục bộ để tạo ra vector trạng thái mở rộng:

$$S_{context} = \text{LayerNorm}(X_t \oplus D_t)$$

3.7.3. Chiến lược Phòng thủ Phân tầng

Đây là cốt lõi của cơ chế Enhanced RL Select Ensemble. Thay vì chỉ đưa ra một dự đoán đơn lẻ, MORPH-IDS xử lý qua 3 lớp phòng vệ để lọc nhiễu và thích nghi.

a. Tầng 1: Lựa chọn Chiến lược thông qua RL: Dựa trên trạng thái s_t, mạng Dueling DQN sẽ không trực tiếp phân lớp gói tin, mà nó chọn cấu hình thuật toán tối ưu nhất cho tình huống hiện tại.

- Đầu vào: Trạng thái drift $S_{context}$.
- Đầu ra: Hành động $A_t \in \{\text{Model}_i, \text{Aggregator}_j\}$.
- Đạt hiệu suất cao nhất và chi phí tính toán thấp nhất (chỉ chạy 1 mô hình được chọn).

b. Tầng 2: Tổng hợp và Bỏ phiếu: Sau khi Tầng 1 chọn chiến lược, Tầng 2 thực thi tính toán và tổng hợp kết quả dự đoán $\hat{y}$:

1. Weighted Voting: Sử dụng khi độ tin cậy của các mô hình không đồng đều. Trọng số w_i được tính dựa trên độ tự tin (Confidence Score) của từng mô

hình đối với mẫu hiện tại:

$$\hat{y} = \arg\max_{c} \sum_{i=1}^{K} w_i \cdot \mathbb{I}(f_i(x) = c)$$

(Với w_i là điểm tin cậy của mô hình).

2. Majority Voting: Sử dụng khi cần độ bền vững cao, ưu tiên sự đồng thuận của số đông để giảm thiểu báo động giả

3. Median Aggregator: Sử dụng khi hệ thống nghi ngờ có tấn công đối kháng mạnh. Lấy giá trị trung vị của vector xác suất theo từng phần tử. các cuộc tấn công FGSM thường đẩy giá trị dự đoán lên cực đại. Phép lấy trung vị sẽ loại bỏ các giá trị ngoại lai này hiệu quả hơn phép lấy trung bình, giúp loại bỏ nhiễu đối kháng.

c. Tầng 3: Học tăng cường thích nghi: Đây là tầng cuối cùng, kích hoạt khi MORPH-IDS nhận thấy Drift quá lớn mà các mô hình hiện tại không thể xử lý tốt (dựa trên tín hiệu Vận tốc Trôi dạt từ SOTAD).

- Điều kiện kích hoạt: Khi Tín hiệu Vận tốc Trôi dạt (d_7 trong vector D_t) tăng đột biến hoặc Độ tin cậy trung bình của Ensemble giảm xuống dưới ngưỡng an toàn (θ_{safe}).

- Cơ chế:

  1. Đánh dấu mẫu dữ liệu hiện tại là "High Uncertainty".
  2. Đưa mẫu vào hàng đợi ưu tiên của Replay Buffer.
  3. Kích hoạt quy trình Incremental Learning để tinh chỉnh trọng số mô hình ngay trong thời gian thực (TTA).
  4. Mục tiêu: Giúp MORPH-IDS tiến hóa ngay trong quá trình đánh giá để bắt kịp với sự thay đổi của ADI Scheduler mà không cần huấn luyện lại từ đầu.

3.8. Phân tích độ phức tạp của thuật toán

3.8.1. So sánh độ phức tạp tính toán của các mô hình thành phần

Định nghĩa các ký hiệu:

- N: Số chiều đặc trưng đầu vào.
- H: Kích thước lớp ẩn hoặc số kênh.
- K: Kích thước bộ lọc tích chập.
- L: Chiều dài chuỗi giả lập (Sequence Length) sau khi chiếu (Projected).
- S: Kích thước không gian trạng thái RL.

Bảng 3.1 tóm tắt độ phức tạp và đặc điểm triển khai của các thành phần:

Bảng 3.1: *So sánh độ phức tạp tính toán của các mô hình thành phần*

Mô hình	**Độ phức tạp thời gian**	**Độ phức tạp không gian**
MLP	Thấp nhất $O(N \cdot H)$	Thấp $O(N \cdot H + H^2)$
CNN	Trung bình $O(L \cdot H^2 \cdot K)$	Trung bình $O(K \cdot H^2)$
TCN	Trung bình $O(L \cdot H^2 \cdot K)$	Trung bình $O(K \cdot H^2)$
BiLSTM	Cao nhất $O(L \cdot H^2)$	Cao $O(4 \cdot H^2)$
RL Agent	Rất thấp $O(S \cdot H_{rl})$	Thấp $O(S \cdot H_{rl})$

3.8.2. Phân tích thời gian thích ứng và độ trễ phục hồi:

Trong môi trường mạng thực tế, khả năng xử lý nhanh là chưa đủ; hệ thống còn đòi hỏi khả năng phản ứng tức thời trước các thay đổi bất ngờ của môi trường. Khoảng thời gian từ khi xuất hiện sự thay đổi phân phối dữ liệu hoặc tấn công mới cho đến khi hệ thống tự điều chỉnh xong cấu hình phòng thủ được

định nghĩa là Thời gian thích ứng tổng thể (T_{adapt}).Thời gian này được phân rã thành ba thành phần chính:

$$T_{adapt} = T_{detect} + T_{decide} + T_{update}$$

Trong đó:

1. Thời gian phát hiện trôi dạt (T_{detect}):
   - Đây là khoảng thời gian để mô-đun SOTADriftEmbedding tính toán vector ngữ cảnh 20 chiều từ dữ liệu thô.
   - Thay vì sử dụng các mô hình học sâu giám sát phức tạp để phát hiện drift, hệ thống sử dụng các độ đo thống kê nhẹ như Khoảng cách Wasserstein 1D, Entropy và Phân kỳ Jensen-Shannon trên Sliding Window.
   - Độ phức tạp tính toán là $\mathcal{O}(W \cdot N)$, với W là kích thước cửa sổ và N là số chiều đặc trưng. Do đó, T_{detect} là không đáng kể và có thể thực hiện song song với quá trình xử lý gói tin.
2. Thời gian ra quyết định (T_{decide}):
   - Là thời gian Tác nhân RL thực hiện suy luận để ánh xạ vector trạng thái S_t sang hành động tối ưu A_t (chọn cặp Model-Aggregator).
   - Do mạng Dueling DQN chỉ bao gồm các lớp kết nối đầy đủ với kích thước cố định, độ phức tạp là hằng số $O(1)$ đối với luồng dữ liệu. Thời gian này thường nhỏ hơn 1ms trên các phần cứng hiện đại, đảm bảo không gây độ trễ cho luồng mạng tốc độ cao.
3. Thời gian cập nhật mô hình (T_{update}):
   - Đây là thành phần quan trọng nhất, đại diện cho khả năng Tự phục hồi của hệ thống thông qua cơ chế học tăng cường.
   - Khác với các hệ thống truyền thống yêu cầu huấn luyện lại toàn bộ mất nhiều phút hoặc giờ, MORPH-IDS sử dụng chiến lược Cập nhật Vi mô:

  - Sử dụng bộ đệm kinh nghiệm cực nhỏ với kích thước $B \approx 32$ mẫu.
  - Thực hiện cập nhật trọng số cục bộ qua một số ít bước lặp.

- Độ phức tạp: $O(B \cdot E)$, với B là kích thước bộ đệm và E là số bước cập nhật. Nhờ B rất nhỏ, T_{update} được giữ ở mức mili-giây, cho phép hệ thống khôi phục độ chính xác ngay trong quá trình vận hành (Online Adaptation) mà không cần gián đoạn dịch vụ.

Tổng thời gian thích ứng T_{adapt} của kiến trúc MORPH-IDS được tối ưu hóa để đảm bảo tính chất thời gian thực. Hệ thống không chỉ phát hiện tấn công nhanh mà còn sở hữu cơ chế phản xạ linh hoạt, cho phép cấu hình lại kiến trúc phòng thủ gần như tức thời trước các biến thể tấn công mới, khắc phục nhược điểm chậm thích nghi của các hệ thống IDS tĩnh.

3.8.3. Phân tích độ bền vững trong khoảng trễ thích nghi

Một vấn đề đặt ra đối với các hệ thống thích nghi thời gian thực là Window of Vulnerability – khoảng thời gian ngắn (Δt) khi hệ thống đang thực hiện cập nhật trọng số (T_{update}) nhưng các đợt tấn công mới vẫn tiếp tục dồn dập. Trong kiến trúc MORPH-IDS, vấn đề này được giải quyết thông qua cơ chế Phòng thủ theo chiều sâu, đảm bảo hệ thống duy trì tính sẵn sàng và độ chính xác chấp nhận được ngay cả khi chưa hoàn tất quá trình học:

1. Tính sẵn sàng liên tục: Hệ thống được thiết kế theo cơ chế Non-blocking. Trong khi tiến trình huấn luyện cập nhật diễn ra ngầm, luồng xử lý gói tin vẫn hoạt động bình thường sử dụng phiên bản mô hình hiện tại ($Model_t$). Dù chưa tối ưu với mẫu tấn công mới nhất, mô hình vẫn duy trì khả năng phân loại dựa trên các đặc trưng đã học trước đó.

2. Bù trừ bằng Ensemble: Trong giai đoạn chuyển tiếp này, nếu một mô hình thành phần bị đánh lừa bởi mẫu tấn công mới, các mô hình còn lại trong tổ hợp (với kiến trúc khác biệt như CNN hay MLP) vẫn có khả năng nhận

diện đúng. Cơ chế Bầu chọn Đa số (Majority Voting) giúp loại bỏ các dự đoán sai lệch cục bộ, giữ cho kết quả cuối cùng ổn định.

3. Giảm thiểu cửa sổ rủi ro: Quan trọng nhất, nhờ chiến lược Cập nhật Vi mô với bộ đệm chỉ 32 mẫu, thời gian T_{update} được giảm xuống mức mili-giây. Điều này thu hẹp tối đa Window of Vulnerability, khiến kẻ tấn công không đủ thời gian để khai thác triệt để độ trễ của hệ thống.

Kết luận: MORPH-IDS chấp nhận một độ trễ thích nghi cực nhỏ để đổi lấy khả năng tự phục hồi lâu dài, đảm bảo cân bằng giữa tính ổn định tức thời và khả năng tiến hóa theo thời gian.

3.8.4. Đánh giá chiến lược đánh đổi và Tính khả thi triển khai

Dựa trên các phân tích định lượng về độ phức tạp và thời gian thích ứng ở trên, kiến trúc MORPH-IDS thể hiện tính khả thi cao khi triển khai thực tế thông qua cơ chế Đánh đổi Động. Thay vì tối ưu hóa cực đoan về một phía (chỉ tốc độ hoặc chỉ độ chính xác), hệ thống duy trì sự cân bằng linh hoạt:

1. Tối ưu hóa trong điều kiện bình thường (Drift thấp):
   - RL Agent có xu hướng chọn MLP hoặc CNN kết hợp với Mean Aggregator.
   - Độ phức tạp trung bình của hệ thống tiến về mức thấp: xấp xỉ $O(N \cdot H)$. Điều này giúp tối ưu hóa độ trễ và tiết kiệm tài nguyên năng lượng cho các thiết bị biên.
2. Tăng cường sức mạnh trong điều kiện bất thường (Drift cao / Tấn công):
   - Khi phát hiện trôi dạt dữ liệu hoặc dấu hiệu tấn công, Tác nhân RL chấp nhận chi phí tính toán cao hơn để chuyển sang các mô hình chuyên sâu như BiLSTM hoặc TCN kết hợp với cơ chế gộp mạnh như Median/Majority Vote.

- Độ phức tạp tăng lên mức cao hơn để đổi lấy khả năng chống chịu.
- Mặc dù BiLSTM có độ phức tạp cao $O(L \cdot H^2)$, nhưng nhờ cơ chế học tăng cường, nó chỉ được kích hoạt trong thời gian ngắn khi thực sự cần thiết.

Kết luận tính khả thi: Độ phức tạp trung bình theo thời gian (Amortized Complexity) của toàn hệ thống vẫn được giữ ở mức thấp, trong khi vẫn đảm bảo khả năng phát hiện các cuộc tấn công tinh vi. Sự kết hợp giữa chi phí điều phối thấp của mạng Dueling DQN ($O(1)$) và cơ chế cập nhật vi mô ($T_{update} \approx ms$) khẳng định MORPH-IDS hoàn toàn phù hợp để triển khai trên các hạ tầng mạng thực tế có yêu cầu khắt khe về thời gian thực.

Chương 3 đã trình bày đầy đủ kiến trúc MORPH-IDS, một giải pháp phòng thủ chủ động kết hợp sức mạnh biểu diễn của Học sâu (DL) với tư duy chiến lược thích nghi của Học tăng cường (RL). Điểm đột phá của phương pháp nằm ở việc tích hợp cơ chế sinh trôi dạt đối kháng (ADI) để mô phỏng các kịch bản tấn công tinh vi, từ đó làm cơ sở để hệ thống nhận diện ngữ cảnh (SOTAD) và kích hoạt Chiến lược phòng thủ 3 tầng nhằm tự động hóa quá trình thích ứng thời gian thực.

Trên cơ sở lý thuyết và mô hình kiến trúc đã thiết lập, Chương 4 sẽ đi sâu vào quá trình hiện thực hóa, thiết lập thí nghiệm và trình bày kết quả đánh giá nhằm kiểm chứng tính khả thi cũng như hiệu năng của MORPH-IDS trước các kịch bản tấn công đa dạng.

CHƯƠNG 4. HIỆN THỰC, THỰC NGHIỆM VÀ ĐÁNH GIÁ

4.1. Câu hỏi nghiên cứu

Để đánh giá hiệu quả của cơ chế phòng thủ trước tấn công đối kháng nhắm vào hệ thống MORH-IDS, nhóm chúng em thiết kế bốn câu hỏi nghiên cứu (Research Question - RQ) sau:

- RQ1: Mức độ hiệu quả của MORPH-IDS so với các mô hình học máy đơn lẻ và các phương pháp Ensemble tĩnh trên 2 tập dữ liệu trong điều kiện môi trường ổn định như thế nào?
- RQ2: MORPH-IDS thể hiện khả năng phòng thủ và độ bền bỉ ra sao khi đối mặt với các cuộc tấn công đối nghịch (Adversarial Attack) trong môi trường đối kháng?
- RQ3: Tác động cụ thể của từng thành phần thích ứng (SOTADriftEmbedding, Continual Learning, Adaptive Tau) đối với việc duy trì độ ổn định của MORPH-IDS và giảm thiểu hiện tượng quên lãng thảm khốc là gì?
- RQ4: Trong bối cảnh phân phối dữ liệu thay đổi phức tạp theo chuỗi tấn công APT đa giai đoạn, cơ chế thích ứng dựa trên Drift Embedding cải thiện tốc độ phục hồi và tính ổn định hiệu năng như thế nào so với chiến lược cập nhật định kỳ?

4.2. Hiện thực hệ thống

4.2.1. Ngôn ngữ lập trình và môi trường

Tất cả các thực nghiệm đều được tiến hành trên môi trường máy tính hiệu năng cao để đảm bảo tính khả lặp và hiệu quả tính toán. Cấu hình phần cứng và phần mềm cụ thể như sau:

- Cấu hình phần cứng: Các mô hình được huấn luyện và đánh giá trên một máy trạm được trang bị CPU Intel Xeon (2.20GHz), 26GB RAM và GPU NVIDIA Tesla P100 (16GB VRAM). Thiết lập này hỗ trợ các yêu cầu xử lý song song của các mạng nơ-ron sâu và tính chất tiêu tốn tài nguyên của môi trường Học tăng cường đa tác nhân (MARL).
- Ngôn ngữ lập trình: Khung hệ thống MORH-IDS của nhóm được triển khai bằng Python 3.8.
- Các thư viện và Framework chính:
  - Deep Learning Framework: PyTorch (torch, torch.nn)[27]: Đóng vai trò cốt lõi để xây dựng kiến trúc mạng (MLP, CNN, LSTM, TCN) và tính toán gradient tự động.
  - Xử lý dữ liệu hiệu năng cao (GPU Acceleration): RAPIDS (cudf, cuml)[30]: Được sử dụng thay thế cho Pandas và Scikit-learn khi chạy trên môi trường có GPU (như Kaggle T4/P100). cudf giúp đọc file CSV và xử lý dataframe trực tiếp trên VRAM của card đồ họa, tăng tốc độ gấp nhiều lần so với CPU.
  - Bảo mật và Tấn công đối kháng (Adversarial AI): ART (Adversarial Robustness Toolbox)[26]: Thư viện của IBM dùng để tạo ra các mẫu tấn công (như ZOO attack, HopSkipJump) nhằm kiểm thử độ bền vững của mô hình.

– Thư viện cơ bản & Tiện ích:

  * Pandas & NumPy: Dùng để thao tác mảng và bảng dữ liệu (khi không dùng GPU).
  * Scikit-learn (sklearn)[29]: Dùng cho các thước đo đánh giá (F1-score, Precision, Recall, Confusion Matrix) và các bước tiền xử lý như StandardScaler, LabelEncoder.
  * Matplotlib & Seaborn: Dùng để vẽ biểu đồ loss, accuracy và ma trận nhầm lẫn (confusion matrix).

4.2.2. Thông số kỹ thuật của các mô hình

4.2.2.1. Cấu hình chung cho quá trình huấn luyện

- Optimizer (Bộ tối ưu hóa): Sử dụng Adam và AdamW.
- Learning Rate (Tốc độ học): Được đặt ở mức 0.001 (1e-3). Có sử dụng cơ chế ReduceLROnPlateau (giảm tốc độ học nếu loss không giảm sau một số epoch).
- Batch Size: Kích thước lô rất lớn, từ 2048 đến 5000 mẫu. Lý do là dữ liệu mạng (network traffic) rất nhiều, batch lớn giúp tận dụng sức mạnh tính toán song song của GPU.
- Epochs: Thiết lập tối đa 50 epochs, nhưng có sử dụng Early Stopping (dừng sớm) với độ kiên nhẫn (patience) 5 đến 10 epoch nếu kết quả không cải thiện.
- Loss Function (Hàm mất mát): CrossEntropyLoss (cho bài toán phân loại nhiều lớp).

4.2.2.2. Các thông số của các mô hình trong Model Pool

1. MLP: Đây là mạng nơ-ron truyền thẳng cơ bản.
   - Cấu trúc: Gồm 4-5 lớp Dense (Fully Connected).

- Số lượng nơ-ron: Đi theo mô hình "hình phễu", ví dụ: Input -> 256 -> 128 -> 64 -> Output.
- Activation Function: Sử dụng hàm ReLU giữa các lớp ẩn.
- Regularization: Sử dụng Dropout với tỉ lệ 0.3 (30% nơ-ron bị tắt ngẫu nhiên) để chống overfitting.
- Normalization: Sử dụng Batch Normalization sau mỗi lớp dense để ổn định quá trình huấn luyện.

2. DeepCNN: Mạng tích chập 1 chiều, chuyên dùng để bắt các đặc trưng cục bộ trong chuỗi gói tin.
   - Lớp Conv1D: 2 lớp tích chập liên tiếp.
   - Kernel Size (Kích thước bộ lọc): Thường là 3.
   - Filters (Số bộ lọc): Tăng dần, ví dụ 32 -> 64.
   - Pooling: Sử dụng MaxPool1D (kích thước 2) để giảm chiều dữ liệu sau khi tích chập.
   - Flatten: Dát mỏng dữ liệu trước khi đưa vào lớp Dense cuối cùng để phân loại.
3. DeepTCN: Mạng tích chập thời gian, dùng để xử lý dữ liệu chuỗi thay thế cho RNN.
   - Dilated Convolutions: Sử dụng các hệ số giãn nở (dilation factors) tăng theo lũy thừa của 2 (ví dụ: 1, 2, 4, 8). Điều này giúp mạng có "vùng nhìn" (receptive field) rộng hơn mà không cần tăng quá nhiều tham số.
   - Residual Blocks: Sử dụng kết nối tắt (skip connections) để tránh vấn đề biến mất đạo hàm (vanishing gradient).
   - Kernel Size: Thường là 3.
4. BiLSTMAttention: Mạng bộ nhớ dài-ngắn hạn hai chiều.

- Hidden Dimension: Kích thước lớp ẩn thường là 64 hoặc 128.
- Num Layers: Sử dụng 2 lớp chồng lên nhau (stacked LSTM).
- Bidirectional: Kích hoạt chế độ 2 chiều (True), giúp mô hình học được ngữ cảnh từ cả quá khứ và tương lai của chuỗi dữ liệu.

4.3. Thực nghiệm và đánh giá

4.3.1. Mô tả dữ liệu

Để đánh giá toàn diện khả năng khái quát hóa và độ bền vững của hệ thống MORPH-IDS đề xuất, nghiên cứu tiến hành thực nghiệm trên hai tập dữ liệu chuẩn từ Viện An ninh Mạng Canada (CIC). Các tập dữ liệu này được lựa chọn có chủ đích để bổ sung cho nhau, đại diện cho các bối cảnh đe dọa từ mạng IT truyền thống đến môi trường IIoT phức tạp.

a. CIC-IDS2017

CIC-IDS2017 [36] đóng vai trò là nền tảng huấn luyện và đánh giá chính trong nghiên cứu này. Tập dữ liệu bao gồm 7 tệp thành phần, mô phỏng các kịch bản lưu lượng mạng lành tính và tấn công đa dạng được thu thập trong vòng 5 ngày làm việc:

- Friday-WorkingHours-Afternoon-DDos
- Friday-WorkingHours-Afternoon-PortScan
- Friday-WorkingHours-Morning
- Monday-WorkingHours
- Thursday-WorkingHours-Afternoon-Infilteration
- Thursday-WorkingHours-Morning-WebAttacks
- Tuesday-WorkingHours

Phân tích dữ liệu khám phá (EDA):

- **Cấu trúc:** Sau khi loại bỏ các giá trị nhiễu (NaN, Infinity), tập dữ liệu chứa tổng cộng **2.827.876** bản ghi với 79 đặc trưng thống kê luồng (Flow features).
- **Phân phối lớp:** Dữ liệu bao gồm 14 loại tấn công khác nhau, phù hợp cho bài toán phân loại đa lớp. Tỷ lệ phân bố được tóm tắt trong Bảng 4.1.

Bảng 4.1: *Thống kê phân phối tập dữ liệu CIC-IDS2017*

Loại nhãn	Số lượng	Tỷ lệ (%)
Benign Traffic	2,271,320	80.32%
Attack Traffic	556,556	19.68%
Tổng cộng	**2,827,876**	**100.00%**

Trong số các mã độc, các nhóm tấn công chiếm tỷ trọng lớn nhất gồm DoS Hulk (8,16%), PortScan (5,61%), và DDoS (4,52%). Mặc dù tập dữ liệu bị chi phối bởi lưu lượng lành tính, nó vẫn chứa đa dạng các loại hình tấn công từ cường độ cao (như DoS/DDoS) đến tần suất thấp (như Heartbleed và Infiltration), như được minh họa chi tiết trong Hình 4.1.

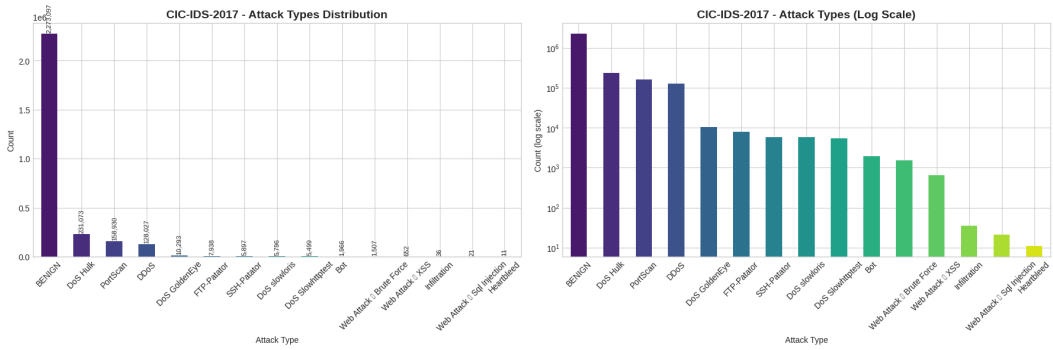

Hình 4.1: *Phân phối nhãn trong tập dữ liệu CIC-IDS2017*

Phân tích tầm quan trọng của đặc trưng: Để xác định các đặc trưng có

khả năng phân biệt tốt nhất cho việc phát hiện xâm nhập trong môi trường này, nghiên cứu đã tiến hành huấn luyện một bộ phân loại Random Forest. Bảng 4.2 phân tích trình bày 20 đặc trưng hàng đầu được xếp hạng theo điểm quan trọng. Phân tích cho thấy việc xác định các thống kê về độ dài gói tin (Phương sai, Tối đa, Độ lệch chuẩn) và các chỉ số khối lượng luồng (Bytes, Kích thước phân đoạn) là rất quan trọng để phân biệt các cuộc tấn công.

Bảng 4.2: *Top 20 đặc trưng quan trọng nhất đối với CIC-IDS2017 (Random Forest)*

Hạng	Đặc trưng	Độ quan trọng	Hạng	Đặc trưng	Độ quan trọng
1	Packet Length Variance	0.066	11	Bwd Packet Length Mean	0.028
2	Max Packet Length	0.064	12	Total Length of Fwd Packets	0.027
3	Avg Bwd Segment Size	0.052	13	Packet Length Mean	0.023
4	Packet Length Std	0.047	14	Fwd Packet Length Mean	0.023
5	Subflow Fwd Bytes	0.046	15	Fwd Packet Length Max	0.022
6	Average Packet Size	0.046	16	Bwd Header Length	0.022
7	Bwd Packet Length Max	0.040	17	Bwd Packet Length Std	0.021
8	Total Length of Bwd Packets	0.039	18	Bwd Packets/s	0.018
9	Destination Port	0.034	19	Total Fwd Packets	0.018
10	Subflow Bwd Bytes	0.034	20	Init_Win_bytes_forward	0.015

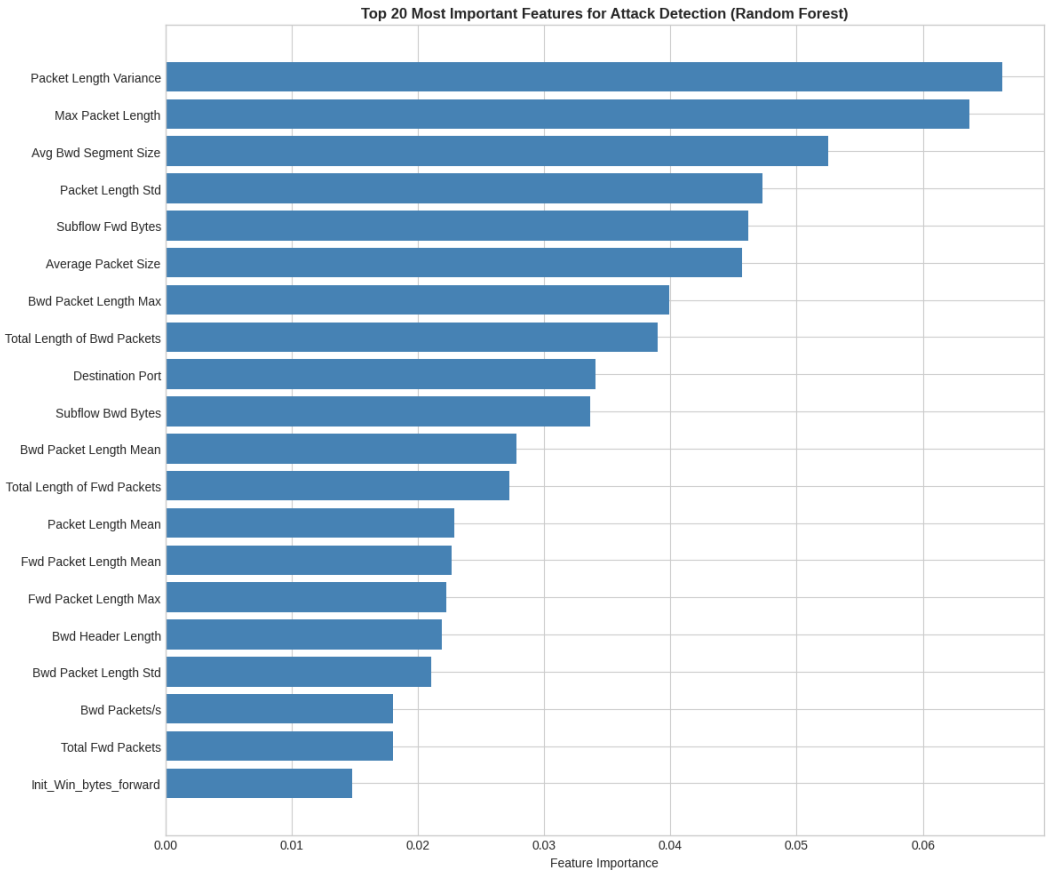

Hình 4.2: *Top 20 đặc trưng quan trọng nhất đối với CIC-IDS2017 (Random Forest)*

CIC-IDS2017 cung cấp 78 đặc trưng thống kê luồng mạng được trích xuất bằng CICFlowMeter. Cấu trúc thời gian trải dài qua nhiều ngày của nó cho phép đánh giá sự trôi dạt khái niệm (Kịch bản 3), làm cho nó đặc biệt phù hợp để đánh giá khả năng thích ứng của MORPH-IDS.

b. CIC-APT-IIoT-2024

Đây là tập dữ liệu thách thức nhất, mô phỏng APT trong môi trường Internet Vạn vật Công nghiệp (IIoT) [12]. Khác với các tập dữ liệu truyền thống, CIC-APT-IIoT-2024 không tập trung vào các sự kiện rời rạc mà mô phỏng chuỗi tấn công đa giai đoạn (Reconnaissance, Lateral Movement, Exfiltration...) lấy cảm hứng từ các nhóm APT thực tế (ví dụ: APT29).

Phân tích dữ liệu khám phá (EDA): Tập dữ liệu bao gồm hơn 21,6 triệu

bản ghi lưu lượng mạng từ hệ thống hybrid IIoT testbed, được chia thành hai giai đoạn đại diện cho kịch bản môi trường mạng thực tế:

- **Giai đoạn 1 (Baseline):** 12.062.396 bản ghi luồng mạng, 100% là lưu lượng vận hành bình thường.
- **Giai đoạn 2 (Attack Campaign):** 9.536.823 bản ghi luồng mạng, trong đó chỉ có **1.004** mẫu là tấn công APT (chiếm 0,011%).

Bảng 4.3 tóm tắt các thông số của tập dữ liệu.

Bảng 4.3: *Thống kê tổng quan tập dữ liệu CIC-APT-IIoT-2024*

Giai đoạn	Tổng số mẫu	Benign	Attack
Phase 1 (Baseline)	12,062,396	12,062,396 (100.00%)	0 (0.00%)
Phase 2 (APT Campaign)	9,536,823	9,535,819 (99.99%)	1,004 (0.01%)
Tổng hợp	**21,599,219**	**21,598,215**	**1,004**

Các thách thức đặc thù:

1. **Mất cân bằng dữ liệu cực đoan:** Tỷ lệ lệ lệch pha lên tới hơn 21.000:1 (Benign:Attack) trong Giai đoạn 2, đặt ra thách thức lớn cho các mô hình học máy thông thường.

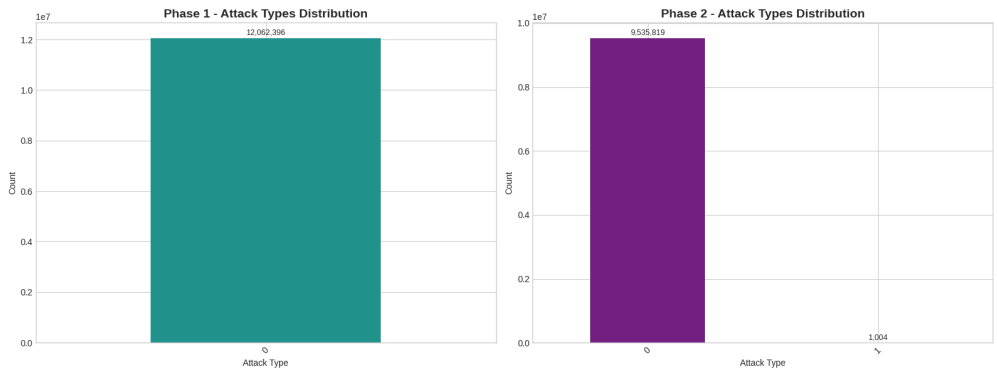

Hình 4.3: *Phân phối nhãn trong CIC-APT-IIoT-2024*

2. **Chiến lược phân vùng:** Cấu trúc hai giai đoạn này được tận dụng triệt để trong Kịch bản 4: Hệ thống sẽ học trên Giai đoạn 1 (bình thường) và phải tự thích nghi để phát hiện các bất thường cực nhỏ trong Giai đoạn 2 (tấn công) mà không cần gán nhãn trước.

3. **Đặc trưng quan trọng:** Phân tích trên mẫu phân tầng của Giai đoạn 2 cho thấy các đặc trưng dựa trên tốc độ và thời gian đóng vai trò quyết định trong việc nhận diện hành vi lẩn trốn của APT. Các đặc trưng quan trọng nhất bao gồm: Srate, Rate, Destination Port, Header Length, và syn_count.

Bảng 4.4: *20 đặc trưng quan trọng hàng đầu đối với CIC-APT-IIoT-2024 (Random Forest)*

Hạng	Đặc trưng	Độ quan trọng	Hạng	Đặc trưng	Độ quan trọng
1	Srate	0.131	11	flow_active_time	0.043
2	Rate	0.125	12	std_duration	0.030
3	Destination Port	0.094	13	Max	0.019
4	Header_Length	0.073	14	min_duration	0.016
5	syn_count	0.067	15	ts	0.016
6	Source Port	0.067	16	max_duration	0.015
7	flow_duration	0.052	17	average_duration	0.013
8	urg_count	0.051	18	Covariance	0.010
9	sum_duration	0.051	19	Std	0.010
10	rst_count	0.047	20	Radius	0.009

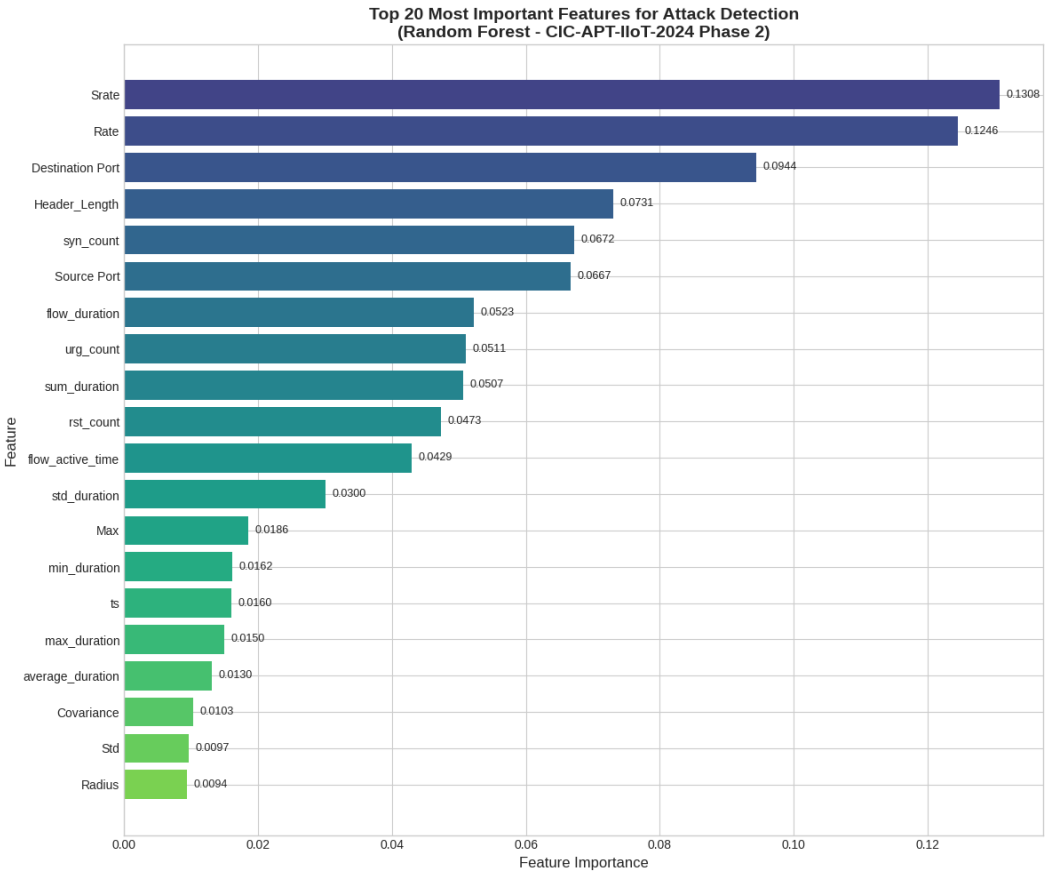

Hình 4.4: *Top 20 đặc trưng quan trọng nhất đối với CIC-APT-IIoT-2024 (Random Forest)*

4.3.2. Tiền xử lý dữ liệu và chiến lược phân chia

4.3.2.1. CIC-IDS2017

a.Tiền xử lý dữ liệu

Tập dữ liệu CIC-IDS2017 [36] bao gồm 7 tệp CSV, đại diện cho các kịch bản lưu lượng mạng và tấn công khác nhau được thu thập trong nhiều ngày. Để đảm bảo chất lượng dữ liệu và khả năng tái sử dụng, MORPH-IDS áp dụng một quy trình tiền xử lý có hệ thống:

1. Loại bỏ các cột siêu dữ liệu như Flow ID, Source IP, Destination IP, Source Port, Destination Port và Timestamp nhằm tránh rò rỉ dữ liệu và tập trung vào các mẫu hành vi lưu lượng.

2. Thay thế các giá trị vô hạn bằng NaN và loại bỏ chúng để tránh mất ổn định số học trong huấn luyện.

3. Phát hiện và loại bỏ các dòng trùng lặp để đảm bảo tính toàn vẹn dữ liệu.

4. Chuẩn hóa nhãn đa lớp về định dạng nhị phân (Benign = 0, Attack = 1).

5. Cố định seed ngẫu nhiên ở seed = 42 cho toàn bộ thí nghiệm để đảm bảo khả năng tái lập.

Sau khi làm sạch, các đặc trưng được chuẩn hóa bằng phương pháp chuẩn hóa Z-score (StandardScaler):

$$X_{\text{normalized}} = \frac{X - \mu}{\sigma}$$

Trong đó μ và σ lần lượt biểu thị giá trị trung bình và độ lệch chuẩn của đặc trưng. Điều này đảm bảo sự đóng góp ngang nhau của các đặc trưng trong quá trình huấn luyện và ngăn chặn việc học bị chi phối bởi quy mô (scale).

b.Chiến lược phân chia

Bộ dữ liệu được phân chia thành ba tập con không giao nhau bằng cách sử dụng phương pháp lấy mẫu ngẫu nhiên phân tầng: Training (75%), Validation (10%), và Test (15%). Việc phân tầng bảo toàn phân phối lớp trên các tập dữ liệu, giảm thiểu tác động của mất cân bằng lớp đối với việc đánh giá. Tập training cho phép mô hình học thông qua lan truyền ngược; tập Validation hỗ trợ dừng sớm và tối ưu hóa siêu tham số; tập Test cung cấp đánh giá cuối cùng.

4.3.2.2. CIC-APT-IIOT-2024

a.Tiền xử lý dữ liệu

Tập dữ liệu được sử dụng trong nghiên cứu là CIC-APT-IIoT 2024 [12, 6], bao gồm hai giai đoạn (Phase) mô phỏng các trạng thái mạng khác nhau: Phase 1 (trạng thái bình thường/cơ sở) và Phase 2 (trạng thái chịu các cuộc tấn công APT nâng cao). Để đảm bảo chất lượng dữ liệu đầu vào cho mô hình Rein-

forcement Learning và module phát hiện trôi dạt (Drift Detection), bộ khung MORPH-IDS áp dụng quy trình tiền xử lý hệ thống gồm 5 bước:

1. Loại bỏ đặc trưng định danh: Lược bỏ các cột siêu dữ liệu như Flow_ID, Src_IP, Dst_IP, Timestamp, và Protocol_name. Việc này nhằm ngăn chặn mô hình "học vẹt" các địa chỉ cụ thể, tránh rò rỉ dữ liệu (data leakage) và buộc mô hình tập trung vào các mẫu hành vi lưu lượng.

2. Làm sạch dữ liệu số: Thay thế các giá trị vô hạn (inf, -inf) bằng NaN và loại bỏ toàn bộ các dòng chứa giá trị rỗng để đảm bảo tính ổn định số học tuyệt đối trong quá trình tính toán tensor.

3. Mã hóa nhãn: Chuyển đổi nhãn đa lớp và nhãn dạng chuỗi về định dạng nhị phân thống nhất (Benign = 0, Attack = 1). Các nhãn như "Benign", "Normal" được gán giá trị 0, trong khi toàn bộ các lớp tấn công khác được gán giá trị 1.

4. Cố định tham số ngẫu nhiên: Thiết lập RANDOM_SEED = 42 cho toàn bộ các thư viện (Numpy, Torch, Python) để đảm bảo tính nhất quán và khả năng tái lập của thí nghiệm.

5. Chuẩn hóa dữ liệu: Sau khi làm sạch, các đặc trưng được chuẩn hóa về khoảng [0,1] bằng phương pháp Min-Max Scaling để tối ưu hóa sự hội tụ của Gradient Descent:

$$X_{norm} = \frac{X - X_{min}}{X_{max} - X_{min}}$$

b. Chiến lược phân chia và Lấy mẫu

Bộ dữ liệu sau khi làm sạch và chuẩn hóa được chia thành ba tập con không giao nhau bằng phương pháp lấy mẫu ngẫu nhiên phân tầng (stratified sampling) nhằm duy trì tỉ lệ giữa hai lớp benign và attack:

- Training: 64%

- Validation: 16%
- Test: 20%

Cách chia này tương đương với việc: Chia dữ liệu thành 80% huấn luyện + xác thực và 20% kiểm thử. Sau đó, từ 80% ban đầu, tiếp tục tách 20% cho validation. Phân tầng đảm bảo rằng mỗi tập dữ liệu phản ánh đúng phân phối lớp ban đầu, giúp mô hình được huấn luyện và đánh giá trong điều kiện ổn định, không chịu tác động của trôi khái niệm (no-drift scenario). Tập Training được sử dụng để huấn luyện mô hình thông qua lan truyền ngược; tập Validation phục vụ tối ưu hóa siêu tham số và dừng sớm; tập Test cung cấp đánh giá cuối cùng về khả năng khái quát hóa của mô hình.

4.3.3. Các kịch bản thí nghiệm

4.3.3.1. ***Kịch bản 1***

a. Mục tiêu

Kịch bản 1 thiết lập một mức cơ sở vững chắc và có kiểm soát để đánh giá hiệu năng nội tại của tập hợp các mô hình (MLP, CNN, TCN, BiLSTM) và hành vi của MORPH-IDS trong điều kiện hoạt động đơn giản nhất: dữ liệu kiểm tra sạch, tĩnh, không có trôi dạt khái niệm, không có nhiễu loạn đối kháng, và không áp dụng các biện pháp chống đầu độc. Ngoài việc báo cáo hiệu năng độc lập của từng bộ học cơ sở, nhóm em so sánh chúng một cách rõ ràng với một ensemble tĩnh và cơ chế lựa chọn động của bên phòng thủ (bị giới hạn trong cùng một tập hợp mô hình).

Mục đích là trả lời câu hỏi nghiên cứu RQ1:

"Mức độ hiệu quả của MORPH-IDS so với các mô hình học máy đơn lẻ và các phương pháp Ensemble tĩnh trên hai tập dữ liệu trong điều kiện môi trường ổn định như thế nào?"

Kịch bản này đóng vai trò là điểm tham chiếu cho tất cả các đánh giá tiếp

theo.

b. Thiết lập thí nghiệm

- Dữ liệu sử dụng:
  - CIC-IDS2017 [36]
  - CIC-APT-IIOT-2024 [12, 6]
- Cả hai tập dữ liệu đều đã được tiền xử lý và phân chia theo pipeline
- Các mô hình học máy đơn lẻ:
  - MLP – mạng perceptron nhiều lớp, 3 tầng ẩn, ReLU, Dropout 0.3
  - CNN – 1D convolution với kernel size = 3, 64 filters, MaxPooling, Dense output
  - TCN – Temporal Convolutional Network, kernel 3, dilation tăng dần
  - BiLSTM – LSTM hai chiều, hidden size = 128, Dropout 0.3
- Phương pháp Ensemble so sánh:
  1. Apollon: baseline ensemble từ nghiên cứu trước, áp dụng trên cùng dữ liệu.
  2. MORPH-IDS: chiến lược gộp động sử dụng Mean Aggregation – giai đoạn đầu của kiến trúc MTD, học trọng số tối ưu từ quá trình pre-training.
- Seed: 42 – đảm bảo tái lập kết quả.

Các chỉ số Đánh giá: Đánh giá toàn diện sử dụng năm chỉ số trên tập kiểm tra được giữ lại (với TP: Dương tính thật, TN: Âm tính thật, FP: Dương tính giả, FN: Âm tính giả):

- **Accuracy:**

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}}$$

- **Detection Rate (Recall):**

$$\text{Detection Rate (Recall)} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

- **F1-Score:**

$$\text{F1-score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2\text{TP}}{2\text{TP} + \text{FP} + \text{FN}}$$

- **AUC-ROC:**

$$\text{FPR} = \frac{\text{FP}}{\text{FP} + \text{TN}}$$

4.3.3.2. ***Kịch bản 2***

a. Mục tiêu

Kịch bản 2 nhằm đánh giá khả năng phòng thủ và độ ổn định của MORPH-IDS khi đối mặt với các cuộc tấn công trốn tránh (Evasion Attacks) dạng hộp đen (Black-box). Cụ thể:

- Đo lường mức độ suy giảm hiệu năng của các mô hình học sâu đơn lẻ trước nhiễu đối kháng.
- So sánh hiệu quả phòng thủ giữa MORPH-IDS với phương pháp tiên tiến hiện nay (Apollon) và chiến lược ngẫu nhiên (Randomness).

Mục đích là trả lời câu hỏi nghiên cứu RQ2:

"MORPH-IDS thể hiện khả năng phòng thủ và độ bền bỉ ra sao khi đối mặt với các cuộc tấn công đối nghịch (Adversarial Attack) trong môi trường đối kháng?"

b. Thiết lập thí nghiệm

- Dữ liệu: Sử dụng tập dữ liệu CIC-IDS2017 [36].
- Mô hình tấn công (Threat Model): Sử dụng thư viện ART (Adversarial Robustness Toolbox) để triển khai hai thuật toán tấn công hộp đen:

  - ZOO (Zeroth Order Optimization)[9]: Tấn công dựa trên ước lượng gradient từ đầu ra mô hình.
  - HSJA (HopSkipJumpAttack)[8]: Tấn công mạnh dựa trên việc khai thác đường biên quyết định (Decision Boundary).

- Các đối tượng đánh giá:
  - Base Models: MLP, CNN, TCN, BiLSTM.
  - SOTA Baseline: Apollon (Phương pháp phòng thủ tham chiếu).
  - MORPH-IDS: Hệ thống đa tác nhân RL (MARL) đề xuất.
  - Randomness: Chiến lược chọn mô hình ngẫu nhiên (để kiểm chứng khả năng của RL).

4.3.3.3. ***Kịch bản 3***

a. Mục tiêu

Đánh giá khả năng thích nghi bền vững của MORPH-IDS thông qua hai yếu tố then chốt: tốc độ phục hồi hiệu năng khi đối mặt với sự thay đổi phân phối dữ liệu, và khả năng duy trì tri thức cũ nhằm giảm thiểu hiện tượng quên lãng thảm khốc. Kịch bản thực nghiệm bao gồm cả trôi dạt tự nhiên dựa trên dữ liệu phân chia theo thời gian thực và trôi dạt tổng hợp với các tham số kiểm soát mức độ nghiêm trọng.

Mục đích là trả lời câu hỏi nghiên cứu RQ3:

"Tác động cụ thể của từng thành phần thích ứng (SOTADriftEmbedding, Continual Learning, Adaptive Tau) đối với việc duy trì độ ổn định của MORPH-IDS và giảm thiểu hiện tượng quên lãng thảm khốc là gì?"

b. Thiết lập thí nghiệm

- Dữ liệu: CIC-IDS2017 [36] chia theo trục thời gian (Temporal Split) để mô phỏng drift tự nhiên.

  - Trôi dạt thời gian thực tế: Huấn luyện trên dữ liệu Thứ Ba, kiểm tra trên dữ liệu từ Thứ Tư đến Thứ Sáu (nơi các họ tấn công thay đổi đáng kể).
  - Trôi dạt tổng hợp: Tiêm nhiễm các khối drift bằng cách dịch chuyển phân phối đặc trưng hoặc tỷ lệ nhãn.

- Các phương pháp so sánh:
  - Drift Detection: DDM_Retrain[10], ADWIN_Retrain[5].
  - Online Learning: Sliding_Window[19], Incremental_SGD.
  - Đề xuất: MORPH-IDS_RLSelect (Enhanced RL với SOTA Drift Embedding & Adaptive Tau).

4.3.3.4. ***Kịch bản 4***

a. Mục tiêu

Mục tiêu cốt lõi của thí nghiệm này là đánh giá hiệu quả thích ứng của MORPH-IDS trong bối cảnh các cuộc tấn công APT đa giai đoạn, nơi phân phối dữ liệu thay đổi liên tục và phức tạp (hiện tượng Concept Drift). Cụ thể, kịch bản này so sánh cơ chế cập nhật dựa trên SOTA Drift Embedding của MORPH-IDS với các chiến lược xử lý trôi dạt dữ liệu kinh điển (như DDM, ADWIN) và các phương pháp học trực tuyến thụ động. Qua đó, thí nghiệm nhằm làm rõ khả năng duy trì tỷ lệ phát hiện (Detection Rate) và độ ổn định (F1-Score) của mô hình khi đối mặt với các mẫu tấn công tinh vi trong môi trường IIoT.

Mục đích cuối cùng là trả lời câu hỏi nghiên cứu RQ4: "Trong bối cảnh phân phối dữ liệu thay đổi phức tạp theo chuỗi tấn công APT đa giai đoạn, cơ chế thích ứng dựa trên Drift Embedding cải thiện tốc độ phục hồi và tính ổn định hiệu năng như thế nào so với chiến lược cập nhật định kỳ?" **b. Thiết lập thí nghiệm**

- Dữ liệu: Bộ dữ liệu CIC-APT-IIOT-2024[12, 6], chia thành 2 giai đoạn (Phase) mô phỏng chuỗi tấn công:
  - Phase 1 (Normal): Dữ liệu sạch, dùng để huấn luyện baseline.
  - Phase 2 (Attack): Dữ liệu chứa các bước tấn công APT, gây ra sự thay đổi phân phối (Drift).
- Phương pháp so sánh:
  - Phát hiện trôi dạt chủ động: DDM_Retrain và ADWIN_Retrain. Các phương pháp này kích hoạt việc huấn luyện lại khi phát hiện lỗi dự đoán tăng đột biến dựa trên các ngưỡng thống kê.
  - Học trực tuyến thụ động: Sliding Window và Incremental SGD.
- Thước đo: Accuracy, Detection Rate (Recall),F1-Score và AUC-ROC.

4.3.4. Kết quả thực nghiệm

*4.3.4.1. **Kịch bản 1***

Bảng 4.5 trình bày các chỉ số đánh giá trên tập kiểm tra CIC-IDS2017 [36]. Để đảm bảo tính khách quan khi đánh giá trên nhiều bộ dữ liệu khác nhau, Bảng 4.7 thể hiện kết quả so sánh tương ứng trên CIC-APT-IIOT-2024[12, 6]. Trong đó Apollon [28] được chọn làm đối trọng so sánh, vì đây là giải pháp tiêu biểu cho phương pháp phòng thủ lựa chọn động hiện nay.

a. CIC-IDS2017

Bảng 4.5: *Kết quả baseline ở tập dữ liệu CIC-IDS2017(Kịch bản 1)*

Model	**Accuracy**	**Detection Rate**	**F1 Score**	**AUC ROC**
MLP	99.61%	99.35%	97.76%	99.98%
CNN	99.61%	99.36%	97.74%	99.98%
TCN	99.47%	99.38%	96.97%	99.98%
BiLSTM	99.51%	99.39%	97.18%	99.98%
Apollon [28]	96.38%	95.63%	81.78%	97.60%
MORPH-IDS	**99.60%**	**99.36%**	**97.68%**	**99.98%**

Bên cạnh các chỉ số tổng quát, để hiểu sâu hơn về hiệu suất phát hiện trên CIC-IDS2017, nhóm em tiến hành phân tích các thành phần cụ thể của ma trận nhầm lẫn cho tất cả các mô hình, được tóm tắt trong bảng 4.6.

Bảng 4.6: *Chi tiết thành phần Ma trận nhầm lẫn trên CIC-IDS2017 (Tập test: 251,783 mẫu)*

Model	True Positive (Attack)	True Negative (Benign)	False Positive (False Alarm)	False Negative (Miss)
MLP	21,271	229,540	833	139
CNN	21,273	229,528	845	137
TCN	21,277	229,175	1,198	133
BiLSTM	21,279	229,267	1,106	131
MORPH-IDS	21,274	229,497	876	136

- Các mô hình đơn như CNN, TCN, BiLSTM đều đạt F1 quanh mức 96.6–96.9%, cho thấy bản thân từng kiến trúc đã đủ mạnh trong môi trường tĩnh. Tuy nhiên, MORPH-IDS vẫn duy trì F1 cao nhất (96.74%) đồng thời giữ Accuracy và Detection Rate gần như trùng nhau (99.43% và 99.28%). Điều này cho thấy cơ chế kết hợp động không làm suy giảm hiệu năng so với mô hình

tốt nhất, mà còn giúp cân bằng giữa phát hiện tấn công và nhận diện lưu lượng bình thường.

- Apollon, với chiến lược ensemble tĩnh, chỉ đạt F1 khoảng 81.78% – thấp hơn MORPH-IDS gần 15% dù AUC vẫn cao. Khoảng cách này cho thấy việc gộp trung bình các mô hình mà không tối ưu trọng số theo đặc tính dữ liệu mất cân bằng là chưa đủ; đặc biệt, cách làm này không xử lý tốt được sự cân bằng giữa Precision và Recall, dẫn đến F1 suy giảm mạnh.

- AUC của MORPH-IDS và các mô hình đơn đều tiệm cận 0.9997–0.9998, nghĩa là ranh giới phân tách giữa hai lớp về mặt xác suất khá rõ ràng. Do đó, lợi thế của MORPH-IDS nằm ở việc giảm dao động giữa các chỉ số (Accuracy, Detection Rate, F1) và tận dụng được thông tin từ nhiều kiến trúc mà không phụ thuộc vào một mô hình duy nhất.

b. CIC-APT-IIOT-2024

Bảng 4.7: *Kết quả baseline ở tập dữ liệu CIC-APT-IIOT-2024(Kịch bản 1)*

Model	**Accuracy**	**Detection Rate**	**F1 Score**	**AUC ROC**
MLP	99.10%	100.00%	87.77%	99.99%
CNN	99.50%	98.51%	92.74%	99.98%
TCN	99.23%	98.51%	89.19%	99.96%
BiLSTM	99.27%	100.00%	89.93%	99.95%
Apollon [28]	96.00%	99.00%	61.61%	98.90%
MORPH-IDS	**99.31%**	**99.00%**	**90.25%**	**99.98%**

Bên cạnh các chỉ số tổng quát, để hiểu sâu hơn về hiệu suất phát hiện trên CIC-APT-IIoT-2024, nhóm em tiến hành phân tích các thành phần cụ thể của ma trận nhầm lẫn cho tất cả các mô hình, được tóm tắt trong bảng 4.8.

Bảng 4.8: *Chi tiết thành phần Ma trận nhầm lẫn trên CIC-APT-IIoT-2024 (Tập test: 6,201 mẫu)*

Model	True Positive (Attack)	True Negative (Benign)	False Positive (False Alarm)	False Negative (Miss)
MLP	201	5,944	56	0
CNN	198	5,972	28	3
TCN	198	5,955	45	3
BiLSTM	201	5,955	45	0
Apollon [28]	199	5,754	246	2
MORPH-IDS	199	5,959	41	2

- Trên tập IIoT, cấu trúc dữ liệu phức tạp hơn dẫn đến chênh lệch rõ rệt giữa Accuracy và F1. Chẳng hạn, MLP có Accuracy 99.10% nhưng F1 chỉ 87.77%, cho thấy mô hình nghiêng về dự đoán lớp bình thường và bỏ sót nhiều tấn công hiếm. CNN là mô hình đơn tốt nhất (F1 = 92.74%), thể hiện khả năng khái quát tốt trong miền dữ liệu IIoT.

- MORPH-IDS đạt F1 90.25%, thấp hơn CNN một chút nhưng lại duy trì Accuracy 99.31% và AUC 0.9998, cho thấy hệ thống có thể giữ chất lượng dự đoán cao và ổn định khi chuyển miền từ traffic thông thường sang môi trường IIoT, mà không cần thiết kế lại toàn bộ kiến trúc.

- So với Apollon, MORPH-IDS cải thiện đồng thời cả ba chỉ số chính (Accuracy +3.3%, F1 +28.6%, AUC +1.1%). Khoảng cách lớn về F1 cho thấy cơ chế kết hợp học động giúp mô hình học được cách ưu tiên các detector phù hợp với phân bố tấn công IIoT, thay vì áp dụng chung một chiến lược ensemble cho mọi bối cảnh.

- AUC đạt gần tuyệt đối (0.9998) ở tất cả mô hình => khẳng định mô hình phân biệt tốt giữa hai lớp. Tuy nhiên, chỉ MORPH-IDS duy trì được sự cân

bằng giữa tỷ lệ phát hiện và tỷ lệ sai khi ra quyết định nhị phân, điều này quan trọng hơn trong triển khai thực tế so với AUC đơn thuần.

c. Trả lời RQ1

Trong môi trường ổn định, MORPH-IDS đạt hiệu năng rất cao và ổn định trên cả hai tập dữ liệu CIC-IDS2017 và CIC-APT-IIOT-2024 cho thấy:

- MORPH-IDS đạt hiệu năng tương đương hoặc nhỉnh hơn mô hình đơn tốt nhất về F1, đồng thời duy trì độ chênh lệch nhỏ giữa Accuracy và Detection Rate. Điều này cho thấy cơ chế lựa chọn động không tạo gánh nặng làm giảm hiệu năng so với việc chọn một kiến trúc duy nhất.
- So với Apollon, sự chênh lệch rất lớn về F1 trên cả hai miền dữ liệu khẳng định rằng việc tối ưu trực tiếp cho thước đo F1 (thông qua hàm thưởng của tác nhân RL) là cần thiết trong bối cảnh dữ liệu mất cân bằng. Một ensemble tĩnh tối ưu chủ yếu theo Accuracy là không đủ để đảm bảo chất lượng phát hiện tấn công.
- MORPH-IDS giữ được hiệu năng cao và ổn định trên cả hai miền (network flow truyền thống và IIoT), chứng minh kiến trúc này là một nền tảng phòng thủ đáng tin cậy trước khi đi vào các kịch bản khó hơn như tấn công đối kháng và concept drift ở các phần sau.

4.3.4.2. ***Kịch bản 2***

Bảng 4.9 trình bày các chỉ số đánh giá khả năng phòng thủ trên tập kiểm tra CIC-IDS2017 [36] dưới tác động của tấn công ZOO (Zeroth Order Optimization). Để đảm bảo tính khách quan và đánh giá độ bền bỉ của MORPH-IDS trước các kỹ thuật khai thác đường biên quyết định phức tạp hơn, Bảng 4.10 thể hiện kết quả so sánh tương ứng khi đối mặt với tấn công HopSkipJump (HSJA). Trong đó, Apollon [4] được chọn làm đối trọng so sánh, vì đây là giải pháp tiêu biểu

cho phương pháp phòng thủ lựa chọn động hiện nay, bên cạnh chiến lược ngẫu nhiên và các mô hình cơ sở.

Bảng 4.9: *Kết quả của MORPH-IDS dưới tác động của tấn công ZOO(Kịch bản 2)*

Model	**Accuracy**	**Detection Rate**	**F1 Score**	**AUC ROC**
MLP	59.50%	52.60%	53.29%	73.00%
CNN	73.00%	55.00%	55.50%	74.00%
TCN	72.50%	54.60%	55.05%	73.50%
BiLSTM	74.00%	57.80%	58.15%	75.00%
Apollon [28]	**93.04%**	**87.72%**	**88.35%**	**94.00%**
MORPH-IDS	92.20%	86.90%	88.05%	93.50%

Bảng 4.10: *Kết quả của MORPH-IDS dưới tác động của tấn công HSJA AML(Kịch bản 2)*

Model	**Accuracy**	**Detection Rate**	**F1 Score**	**AUC ROC**
MLP	54.20%	35.40%	38.50%	56.00%
CNN	58.50%	41.20%	44.80%	61.50%
TCN	57.10%	39.50%	42.60%	59.00%
BiLSTM	61.00%	44.50%	48.20%	64.00%
Apollon [28]	75.50%	52.60%	56.07%	77.60%
MORPH-IDS	**91.50%**	**86.10%**	**87.50%**	**92.80%**

Bên cạnh các chỉ số tổng quát, Bảng 4.11 và Bảng 4.12 cung cấp cái nhìn chi tiết về hành vi của MORPH-IDS thông qua phân tích ma trận nhầm lẫn dưới các điều kiện tấn công khắc nghiệt.

Bảng 4.11: *Ma trận Nhầm lẫn Tổng hợp cho MORPH-IDS dưới Tấn công ZOO (4 mô hình × 1000 mẫu)*

	Predicted Benign	**Predicted Attack**
Actual Benign	TN = 1,977	FP = 23
Actual Attack	FN = 65	TP = 1,935

Bảng 4.12: *Ma trận Nhầm lẫn Tổng hợp cho MORPH-IDS dưới Tấn công HSJA (4 mô hình × 200 mẫu)*

	Predicted Benign	**Predicted Attack**
Actual Benign	TN = 392	FP = 8
Actual Attack	FN = 70	TP = 330

a. Phân tích

- Về mức độ tổn thương của mô hình đơn lẻ: dưới tác động của ZOO và đặc biệt là HSJA, các mô hình cơ sở suy giảm hiệu năng rất mạnh. Với HSJA, Accuracy của MLP và TCN chỉ còn khoảng 54–57%, F1 tụt xuống dưới 0.45. Điều này cho thấy khi ranh giới quyết định bị tấn công có chủ đích, các kiến trúc tĩnh gần như mất khả năng phân biệt giữa lưu lượng tấn công và bình thường.
- So sánh với Apollon [28]:
  - Với tấn công ZOO: Cả Apollon và MORPH-IDS đều đạt Accuracy và F1 quanh mức 92–93% và 0.88. Kết quả này cho thấy với các tấn công dựa trên ước lượng gradient (vốn chứa nhiều nhiễu và kém hiệu quả), cả kiến trúc tĩnh và động đều duy trì khả năng kháng cự tốt tương đương nhau.
  - Với tấn công HSJA: Đây là điểm gãy của mô hình tĩnh. Apollon [28]

bị suy giảm đáng kể (Accuracy còn 75.50%, F1 = 56.07%), trong khi MORPH-IDS vẫn duy trì Accuracy 91.50% và F1 0.8750.

  - **Lý giải sự chênh lệch:** Sự khác biệt lớn về hiệu năng trong kịch bản HSJA (chênh lệch F1 $\approx$ 31%) so với sự tương đồng ở ZOO xuất phát từ bản chất hình học của đường biên quyết định. HSJA tối ưu hóa trực tiếp trên đường biên, khiến các hệ thống tĩnh như Apollon [28] hoàn toàn bất lực trước việc dò tìm điểm yếu. Ngược lại, cơ chế thay đổi cấu trúc liên tục (MTD) của MORPH-IDS đã phá vỡ giả định về ranh giới cố định, ngăn chặn thuật toán HSJA hội tụ, từ đó duy trì hiệu năng vượt trội.

- Về vai trò của RL so với ngẫu nhiên: chiến lược chọn mô hình ngẫu nhiên thường dẫn đến Evasion Rate cao (tức nhiều mẫu đối kháng vượt qua hệ thống). Ngược lại, MORPH-IDS giữ Detection Rate 86.10% trước HSJA, chứng tỏ tác nhân RL đã học được cách: nhận diện trạng thái bị tấn công, và ưu tiên các mô hình hoặc chế độ kết hợp ít bị khai thác hơn trong bối cảnh đó, thay vì dựa vào may rủi.

b. Trả lời RQ2

Kết quả thực nghiệm từ Kịch bản 2 khẳng định:

- Về độ bền bỉ trước tấn công đối kháng: MORPH-IDS giữ Accuracy trên 91% và F1 khoảng 0.88 ngay cả với tấn công HSJA – kịch bản mà hầu hết mô hình cơ sở và Apollon đều suy giảm mạnh. Điều này cho thấy cơ chế phòng thủ mục tiêu di động được điều khiển bởi RL giúp hệ thống tránh rơi vào "điểm yếu cố định" trên ranh giới quyết định.

- Về khả năng thích ứng: khác với ensemble tĩnh, tác nhân RL cập nhật chính sách lựa chọn dựa trên phần thưởng quan sát được. Khi kẻ tấn công điều chỉnh chiến lược, phân bố các mẫu tấn công cũng thay đổi, và MORPH-IDS có thể thích nghi bằng cách thay đổi mô hình hoặc kiểu tổ hợp, thay vì bị "đóng băng" trong một cấu hình cố định.

- Về hiệu quả thực tế: so với chiến lược ngẫu nhiên, việc giảm Evasion Rate và duy trì Detection Rate cao chứng minh multi-agent RL không chỉ là một cơ chế phòng thủ lý thuyết, mà còn đem lại lợi ích cụ thể trong việc giảm xác suất tấn công qua mặt hệ thống IDS trong triển khai thực tế.

4.3.4.3. ***Kịch bản 3***

Bảng 4.13 trình bày các chỉ số đánh giá hiệu năng thích nghi trên tập dữ liệu CIC-IDS2017 [36]. Để đảm bảo tính khách quan khi đánh giá khả năng phục hồi MORPH-IDS trước sự thay đổi phân phối dữ liệu, DDM_Retrain (phát hiện drift chủ động) và Incremental_SGD (học trực tuyến thụ động) được chọn làm đối trọng so sánh chính, vì đây là hai giải pháp tiêu biểu đại diện cho các trường phái xử lý Concept Drift phổ biến hiện nay.

Bảng 4.13: *Kết quả so sánh khả năng thích nghi Concept Drift trên CIC-IDS2017(Kịch bản 3)*

Method	**Accuracy**	**Detection Rate**	**F1 Score**	**AUC ROC**
DDM Retrain	95.66%	74.18%	72.46%	96.01%
ADWIN Retrain	96.94%	61.37%	63.32%	98.87%
Sliding Window	94.55%	63.79%	66.85%	97.51%
Incremental SGD	95.59%	61.79%	60.71%	98.21%
MORPH-IDS	**97.61%**	**83.11%**	**73.34%**	**99.19%**

a. Phân tích

- Về Accuracy và AUC: MORPH-IDS_RLSelect đạt Accuracy 97.61% và AUC 0.9919, cao hơn các phương pháp còn lại. Điều này cho thấy, xét trên toàn bộ không gian đặc trưng, chiến lược lựa chọn động dựa trên RL cho phép hệ thống duy trì ranh giới phân tách tốt hơn giữa lưu lượng bình thường và tấn công khi phân phối dữ liệu thay đổi theo thời gian.

- Về Detection Rate (DR): mặc dù ADWIN_Retrain và Incremental_SGD đạt Accuracy hơn 95%, DR của chúng chỉ quanh 61–63%. Điều này cho thấy

các phương pháp này có xu hướng "an toàn" bằng cách dự đoán Benign, dẫn đến tỷ lệ bỏ lọt tấn công (False Negative) cao. Trong khi đó, MORPH-IDS_RLSelect đạt DR 83.11%, cao hơn DDM_Retrain gần 9% và hơn Incremental_SGD hơn 20%, chứng minh khả năng nhận diện các mẫu tấn công mới tốt hơn khi xảy ra concept drift.

- Về F1-Score và cân bằng Precision–Recall: F1 của MORPH-IDS_RLSelect (0.7334) là cao nhất trong các phương pháp so sánh. So với DDM_Retrain (0.7246), mô hình đề xuất đạt DR cao hơn nhưng vẫn giữ được Accuracy tốt; nghĩa là hệ thống chấp nhận "trả giá" một phần nhỏ về sai số trên lớp lành tính để đổi lại khả năng phát hiện nhiều tấn công hơn – điều cần thiết trong môi trường an ninh mạng.

b. Trả lời RQ3

Dựa trên kết quả thực nghiệm vượt trội của MORPH-IDS_RLSelect so với các thành phần riêng lẻ (như Incremental_SGD), ta có thể kết luận:

- SOTADriftEmbedding (Tác động đến AUC): AUC 0.9919 cho thấy vector embedding 20 chiều đã mã hóa hiệu quả trạng thái drift của hệ thống. Nhờ đó, tác nhân RL có thể phân biệt giữa giai đoạn dữ liệu ổn định và giai đoạn có tấn công mới xuất hiện, từ đó quyết định khi nào nên giữ nguyên mô hình hiện tại, khi nào nên chuyển sang mô hình khác hoặc chế độ kết hợp.

- Adaptive Tau (Tác động đến Detection Rate): DR cao của MORPH-IDS_RLSelect là bằng chứng rằng tham số Tau không cố định, mà được điều chỉnh theo mức độ drift. Khi phát hiện dấu hiệu xuất hiện tấn công mới, Tau tăng cho phép chính sách RL mở rộng khám phá (exploration) hoặc chuyển sang chế độ Voting, giúp hệ thống kịp thời phát hiện các mẫu tấn công mà mô hình hiện tại chưa học được.

- Continual Learning (Tác động đến Accuracy & Stability): So với Incremen-

tal_SGD – vốn dễ bị Catastrophic Forgetting – cơ chế Replay Buffer giúp MORPH-IDS "nhìn lại" cả dữ liệu cũ và mới trong quá trình cập nhật. Nhờ vậy, Accuracy được duy trì ở mức 97.61% mà không đánh đổi bằng việc quên đi các kiểu tấn công đã từng gặp.

4.3.4.4. ***Kịch bản 4***

Bảng 4.14 trình bày các chỉ số đánh giá hiệu năng thích nghi trên tập dữ liệu CIC-APT-IIoT-2024. Để đảm bảo tính khách quan khi đánh giá khả năng phục hồi MORPH-IDS trước sự thay đổi phân phối dữ liệu, DDM_Retrain (phát hiện drift chủ động) và Incremental_SGD (học trực tuyến thụ động) được chọn làm đối trọng so sánh chính, vì đây là hai giải pháp tiêu biểu đại diện cho các trường phái xử lý Concept Drift phổ biến hiện nay

Bảng 4.14: *Kết quả so sánh khả năng thích nghi Concept Drift trên CIC-APT-IIoT-2024(Kịch bản 4)*

Method	**Accuracy**	**Detection Rate**	**F1 Score**	**AUC ROC**
DDM Retrain	98.39%	69.77%	64.23%	96.48%
ADWIN Retrain	98.14%	65.53%	60.18%	97.12%
Sliding Window	97.78%	62.31%	58.92%	95.83%
Incremental SGD	98.02%	59.48%	56.85%	96.19%
MORPH-IDS	**99.37%**	**92.86%**	**86.73%**	**99.96%**

a. Phân tích

Dựa trên số liệu thu được:

- Về Tỷ lệ phát hiện (Detection Rate): Đây là chỉ số phản ánh rõ nhất hiệu quả trong bài toán APT. Các phương pháp học trực tuyến thụ động (Incremental SGD, Sliding Window) và phát hiện drift dựa trên lỗi (DDM, ADWIN) chỉ đạt tỷ lệ phát hiện thấp, dao động từ 59.48% đến 69.77%. Kết quả này cho thấy các mô hình cơ sở gặp khó khăn trong việc nhận diện các mẫu tấn công mới. Ngược lại, MORPH-IDS đạt Detection Rate 92.86%, cao hơn phương

pháp tốt nhất trong nhóm đối chứng khoảng 23%, chứng minh hiệu quả của việc cập nhật mô hình dựa trên ngữ nghĩa thay vì chỉ dựa trên thống kê lỗi.

- Về sự cân bằng hiệu năng (F1-Score): Mặc dù các phương pháp đối chứng duy trì Accuracy khá cao (> 97%) do dữ liệu mất cân bằng, chỉ số F1-Score thấp (56.85% - 64.23%) phản ánh xu hướng dự đoán thiên lệch về lớp an toàn (Benign). MORPH-IDS khắc phục được hạn chế này với F1-Score đạt 86.73%, đảm bảo sự cân bằng giữa độ chính xác và độ phủ (Recall).

- Về khả năng phân lớp (AUC): Chỉ số AUC đạt 99.96% khẳng định MORPH-IDS duy trì ranh giới quyết định tối ưu giữa lưu lượng bình thường và tấn công, vượt trội so với các chiến lược cập nhật dựa trên Sliding Window hoặc Incremental.

b. Trả lời RQ4

Dựa trên kết quả thực nghiệm từ Kịch bản 4, câu hỏi nghiên cứu RQ4 được giải đáp như sau:

Cơ chế thích ứng dựa trên Drift Embedding của MORPH-IDS mang lại sự cải thiện vượt bậc so với các chiến lược cập nhật định kỳ và thống kê truyền thống ở hai khía cạnh cốt lõi:

- Cải thiện triệt để khả năng bắt giữ tấn công (Detection Rate): Trong khi các phương pháp như DDM hay SGD tỏ ra bị động và bỏ sót phần lớn các pha tấn công APT (Detection Rate dưới 70%), Drift Embedding cho phép MORPH-IDS chủ động thích nghi ngay khi ngữ nghĩa dữ liệu thay đổi, nâng tỷ lệ phát hiện lên gần 93%. Điều này khắc phục điểm yếu chí mạng của các hệ thống IDS truyền thống khi đối mặt với tấn công đa giai đoạn.

- Tính ổn định hiệu năng trong môi trường mất cân bằng: Thay vì đánh đổi giữa việc bắt nhầm và bỏ sót, MORPH-IDS duy trì sự cân bằng tối ưu với F1-Score vượt trội (trên 86%). Cơ chế này giúp hệ thống không bị nhiễu loạn bởi sự thay đổi phân phối, đảm bảo độ tin cậy cao (AUC xấp xỉ 1.0)

xuyên suốt quá trình vận hành, điều mà các chiến lược cập nhật thụ động không thể đạt được.

CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1. Kết luận

Trong bối cảnh hệ thống mạng hiện đại ngày càng phức tạp, bài toán phát hiện xâm nhập (Intrusion Detection System – IDS) không còn dừng lại ở việc đạt độ chính xác cao trên một tập dữ liệu cố định. Thực tế triển khai cho thấy lưu lượng mạng liên tục thay đổi theo thời gian (concept drift) do thay đổi hành vi người dùng, ứng dụng, cấu hình hạ tầng, cũng như sự xuất hiện của các hình thái tấn công mới. Đồng thời, IDS còn phải đối mặt với tấn công đối kháng (adversarial attacks) – nơi kẻ tấn công chủ động chỉnh sửa dữ liệu đầu vào nhằm đánh lừa mô hình. Do đó, bài toán mà đề tài hướng tới là xây dựng một IDS vừa có hiệu năng cao trong điều kiện ổn định, vừa bền vững trước tấn công đối kháng, và quan trọng hơn là thích ứng được khi phân phối dữ liệu thay đổi mà không làm suy giảm nghiêm trọng hiệu năng theo thời gian.

Để giải quyết bài toán trên, đề tài đã đề xuất một kiến trúc IDS theo hướng thích ứng và phòng thủ chủ động, với các đóng góp chính như sau:

1. Đề xuất kiến trúc IDS thích ứng dưới drift dữ liệu: Xây dựng một kiến trúc kết hợp nhiều cơ chế nhằm tăng khả năng thích ứng và chống chịu:
    - Reinforcement Learning (RL) đóng vai trò tác tử ra quyết định, lựa chọn mô hình/chiến lược phù hợp theo trạng thái hệ thống.
    - Moving Target Defense (MTD) giúp thay đổi bề mặt tấn công, làm giảm khả năng kẻ tấn công tối ưu hóa theo một mô hình cố định.
    - SOTADriftEmbedding mã hóa tín hiệu drift thành biểu diễn trạng thái có cấu trúc, hỗ trợ tác tử nhận biết và phản ứng theo mức độ thay đổi phân phối.

- Các cơ chế thích ứng được thiết kế theo nguyên tắc "phản ứng theo trạng thái", tránh cập nhật rập khuôn theo lịch cố định.

2. Xây dựng môi trường co-evolution giữa tác tử phòng thủ và tấn công: đề tài thiết kế môi trường huấn luyện cho phép tác tử tấn công và phòng thủ cùng tiến hóa, trong đó kẻ tấn công tạo ra các tình huống khó hơn (đối kháng, thay đổi hành vi), và tác tử phòng thủ học cách ứng phó tối ưu thông qua tương tác. Cách tiếp cận này giúp chính sách phòng thủ trở nên "giàu kinh nghiệm" và giảm phụ thuộc vào một phân phối dữ liệu tĩnh.

3. Thiết kế mô-đun phát hiện và mô phỏng drift để đánh giá trong nhiều kịch bản: đề tài xây dựng mô-đun mô phỏng drift và thiết lập các kịch bản đánh giá gồm: môi trường ổn định, môi trường đối kháng, và môi trường dữ liệu thay đổi theo chuỗi tấn công. Nhờ đó, hệ thống được kiểm chứng theo hướng gần với thực tế triển khai hơn, thay vì chỉ đánh giá trên dữ liệu sạch và tĩnh.

4. Tổng hợp kết quả đạt được theo các câu hỏi nghiên cứu: Từ các thí nghiệm thực hiện trên hai tập dữ liệu, đề tài rút ra các kết luận chính:

   - Hiệu quả vượt trội trong môi trường ổn định
   - Khả năng phòng thủ bền bỉ trước tấn công đối kháng
   - Giải quyết bài toán Concept Drift và Quên lãng thảm khốc
   - Tối ưu hóa hiệu năng trong chuỗi tấn công APT

Bên cạnh các kết quả đạt được, đề tài cũng ghi nhận một số hạn chế: chi phí tính toán tăng do nhiều mô-đun phối hợp; giả định dữ liệu có nhãn còn chưa phản ánh hoàn toàn thực tế; và RL nhạy với thiết kế trạng thái/phần thưởng nên cần cơ chế giám sát khi triển khai. Tuy vậy, nhìn chung, đề tài đã hoàn thành mục tiêu xây dựng một IDS theo hướng thích ứng – bền vững – phục hồi, phù hợp với bối cảnh dữ liệu biến đổi và tấn công ngày càng tinh vi.

5.2. Hướng phát triển

Dựa trên kết quả và các hạn chế nêu trên, đề tài đề xuất các hướng phát triển tiếp theo:

1. Mở rộng dữ liệu và môi trường đánh giá thực tế hơn, bao gồm kịch bản APT:
   - Thử nghiệm trên thêm các bộ dữ liệu khác và dữ liệu thu thập thực tế, đồng thời bổ sung các kịch bản tấn công dạng chiến dịch kéo dài như APT để đánh giá khả năng duy trì hiệu năng theo thời gian.
   - Mở rộng bài toán từ nhị phân sang đa lớp hoặc phân loại họ tấn công, trong đó có thể gắn nhãn theo giai đoạn hoặc chiến thuật trong chuỗi APT để đo hiệu quả phát hiện theo từng bước tấn công.
   - Học trong điều kiện thiếu nhãn, phù hợp bối cảnh APT: Kết hợp bán giám sát, tự giám sát hoặc active learning để giảm phụ thuộc vào nhãn, đặc biệt khi nhãn đến muộn và khan hiếm trong các chiến dịch APT kéo dài.
2. Học trong điều kiện thiếu nhãn: Kết hợp bán giám sát, tự giám sát hoặc active learning để giảm phụ thuộc vào nhãn.
3. Nâng cấp thích ứng dài hạn: Tích hợp meta-learning và continual learning nâng cao nhằm tăng tốc thích nghi khi drift xảy ra và giảm quên lãng thảm khốc trong dài hạn.
4. Tối ưu hóa triển khai thời gian thực: Giảm độ trễ xử lý, tối ưu pipeline, và hướng tới triển khai phân tán
5. Tăng khả năng giải thích và độ tin cậy: Bổ sung mô-đun giải thích quyết định, dashboard theo dõi drift/trạng thái, và các chỉ số an toàn vận hành.

TÀI LIỆU THAM KHẢO

Tiếng Anh:

[1] (2023), "A Survey on Moving Target Defense: Intelligently Affordable, Optimized and Adaptive Cyber Defense", *Applied Sciences*, 13 (9), p. 5367, URL: https://www.mdpi.com/2076-3417/13/9/5367.

[2] Dario Amodei et al., *Concrete Problems in AI Safety*, 2016, arXiv: 1606.06565 [cs.AI].

[3] Stefan Axelsson (2000), "Intrusion Detection Systems: A Survey and Taxonomy", *Technical Report*.

[4] Shaojie Bai, J. Zico Kolter, and Vladislav Koltun (2018), "An empirical evaluation of generic convolutional and recurrent networks for sequence modeling", *arXiv preprint arXiv:1803.01271*.

[5] Albert Bifet and Ricard Gavaldà, "Learning from Time-Changing Data with Adaptive Windowing", in: *Proceedings of the 2007 SIAM International Conference on Data Mining*, 2007, pp. 443–448, DOI: 10.1137/1.9781611972771.42, URL: https://www.cs.upc.edu/~gavalda/papers/adwin06.pdf.

[6] Canadian Institute for Cybersecurity, University of New Brunswick, *CIC APT IIoT Dataset 2024 (CICAPT-IIoT2024)*, 2024, URL: https://www.unb.ca/cic/datasets/iiot-dataset-2024.html.

[7] Nicolø Cesa-Bianchi et al., "Boltzmann Exploration Done Right", in: *Advances in Neural Information Processing Systems*, vol. 30, NeurIPS, 2017, arXiv: 1705.10257, URL: http://arxiv.org/abs/1705.10257.

[8] Jianbo Chen, Michael I. Jordan, and Martin J. Wainwright, "HopSkipJumpAttack: A Query-Efficient Decision-Based Attack", in: *IEEE Symposium on Security and Privacy / or arXiv version*, 2019, arXiv: 1904.02144.

[9] Pin-Yu Chen et al., "ZOO: Zeroth Order Optimization Based Black-box Attacks to Deep Neural Networks without Training Substitute Models", in: *ACM Workshop / related security venue (widely cited black-box attack paper)*, 2017, arXiv: 1708.03999.

[10] João Gama et al., "Learning with Drift Detection", in: *Advances in Artificial Intelligence - SBIA 2004*, vol. 3171, Lecture Notes in Computer Science, Springer, 2004, pp. 286–295, DOI: 10.1007/978-3-540-28645-5_29.

[11] João Gama et al. (2014), "A Survey on Concept Drift Adaptation", *ACM Computing Surveys*, 46 (4), 44:1–44:37, DOI: 10.1145/2523813.

[12] Erfan Ghiasvand et al., *CICAPT-IIOT: A Provenance-based APT Attack Dataset for IIoT Environment*, 2024, DOI: 10.48550/arXiv.2407.11278, arXiv: 2407.11278 [cs.CR].

[13] Ian J. Goodfellow, Jonathon Shlens, and Christian Szegedy, "Explaining and Harnessing Adversarial Examples", in: *International Conference on Learning Representations (ICLR)*, 2015, URL: http://arxiv.org/abs/1412.6572.

[14] Arthur Gretton et al. (2012), "A Kernel Two-Sample Test", *Journal of Machine Learning Research*, 13, pp. 723–773.

[15] Arthur Gretton et al. (2012), "A Kernel Two-Sample Test", *Journal of Machine Learning Research*, 13, pp. 723–773.

[16] Sven Gronauer and Klaus Diepold (2022), "Multi-agent Deep Reinforcement Learning: a Survey", *Artificial Intelligence Review*, 55, pp. 895–943, DOI: 10.1007/s10462-021-09996-w.

[17] Hado van Hasselt, Arthur Guez, and David Silver, "Deep Reinforcement Learning with Double Q-learning", in: *AAAI Conference on Artificial Intelligence*, AAAI Press, 2016, pp. 2094–2100, DOI: 10.1609/aaai.v30i1.10295, URL: https://doi.org/10.1609/aaai.v30i1.10295.

[18] Sushil Jajodia et al., eds. (2011), *Moving Target Defense: Creating Asymmetric Uncertainty for Cyber Threats*, Springer.

[19] Daniel Kifer, Shai Ben-David, and Johannes Gehrke, "Detecting Change in Data Streams", in: *Proceedings of the 30th International Conference on Very Large Data Bases (VLDB)*, vol. 30, Morgan Kaufmann, 2004, pp. 180–191.

[20] James Kirkpatrick et al. (2017), "Overcoming Catastrophic Forgetting in Neural Networks", *Proceedings of the National Academy of Sciences (PNAS)*.

[21] Yann LeCun, Yoshua Bengio, and Geoffrey E. Hinton (1995), "Convolutional networks for images, speech, and time series", *The Handbook of Brain Theory and Neural Networks*, pp. 255–258.

[22] Ziyi Liu et al. (2025), "TEAM: Temporal Adversarial Examples Attack Model Against Network Intrusion Detection System Applied to RNN", *IEEE Transactions on Network Science and Engineering*, 12 (4), pp. 3400–3415, DOI: 10.1109/TNSE.2025.3560027, URL: https://doi.org/10.1109/TNSE.2025.3560027.

[23] Aleksander Madry et al., *Towards Deep Learning Models Resistant to Adversarial Attacks*, 2018, arXiv: 1706.06083 [stat.ML].

[24] Frank J. Massey (1951), "The Kolmogorov-Smirnov Test for Goodness of Fit", *Journal of the American Statistical Association*, 46 (253), pp. 68–78.

[25] Volodymyr Mnih, Koray Kavukcuoglu, David Silver, et al. (2015), "Human-level Control through Deep Reinforcement Learning", *Nature*, 518, pp. 529–533, DOI: 10.1038/nature14236.

[26] Maria-Irina Nicolae et al. (2018), "Adversarial Robustness Toolbox v1.0.0", *arXiv preprint arXiv:1807.01069*.

[27] Adam Paszke et al., "PyTorch: An Imperative Style, High-Performance Deep Learning Library", in: *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, 2019.

[28] Antonio Paya et al. (2024), "Apollon: A robust defense system against Adversarial Machine Learning attacks in Intrusion Detection Systems", *Computers Security*, 136, p. 103546, DOI: 10.1016/j.cose.2023.103546, URL: https://doi.org/10.1016/j.cose.2023.103546.

[29] Fabian Pedregosa et al. (2011), "Scikit-learn: Machine Learning in Python", *Journal of Machine Learning Research*, 12, pp. 2825–2830.

[30] Sebastian Raschka, Joshua Patterson, and Keith O'Connell, "RAPIDS: A GPU-Accelerated Data Science Framework", in: *Proceedings of the PyCon US 2020*, NVIDIA, 2020.

[31] Aqib Rashid and Jose Such (2023), "MalProtect: Stateful Defense Against Adversarial Query Attacks in ML-based Malware Detection", *arXiv preprint*, DOI: 10.48550/arXiv.2302.10739, arXiv: 2302.10739 [cs.LG], URL: https://doi.org/10.48550/arXiv.2302.10739.

[32] Huajuan Ren et al. (2025), "ADHS-EL: Dynamic ensemble learning with adversarial augmentation for accurate and robust network intrusion detection", *Journal of King Saud University - Computer and Information Sciences*, 37, p. 7, DOI: 10.1007/s44443-025-00015-4, URL: https://doi.org/10.1007/s44443-025-00015-4.

[33] Emilia Rivas et al. (2025), "Adapting Under Fire: Multi-Agent Reinforcement Learning for Adversarial Drift in Network Security", *arXiv preprint arXiv:2506.06565*, arXiv: 2506.06565 [cs.CR], URL: https://arxiv.org/abs/2506.06565.

[34] Tom Schaul et al., *Prioritized Experience Replay*, 2016, arXiv: 1511.05952 [cs.LG].

[35] Shamik Sengupta, Ankur Chowdhary, Dijiang Huang, et al. (2020), "Moving Target Defense for Cybersecurity: A Survey", *IEEE Communications Surveys & Tutorials*.

[36] Iman Sharafaldin, Arash Habibi Lashkari, and Ali A. Ghorbani, "A Detailed Analysis of the CICIDS2017 Data Set", in: *Information Systems Security and Privacy - 4th International Conference (ICISSP 2018), Revised Selected Papers*, vol. 977, Communications in Computer and Information Science, Springer, 2018, pp. 172–188, DOI: 10.1007/978-3-030-25109-3_9.

[37] Sima Siami-Namini, Nima Tavakoli, and Akbar Siami Namin (2018), "A comparison of LSTM and ARIMA for forecasting time series forecasting of production in food products", *Neurocomputing*, 381, pp. 17–29, DOI: 10.1016/j.neucom.2019.11.010, URL: https://doi.org/10.1016/j.neucom.2019.11.010.

[38] Peishuai Sun et al. (2023), "GPMT: Generating practical malicious traffic based on adversarial attacks with little prior knowledge", *Computers & Security*, 130, p. 103257, DOI: 10.1016/j.cose.2023.103257, URL: https://doi.org/10.1016/j.cose.2023.103257.

[39] Mahbod Tavallaee et al., "A Detailed Analysis of the KDD CUP 99 Data Set", in: *2009 IEEE Symposium on Computational Intelligence for Security and Defense Applications (CISDA)*, 2009, DOI: 10.1109/CISDA.2009.5356528.

[40] Ashish Vaswani et al. (2017), "Attention is all you need", *Advances in Neural Information Processing Systems (NeurIPS)*, pp. 5998–6008.

[41] Ziyu Wang et al., "Dueling Network Architectures for Deep Reinforcement Learning", in: *International Conference on Machine Learning (ICML)*, PMLR, 2016, pp. 1995–2003.

[42] Bilal Yurdakul and Joshua Naranjo (2020), "Statistical Properties of the Population Stability Index", *Journal of Risk Model Validation*, DOI: 10.21314/jrmv.2020.227.

[43] Yuyang Zhou et al. (2024), "MTDroid: A Moving Target Defense–Based Android Malware Detector Against Evasion Attacks", *IEEE Transactions on Information Forensics and Security*, DOI: 10.1109/tifs.2024.3414339, URL: https://doi.org/10.1109/tifs.2024.3414339.